

1. CNN（卷积神经网络）

1.1 模型结构

CNN 最初是为图像处理设计的，但也被广泛应用于文本挖掘。其核心结构包括：

- 输入层**：将文本表示为词向量矩阵（如 Word2Vec、GloVe 或随机初始化）。
- 卷积层**：使用多个卷积核（filters）在文本矩阵上滑动，提取局部特征。每个卷积核可以捕捉不同的 n-gram 特征（如 2-gram、3-gram）。
- 池化层**：对卷积层的输出进行池化（如最大池化），保留最重要的特征，同时降低维度。
- 全连接层**：将池化层的输出拼接起来，通过全连接层进行分类或回归。

1.2 特点

- 局部特征提取**：CNN 擅长捕捉局部特征（如 n-gram），适合处理文本中的短语或模式。
- 参数共享**：卷积核在文本上滑动时共享参数，减少了模型复杂度。
- 并行计算**：卷积操作可以高效并行化，训练速度快。
- 对位置敏感**：CNN 对词语的位置较为敏感，适合处理短文本或局部依赖较强的任务。

1.3 在文本挖掘中的应用

- 文本分类**：如情感分析、垃圾邮件检测。
- 短文本匹配**：如问答系统、句子相似度计算。
- 关键词提取**：通过卷积核捕捉重要短语。

2. LSTM（长短期记忆网络）

2.1 模型结构

LSTM 是 RNN（循环神经网络）的改进版本，专门设计用于解决长序列依赖问题。其核心结构包括：

- 输入门**：控制当前输入信息的权重。
- 遗忘门**：控制前一时刻记忆的遗忘程度。
- 输出门**：控制当前记忆的输出。
- 记忆单元**：存储长期依赖信息。

LSTM 通过这三个门机制，能够有效捕捉长距离依赖关系。

2.2 特点

- 长距离依赖**：LSTM 能够捕捉文本中的长距离依赖关系，适合处理长文本。
- 序列建模**：LSTM 是序列模型，能够处理变长输入，适合处理时间序列或文本序列。
- 计算复杂度高**：由于是循环结构，LSTM 的训练速度较慢，难以并行化。
- 对顺序敏感**：LSTM 对词语的顺序非常敏感，适合处理上下文依赖强的任务。

2.3 在文本挖掘中的应用

- 文本生成**：如机器翻译、对话生成。
- 序列标注**：如命名实体识别、词性标注。
- 情感分析**：捕捉长文本中的情感变化。

3. Transformer

3.1 模型结构

Transformer 是一种基于自注意力机制（Self-Attention）的模型，完全摒弃了循环和卷积结构。其核心结构包括：

- 输入嵌入层**：将文本转换为词向量。
- 位置编码**：为词向量添加位置信息，弥补 Transformer 对顺序不敏感的缺陷。
- 多头自注意力机制**：通过多个注意力头捕捉文本中不同位置的依赖关系。
- 前馈神经网络**：对注意力机制的输出进行非线性变换。
- 残差连接和层归一化**：加速训练并提高模型稳定性。

3.2 特点

- 全局依赖**：自注意力机制能够捕捉文本中的全局依赖关系，不受距离限制。
- 并行计算**：Transformer 完全基于矩阵运算，可以高效并行化，训练速度快。
- 可扩展性强**：通过堆叠多层 Transformer 模块，可以构建强大的模型（如 BERT、GPT）。
- 对顺序不敏感**：虽然位置编码引入了顺序信息，但 Transformer 对词语顺序的敏感性不如 RNN。

3.3 在文本挖掘中的应用

- 预训练语言模型**：如 BERT、GPT，用于各种下游任务。
- 机器翻译**：Transformer 是当前机器翻译的主流模型。
- 文本摘要**：生成高质量的文本摘要。
- 问答系统**：通过捕捉全局依赖关系，提高问答准确性。

4. 三者的对比

特性	CNN	LSTM	Transformer
依赖关系	局部依赖	长距离依赖	全局依赖
并行化	高度并行	难以并行	高度并行
计算效率	高	低	高
顺序敏感性	对位置敏感	对顺序敏感	对顺序不敏感（需位置编码）
典型应用	文本分类、短文本匹配	文本生成、序列标注	预训练模型、机器翻译

5. 总结

- CNN**：适合捕捉局部特征，适合短文本或局部依赖任务。
- LSTM**：适合捕捉长距离依赖，适合长文本或序列任务。
- Transformer**：适合捕捉全局依赖，适合大规模预训练和复杂任务。

在实际应用中，可以根据任务需求选择合适的模型，或者结合多种模型的优点（如 CNN + LSTM 或 Transformer + CNN）构建更强大的模型。