

## 一.名词解释 (30 分):

### 1.Transformers 架构

Transformer 架构是一种基于自注意力机制的深度学习模型，最初在 2017 年提出，用于处理序列到序列的任务，如机器翻译。其核心结构包括编码器和解码器，通过多头注意力机制实现高效的并行计算和长距离依赖建模。

架构是指系统或实体在其环境中的基本概念或属性，以及实现和演变这些实体及其相关生命周期过程的原则。它广泛应用于企业、组织、解决方案、系统等领域，用于描述和管理复杂系统的结构、功能和组件之间的关系。架构可以分为静态架构、动态架构、参数化架构、移动架构和自我组织架构等类型，反映了技术从固定硬件配置向灵活可扩展系统设计的发展趋势。

此外，架构还涉及数据架构、应用架构和技术架构等多个层次，是企业信息化和 IT 规划的核心

### 2.文本分类

文本分类是自然语言处理 (NLP) 领域的一项重要任务，旨在将文本数据自动归类到预定义类别中。其核心目标是通过机器学习和深度学习方法，从大量已标注的文本数据中学习特征，并对新文本进行分类。常见的应用场景包括垃圾邮件过滤、情感分析、新闻分类等。

文本分类的基本流程包括文本预处理、特征提取、模型训练和评估。常用的特征提取方法有词袋模型、TF-IDF 和词嵌入技术，而模型则包括朴素贝叶斯、支持向量机、随机森林和深度学习模型。

随着技术的发展，文本分类逐渐从基于规则的方法转向基于统计和机器学习的方法，使得分类更加准确和高效。未来，文本分类将继续面临特征表示、高维数据处理和语义理解等挑战。

### 3、微调

微调 (Fine-tuning) 是指在预训练模型的基础上，针对特定任务或数据领域，对部分或全部模型参数进行进一步的训练和调整，以提高模型在该任务上的性能。常见的微调方法包括全量微调、提示微调 (Prompt Tuning)、适配器微调 (Adapter Tuning) 和前缀微调 (Prefix Tuning) 等

### 4. NER 识别

命名实体识别 (NER) 是自然语言处理 (NLP) 中的关键任务，旨在从文本中识别并分类具有特定意义的实体，如人名、地名、组织名等。NER 技术包括基于规则、机器学习和深度学习的方法，近年来深度学习方法 (如 RNN、LSTM、CRF、Transformer 和 BERT) 在 NER 中取得了显著进展。NER 在信息提取、问答系统、机器翻译等领域有广泛应用，并面临跨语言准确性、实体嵌套和歧义等挑战。

### 5.预训练模型

预训练模型是一种通过在大规模数据集上预先训练深度学习模型，以提升其在下游任务中的性能的技术。例如，BERT 模型通过双向 Transformer 架构预训练深度语言表示，显著提高了自然语言处理任务的性能。此外，预训练技术不仅应用于自然语言处理，还广泛用于计算机视觉、时间序列分析等领域。

## 二.简答题 (20\*2 分)

### 1. 大模型在上下文识别中有哪些作用? (深度模型在文本挖掘应用的优势)

1. **提升理解能力**: 大模型通过上下文学习显著提高了对复杂语言结构的理解能力, 尤其是在处理否定词、医疗报告等复杂文本时, 能够纠正错误并提高解释准确性。
2. **增强识别性能**: 在语音识别中, 上下文信息的建模能力可以显著降低词错误率, 例如, 结合注意力机制的 TDNN-LSTM 模型通过融合粗细粒度特征提高了上下文信息建模能力。
3. **优化多模态任务**: 在视频行为识别中, 上下文信息的利用有助于提高识别正确率和模型稀疏性, 例如, HCRF 模型通过上下文信息建模提高了大范围视频中人的行为识别性能。
4. **辅助迁移学习**: 在开放域行为识别中, 大模型通过上下文辅助的方法将预训练知识迁移到新任务中, 提高了分类的鲁棒性。
5. **改善文本生成**: 在文本生成任务中, 大模型结合输入的上下文信息生成连贯、流畅的内容, 例如, 在智能写作系统中, 大模型通过理解上下文信息生成自然语言。
6. **提升推荐系统精度**: 在推荐系统中, 融合上下文信息的神经协同过滤模型能够提高推荐精度, 帮助用户快速发现感兴趣的内容

## 2. RNN 在自然语言处理中有什么局限性?对此, LTSM 如何改善?

RNN 在自然语言处理中的局限性主要包括梯度消失和梯度爆炸问题, 这使得它难以处理长序列数据中的长期依赖关系。此外, RNN 的训练效率较低, 因为其序列性特点导致难以并行计算。

为了解决这些问题, LSTM (长短期记忆网络) 通过引入门控机制 (如输入门、遗忘门和输出门) 来调节信息流动, 从而有效解决了梯度消失和爆炸问题。LSTM 能够捕捉长期依赖关系, 并且在处理长序列数据时表现出色。然而, LSTM 在计算复杂度和训练时间上仍有一定限制。

## 三. 论述利用文本挖掘如何实现社交舆情监控?说明涉及到的主要技术和可能的挑战。(40')

文本挖掘广泛应用于多个领域, 包括但不限于:

- **新闻分类与聚类**: 对新闻故事或网页进行分类和聚类, 以便更好地管理和检索。
- **垃圾邮件检测**: 通过分析邮件内容, 识别并过滤垃圾邮件。
- **社交媒体分析**: 从社交媒体帖子中提取有价值的信息, 用于市场分析和用户行为研究。
- **情感分析**: 分析用户对产品、服务等态度, 帮助企业改进产品和服务。

文本挖掘可以通过以下方式实现社交舆情监控:

1. **数据采集与预处理**: 利用网络爬虫技术获取社交媒体平台上的文本数据, 通过分词、去重、去除停用词等预处理步骤, 提取关键词和特征词。
2. **情感分析**: 运用自然语言处理技术, 如基于深度学习的情感分析模型 (例如 Word2Vec 和循环神经网络), 对文本的情感倾向进行分类, 从而判断公众情绪的正负面。
3. **话题检测与追踪**: 通过聚类算法 (如 K-means) 或基于概率模型的方法, 识别和追踪热点话题及其演化趋势, 帮助及时发现舆情事件。
4. **意见领袖识别**: 结合用户的行为特征、结构特征和情感特征, 通过算法 (如 MFP 算法) 挖掘具有高影响力的“意见领袖”, 以分析其在舆情传播中的作用。
5. **敏感信息监控**: 利用动态遗传算法优化敏感信息过滤模板, 提高对潜在威胁信息的检测效率。
6. **舆情预警与引导**: 通过构建舆情预警系统, 实时监测并分析舆情动态, 为政府或企业提供决策支持。

主要技术:

1. **信息采集与预处理:** 通过网络爬虫或 API 接口获取社交媒体数据, 进行数据清洗和去噪处理, 确保数据的准确性和可用性。
2. **文本表示与特征提取:** 使用词袋模型、TF-IDF、词向量等方法对文本进行表示, 提取关键特征。
3. **情感分析:** 通过情感分类算法 (如 SVM、深度学习模型) 分析文本的情感倾向, 识别正面、负面或中性情感。
4. **主题发现与聚类:** 应用 LDA、UR-LDA 等主题模型, 从海量文本中提取核心主题, 并进行聚类分析。
5. **意见领袖与社群分析:** 通过社交网络分析方法识别意见领袖和社群结构, 理解舆情传播路径。
6. **实时监测与预警:** 结合时空特性, 动态监测舆情变化, 构建预警模型以及及时响应突发事件。

**可能的挑战:**

1. **数据规模与多样性:** 社交媒体数据量庞大且形式多样, 如何高效处理和分析这些数据是一个重大挑战。
2. **语义稀疏性:** 短文本的语义信息较为稀疏, 难以准确捕捉用户的真实意图和情感。
3. **实时性与动态性:** 舆情传播速度快, 需要实时监测和快速响应, 这对系统的实时处理能力提出了高要求。
4. **多模态数据融合:** 社交媒体中包含文本、图像、视频等多种数据类型, 如何有效融合这些异构数据进行综合分析是一个难题。
5. **伦理与隐私问题:** 大规模数据采集和分析可能涉及用户隐私问题, 需要在技术应用中严格遵守相关法律法规。

文本挖掘技术在网络舆情监控中发挥了重要作用, 但同时也面临诸多技术和伦理挑战, 需要持续优化和改进。