



运筹学

许伟 教授/博导
中国人民大学信息学院



本章内容要点

- 基本概念
- 一维搜索
- 无约束极值问题
- 约束极值问题



6.1 基本概念

一、非线性规划的数学模型

非线性规划数学模型的一般形式是

$$\begin{cases} \min f(X) \\ h_i(X) = 0 \quad i = 1, 2, \dots, m \\ g_j(X) \geq 0 \quad j = 1, 2, \dots, l \end{cases} \quad (6.1)$$

其中, $X = (x_1, x_2, \dots, x_n)^T$ 是 n 维欧氏空间 E_n 中的点(向量), 目标函数 $f(X)$ 和约束函数 $h_i(X)$ 、 $g_j(X)$ 为 X 的实函数。

有时, 也将非线性规划的数学模型写成

$$\begin{cases} \min f(X) \\ g_j(X) \geq 0 \quad j = 1, 2, \dots, l \end{cases} \quad (6.2)$$



6.1 基本概念

模型(6.2)也常表示成另一种形式:

$$\begin{cases} \min f(X), X \in R \subset E_n \\ R = \{X | g_j(X) \geq 0, j = 1, 2, \dots, l\} \end{cases} \quad (6.3)$$

上式中 R 为问题的可行域。

若某个约束条件是“ $\leq$ ”不等式,只需用“ -1 ”乘这个约束的两端,即可将其变成“ $\geq$ ”的形式。此外,由于 $\max f(X) = -\min[-f(X)]$,且这两种情况下求出的最优解相同(如有最优解),故当需使目标函数极大化时,只需求其负函数极小化即可。



6.1 基本概念

六、凸规划

现考虑非线性规划(6.2),若其中的 $f(X)$ 为凸函数, $g_j(X)$ ($j=1,2,\dots,l$) 全是凹函数 (即所有 $-g_j(X)$ 全为凸函数),就称这种规划为凸规划。

凸规划具有下述希望的很好的性质:

- (1) 可行解集为凸集。
- (2) 最优解集为凸集(假定最优解存在)。
- (3) 任何局部最优解也是其全局最优解。
- (4) 若目标函数为严格凸函数,且最优解存在,则其最优解必唯一。



6.1 基本概念

七、下降迭代算法

由前面所述,对于可微函数来说,为了求最优解,可令其梯度等于零,由此求得稳定点。然后再用充分条件进行判别,以求出最优解。表面看来,问题似乎已经解决。但是,对一般 n 元函数 $f(X)$ 来说,由条件 $\nabla f(X)=0$ 得到的常常是一个非线性方程组,求解它相当困难。此外,很多实际问题往往很难求出或根本求不出目标函数对各自变量的偏导数,从而使一阶必要条件(6.5)难以应用。因此,除了极个别的情形之外,一般并非从式(6.5)出发,而是采用所谓的迭代法。



6.1 基本概念

迭代法的基本思想是：我们并不期望一下子就能找到函数的最优点，而是从最优点的某一个初始估计 $X^{(0)}$ 出发，按照一定的规则（即所谓算法），先找一个比 $X^{(0)}$ 更好的点 $X^{(1)}$ （对极小化问题来说， $f(X^{(1)})$ 比 $f(X^{(0)})$ 更小；对极大化问题来说， $f(X^{(1)})$ 比 $f(X^{(0)})$ 更大），再找比 $X^{(1)}$ 更好的点 $X^{(2)}$ ，…，如此继续，就产生了一个解点的序列 $\{X^{(k)}\}$ 。若该点列有一极限点 X^* ，即

$$\lim_{k \rightarrow \infty} \|X^{(k)} - X^*\| = 0 \quad (6.18)$$

就称该点列收敛于 X^* 。对于某一算法来说，我们要求它产生的点列 $\{X^{(k)}\}$ 中的某一点本身就是最优点，或者该点列的极限点 X^* 是问题的最优点。

对于极小化问题，我们要求由选取的某一算法所产生的解的序列 $\{X^{(k)}\}$ ，其对应的目标函数值 $f(X^{(k)})$ 应是逐步减小的，即要求

$$f(X^{(0)}) > f(X^{(1)}) > \dots > f(X^{(k)}) > \dots$$

具有这种性质的算法称为下降迭代算法。



6.1 基本概念

下降迭代算法的一般迭代格式是：

(1) 选取某一初始点 $X^{(0)}$ ，令 $k := 0$ ($:=$ 为赋值号， $k := 0$ 表示将 0 赋给变量 k)。

(2) 确定搜索方向。若已得出某一迭代点 $X^{(k)}$ ，且 $X^{(k)}$ 不是极小点。这时，就从 $X^{(k)}$ 出发确定一搜索方向 $P^{(k)}$ ，沿这个方向应能找到使目标函数值下降的点。对约束极值问题，有时(视所用的算法而定)还要求这样的点是可行点。

(3) 确定步长。沿 $P^{(k)}$ 方向前进一个步长，得新点 $X^{(k+1)}$ 。即在由 $X^{(k)}$ 出发的射线

$$X = X^{(k)} + \lambda P^{(k)} \quad \lambda \geq 0$$

上，通过选定步长(因子) $\lambda = \lambda_k$ ，得下一个迭代点

$$X^{(k+1)} = X^{(k)} + \lambda_k P^{(k)}$$

使得

$$f(X^{(k+1)}) = f(X^{(k)} + \lambda_k P^{(k)}) < f(X^{(k)})$$

(4) 检验新得到的点是否为要求的极小点或近似极小点，如满足要求，迭代停止。否则，令 $k := k+1$ ，返回第(2)步继续迭代。

在以上步骤中，选定搜索方向对算法起着关键性的作用，各种算法的区分，主要在于确定搜索方向的方法不同。



6.1 基本概念

在许多算法中,步长的选定是由使目标函数值沿搜索方向下降最多(在极小化问题中)为依据的,即沿射线 $X^{(k)} + \lambda P^{(k)}$ 求 $f(X)$ 的极小,即选取 λ_k ,使

$$f(X^{(k)} + \lambda_k P^{(k)}) = \min_{\lambda} f(X^{(k)} + \lambda P^{(k)}) \quad (6.19)$$

由于这一工作是求以 λ 为变量的一元函数 $f(X^{(k)} + \lambda P^{(k)})$ 的极小点 λ_k ,故称这一过程为(最优)一维搜索或线搜索,由此确定的步长称为最佳步长。

上述一维搜索有个重要的性质,就是在搜索方向上所得最优点处的梯度和该搜索方向正交。这可表述成如下定理:

定理3 设目标函数 $f(X)$ 具有连续一阶偏导数, $X^{(k+1)}$ 按下述规则产生

$$\begin{cases} f(X^{(k)} + \lambda_k P^{(k)}) = \min_{\lambda} f(X^{(k)} + \lambda P^{(k)}) \\ X^{(k+1)} = X^{(k)} + \lambda_k P^{(k)} \end{cases}$$

则有

$$\nabla f(X^{(k+1)})^T P^{(k)} = 0 \quad (6.20)$$

由于函数 $f(X)$ 在某点的梯度和过该点的等值面的切线正交, 从而一维(最优)搜索的方向和其上最优点处函数的等值面相切(图 6-5)。

因真正的极值点 X^* 事先并不知道, 故在实用上只能根据相继两次迭代得到的计算结果来判断是否已达到要求, 从而建立终止迭代计算的准则。常用的终止迭代准则有以下几种:

(1) 根据相继两次迭代结果的绝对误差:

$$\|X^{(k+1)} - X^{(k)}\| \leq \epsilon_1$$

$$|f(X^{(k+1)}) - f(X^{(k)})| \leq \epsilon_2$$

(2) 根据相继两次迭代结果的相对误差:

$$\frac{\|X^{(k+1)} - X^{(k)}\|}{\|X^{(k)}\|} \leq \epsilon_3 \quad (6.21)$$

$$\frac{|f(X^{(k+1)}) - f(X^{(k)})|}{|f(X^{(k)})|} \leq \epsilon_4 \quad (6.22)$$

式(6.21)和(6.22)中的分母要求不等于和不接近于零。

(3) 根据函数梯度的模足够小:

$$\|\nabla f(X^{(k)})\| \leq \epsilon_5$$

以上各式中的 $\epsilon_1, \epsilon_2, \epsilon_3, \epsilon_4$ 和 ϵ_5 为足够小的正数。




图 6-5



6.2 一维搜索

一维搜索的方法很多,这里仅介绍斐波那契(Fibonacci)法和 0.618 法。这两种方法属直接法,仅需计算函数值,不必计算函数的导数。

一、斐波那契法(分数法)

设 $y=f(t)$ 是区间 $[a,b]$ 上的单变量下单峰函数,它在该区间上有唯一极小点 t^* ,而且函数在 t^* 之左严格下降,在 t^* 之右严格上升。若在此区间之内任取两点 a_1 和 b_1 ,且 $a_1 < b_1$,并计算函数值 $f(a_1)$ 和 $f(b_1)$,则可能有以下两种情况:

(1) $f(a_1) < f(b_1)$: 这时极小点 t^* 必在区间 $[a, b_1]$ 内(图 6-6(a))。

(2) $f(a_1) \geq f(b_1)$: 这时极小点 t^* 必在区间 $[a_1, b]$ 内(图 6-6(b))。



6.2 一维搜索

这说明,只要在搜索区间 $[a, b]$ 内取两个不同点,并算出它们的函数值加以比较,即可把包含极小点的区间由 $[a, b]$ 缩小为 $[a, b_1]$ 或 $[a_1, b]$ 。这时,如要继续缩小搜索区间 $[a, b_1]$ 或 $[a_1, b]$,就只需在新的区间内再取一点算出其函数值,与 $f(a_1)$ 或 $f(b_1)$ 加以比较即可。只要按上述方法使缩小后的区间始终包含极小点 t^* ,则区间缩得越小,就越接近于函数的极小点;当然,区间缩得越小,要计算函数值的次数也就越多。这表明,区间的缩短率和函数值的计算次数有关。现在要问,计算 n 次函数值能把区间(包含极小点)缩小到什么程度?或者说,计算函数值 n 次能把至多多大的原区间缩小为长度为1个单位的区间呢?



6.2 一维搜索

现用 F_n 表示计算 n 次函数值能将其缩短为 10 个单位长度区间的最大原区间长度, 则显然有

$$F_0 = F_1 = 1 \quad (6.23)$$

其原因是, 只有当原区间长度本来就等于一个单位区间长度时才不必计算函数值; 此外, 只计算一次函数值无法将区间缩短, 只有原区间长度本来就是一个单位区间长度时才行。



6.2 一维搜索

现考虑 F_2 。在区间 $[a, b]$ 内设想取两个不同点 a_1 和 b_1 , 并计算它们的函数值以缩短区间, 缩短后的区间为 $[a, b_1]$ 或 $[a_1, b]$ 。由于 a_1 和 b_1 是不同的二个点, 因而 $[a, b_1]$ 和 $[a_1, b]$ 这两个区间长度之和必大于 $[a, b]$ 的长度。这说明计算两次函数值一般无法把长度大于 2 个单位长度的区间缩成单位区间。但是, 可以把计算函数值的点 (今后称为试点) 选得尽量靠近区间 $[a, b]$ 的中点, 对于长度等于 2 个单位长度的区间, 缩短后的区间长度等于单位长度的 $(1+\epsilon)$ 倍 (ϵ 为任意小的正数), 从而使缩短后的区间长度接近于 1 个单位长度, 由此得到 $F_2=2$ (图 6-7)。




图 6-7



6.2 一维搜索

用上述的类似分析方法可得

$$F_3 = 3, \quad F_4 = 5, \quad F_5 = 8, \dots$$

在图 6-8 中示出了 $n=3, 4, 5$ 这三种情况, 图中小圆圈中的数字表示选取这个试点的先后顺序, 分数为该点在整个区间的相对位置。




图 6-8



6.2 一维搜索

序列 $\{F_n\}$ 服从于一个一般递推公式:

$$F_n = F_{n-1} + F_{n-2}, \quad n \geq 2 \quad (6.24)$$

使用式(6.24)可依次计算出各 F_n 的值(表 6-1)。

表 6-1

n	0	1	2	3	4	5	6	7	8	9	10	11	12
F_n	1	1	2	3	5	8	13	21	34	55	89	144	233



6.3 无约束极值问题

无约束极值问题可表述为

$$\min f(X), \quad X \in E_n \quad (6.32)$$

前面曾指出,在求解上述问题时常使用迭代法。迭代法可大体分为两大类:一类要用到函数的一阶导数和(或)二阶导数,由于用到了函数的解析性质,故称为解析法;另一类在迭代过程中仅用到函数值,而不要求函数的解析性质,这类方法称为直接法。一般说来,直接法的收敛速度较慢,只是在变量较少时才适用。但直接法的迭代步骤简单,特别是当目标函数的解析表达式十分复杂,甚至写不出具体表达式时,它们的导数很难求得,或根本不存在,这时,就只有用直接法了。下面介绍两种基本的解析法。



6.3 无约束极值问题

一、梯度法(最速下降法)

梯度法是一种古老的方法,但由于它的迭代过程简单,使用方便,而且又是理解其他非线性最优化方法的基础,所以先来说明这一方法。

假定问题(6.32)中的目标函数 $f(X)$ 具有一阶连续偏导数,它存在极小点 X^* 。以 $X^{(k)}$ 表示极小点的第 k 次近似,为了求其第 $k+1$ 次近似 $X^{(k+1)}$,在 $X^{(k)}$ 点沿方向 $P^{(k)}$ 作射线

$$X = X^{(k)} + \lambda P^{(k)} \quad \lambda \geq 0 \quad (6.33)$$

将 $f(X)$ 在 $X^{(k)}$ 处作泰勒展开,得

$$f(X) = f(X^{(k)} + \lambda P^{(k)}) = f(X^{(k)}) + \lambda \nabla f(X^{(k)})^T P^{(k)} + o(\lambda)$$

其中 $\nabla f(X^{(k)})$ 为函数 $f(X)$ 在 $X^{(k)}$ 点的梯度,可以假定 $\nabla f(X^{(k)}) \neq 0$, (否则 $X^{(k)}$ 已是平稳点)。对于充分小的 λ , $o(\lambda)$ 是 λ 的高阶无穷小。这时,只要

$$\nabla f(X^{(k)})^T P^{(k)} < 0 \quad (6.34)$$



6.3 无约束极值问题

即可保证 $f(X^{(k)} + \lambda P^{(k)}) < f(X^{(k)})$ 。在这种情况下,若取下一个迭代点为 $X^{(k+1)} = X^{(k)} + \lambda P^{(k)}$,就能使目标函数值得到改善。下面设法寻求使(6.34)左端取最小值的 $P^{(k)}$ 。由线性代数学知

$$\nabla f(X^{(k)})^T P^{(k)} = \|\nabla f(X^{(k)})\| \cdot \|P^{(k)}\| \cos\theta \quad (6.35)$$

其中 θ 为向量 $\nabla f(X^{(k)})$ 与 $P^{(k)}$ 的夹角。

我们不妨设 $P^{(k)}$ 的模一定。当 $P^{(k)}$ 与 $\nabla f(X^{(k)})$ 同向,即取 $P^{(k)}$ 为梯度方向时, $\theta = 0$, $\cos\theta = 1$, $\nabla f(X^{(k)})^T P^{(k)}$ 最大;当 $P^{(k)}$ 与 $\nabla f(X^{(k)})$ 反向时, $\theta = 180^\circ$, $\cos\theta = -1$, $\nabla f(X^{(k)})^T P^{(k)} < 0$, 且其值最小,这一方向为负梯度方向。前曾指出,负梯度方向是函数值下降最快的方向(通常指在 $X^{(k)}$ 的某一小范围内),沿这一方向搜索,有可能较快地达到极小点,梯度法就采用这样的方向为搜索方向。



6.3 无约束极值问题

为了得到下一个近似极小点,在选定了搜索方向之后,还要确定步长。选取步长的一种方法是通过试算,即先取 λ 为某一个数,检验下式是否满足:

$$f(X^{(k)} - \lambda \nabla f(X^{(k)})) < f(X^{(k)}) \quad (6.36)$$

若满足,就可以取这个 λ 值进行迭代;若不满足,就减小 λ 使满足上式。由于采用负梯度方向为搜索方向,满足式(6.36)的 λ 总是存在的。

另一种方法是

$$\lambda_k; \min_{\lambda \geq 0} f(X^{(k)} - \lambda \nabla f(X^{(k)})) \quad (6.37)$$

这可通过在负梯度方向的一维搜索(例如用 0.618 法),来确定使 $f(X)$ 最小的 λ_k 。我们称这样得到的步长为最佳步长,有时称采用最佳步长时的梯度法为最速下降法。

现将用梯度法求函数 $f(X)$ 的极小点的步骤总结如下:

(1) 给定初始点 $X^{(0)}$ 和允许误差 $\epsilon > 0$, 令 $k := 0$ 。

(2) 计算 $f(X^{(k)})$ 和 $\nabla f(X^{(k)})$, 若 $\|\nabla f(X^{(k)})\|^2 \leq \epsilon$, 停止迭代, 得近似极小点 $X^{(k)}$ 和近似极小值 $f(X^{(k)})$; 否则, 转下一步。

(3) 做一维搜索(也可直接使用下面给出的公式(6.38)或(6.40)):

$$\lambda_k; \min_{\lambda} f(X^{(k)} - \lambda \nabla f(X^{(k)}))$$

并计算 $X^{(k+1)} = X^{(k)} - \lambda_k \nabla f(X^{(k)})$, 然后令 $k := k+1$, 转回第(2)步。

现设 $f(X)$ 具有二阶连续偏导数, 将 $f(X^{(k)} - \lambda \nabla f(X^{(k)}))$ 在 $X^{(k)}$ 作泰勒展开:

$$\begin{aligned} f(X^{(k)} - \lambda \nabla f(X^{(k)})) &\approx f(X^{(k)}) - \nabla f(X^{(k)})^T \lambda \nabla f(X^{(k)}) \\ &\quad + \frac{1}{2} \lambda \nabla f(X^{(k)})^T \nabla^2 f(X^{(k)}) \lambda \nabla f(X^{(k)}) \end{aligned}$$

使上式对 λ 求导, 并令其等于零, 即可得近似最佳步长的如下计算公式:

$$\lambda_k = \frac{\nabla f(X^{(k)})^T \nabla f(X^{(k)})}{\nabla f(X^{(k)})^T \nabla^2 f(X^{(k)}) \nabla f(X^{(k)})} \quad (6.38)$$

有时, 把搜索方向 $P^{(k)}$ 的模规格化为 1, 即取

$$P^{(k)} = - \frac{\nabla f(X^{(k)})}{\|\nabla f(X^{(k)})\|} \quad (6.39)$$

在这种情况下, 式(6.38)就变为

$$\lambda_k = \frac{\nabla f(X^{(k)})^T \nabla f(X^{(k)}) \|\nabla f(X^{(k)})\|}{\nabla f(X^{(k)})^T \nabla^2 f(X^{(k)}) \nabla f(X^{(k)})} \quad (6.40)$$

例 7 用梯度法求下述函数的极小点:

$$f(X) = (x_1 - 2)^2 + (x_2 - 1)^2$$

解 取初始点 $X^{(0)} = (0, 0)^T$

$$\nabla f(X) = [2(x_1 - 2), 2(x_2 - 1)]^T$$

$$\nabla f(X^{(0)}) = (-4, -2)^T$$

$$\nabla^2 f(X) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\lambda_0 = \frac{\nabla f(X^{(0)})^T \nabla f(X^{(0)})}{\nabla f(X^{(0)})^T \nabla^2 f(X^{(0)}) \nabla f(X^{(0)})}$$

$$= \frac{(-4, -2) \begin{pmatrix} -4 \\ -2 \end{pmatrix}}{(-4, -2) \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} -4 \\ -2 \end{pmatrix}} = \frac{1}{2}$$

$$X^{(1)} = X^{(0)} - \lambda_0 \nabla f(X^{(0)})$$

$$= \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} -4 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

$\nabla f(X^{(1)}) = (0, 0)^T$, 故 $X^{(1)}$ 为极小点。其极小值 $f(X^{(1)}) = 0$ 。



6.4 约束极值问题

一、最优性条件

1. 可行下降方向

(1) 起作用约束

假定 $X^{(0)}$ 是问题 (6.3) 的一个可行解, 它满足所有约束条件。对某一个约束条件 $g_j(X) \geq 0$ 来说, $X^{(0)}$ 满足它有两种情况: 一为 $g_j(X^{(0)}) > 0$, 这时, $X^{(0)}$ 不在由这个约束条件形成的可行域边界上, 我们称这一约束为 $X^{(0)}$ 点的不起作用约束(或无效约束); 另一种情况是 $g_j(X^{(0)}) = 0$, 这时, $X^{(0)}$ 点处于由这个约束条件形成的可行域边界上, 对 $X^{(0)}$ 点的进一步摄动来说, 这一约束起到了某种限制作用, 故称它为 $X^{(0)}$ 点的起作用约束(或有效约束)。显然, 等式约束条件对所有可行点都是起作用约束。

(2) 可行方向

设 $X^{(0)}$ 为任一可行点, 对某一方向 P 来说, 若存在实数 $\lambda_0 > 0$, 使对任意的 $\lambda \in [0, \lambda_0]$ 均有下式成立:

$$X^{(0)} + \lambda P \in R$$

就称方向 P 为 $X^{(0)}$ 点的一个可行方向。

以 J 记 $X^{(0)}$ 点所有起作用约束下标的集合, 即

$$J = \{j | g_j(X^{(0)}) = 0, \quad 1 \leq j \leq l\}$$

显然, 如果 P 为 $X^{(0)}$ 点的可行方向, 则存在 $\lambda_0 > 0$, 使对任意 $\lambda \in [0, \lambda_0]$, 有

$$g_j(X^{(0)} + \lambda P) \geq g_j(X^{(0)}) = 0 \quad j \in J$$

从而

$$\left. \frac{dg_j(X^{(0)} + \lambda P)}{d\lambda} \right|_{\lambda=0} = \nabla g_j(X^{(0)})^T P \geq 0 \quad j \in J$$

式中 $\nabla g_j(X^{(0)})$ 为约束函数 $g_j(X)$ 在 $X^{(0)}$ 点的梯度。

另一方面, 由泰勒公式,

$$g_j(X^{(0)} + \lambda P) = g_j(X^{(0)}) + \lambda \nabla g_j(X^{(0)})^T P + o(\lambda)$$

对 $X^{(0)}$ 点的所有起作用约束, 当 $\lambda > 0$ 足够小时, 只要

$$\nabla g_j(X^{(0)})^T P > 0 \quad j \in J \quad (6.46)$$

就有

$$g_j(X^{(0)} + \lambda P) \geq 0 \quad j \in J$$

此外, 对 $X^{(0)}$ 点的所有不起作用约束, $g_j(X^{(0)}) > 0$, 由 $g_j(X)$ 的连续性, 当 $\lambda > 0$ 足够小时, 亦有

$$g_j(X^{(0)} + \lambda P) \geq 0 \quad j \notin J$$

从而, 只要方向 P 满足式(6.46), 即可保证它为 $X^{(0)}$ 点的可行方向。



6.4 约束极值问题

(3) 下降方向

设 $X^{(0)} \in R$, 对某一方向 P 来说, 若存在实数 $\lambda_0 > 0$, 使对任意的 $\lambda \in [0, \lambda_0]$ 均有下式成立:

$$f(X^{(0)} + \lambda P) < f(X^{(0)})$$

就称方向 P 为 $X^{(0)}$ 点的一个下降方向。

由泰勒展开式:

$$f(X^{(0)} + \lambda P) = f(X^{(0)}) + \lambda \nabla f(X^{(0)})^T P + o(\lambda)$$

当 λ 足够小时, 只要

$$\nabla f(X^{(0)})^T P < 0 \quad (6.47)$$

就有 $f(X^{(0)} + \lambda P) < f(X^{(0)})$ 。这说明, 只要方向 P 满足式(6.47), 即可保证它为 $X^{(0)}$ 点的下降方向。



6.4 约束极值问题

(4) 可行下降方向

若 $X^{(0)}$ 点的某一方向 P , 既是该点的可行方向, 又是该点的下降方向, 就称它为这个点的可行下降方向。设 $X^{(0)}$ 不是极小点, 为求其极小点, 继续搜索时应沿该点的可行下降方向进行。显然, 对某一点 X^* 来说, 若该点不存在可行下降方向, 它就可能是局部极小点; 若存在可行下降方向, 它当然就不是极小点。下面的定理 4 从另一角度说明了这一问题。



6.4 约束极值问题

定理 4 设 X^* 是问题(6.3)的一个局部极小点, $f(X)$ 在 X^* 处可微, 而且

$g_j(X)$ 在 X^* 处可微, 当 $j \in J$ 时

$g_j(X)$ 在 X^* 处连续, 当 $j \notin J$ 时

则在 X^* 点不存在可行下降方向, 从而不存在 P 同时满足:

$$\begin{cases} \nabla f(X^*)^T P < 0 \\ \nabla g_j(X^*)^T P > 0 \quad j \in J \end{cases} \quad (6.48)$$

其中, 指标集 $J = \{j | g_j(X^*) = 0, 1 \leq j \leq l\}$ 。

这个定理是显然的。若存在满足式(6.48)的方向 P , 则沿 P 搜索可找到比 X^* 更好的可行点, 这与 X^* 为局部极小点矛盾。

从几何上说, 满足式(6.48)的方向 P , 与该点目标函数负梯度方向的夹角成锐角, 而且, 与该点起作用约束梯度方向的夹角也成锐角。



6.4 约束极值问题

三、制约函数法

制约函数法是通过构造某种制约函数,并将它加到非线性规划的目标函数上,从而将原来的约束极值问题,转化为无约束极值问题来求解。由于这里介绍的方法需要求解一系列无约束问题,故称为序列无约束极小化技术,简记为 SUMT(sequential unconstrained minimization technique)。下面简要介绍其中最基本的两种:罚函数法(也称外点法)和障碍函数法(也称内点法)。



6.4 约束极值问题

对外点法可作如下经济解释：把目标函数 $f(X)$ 看成一种“价格”，约束条件看作某种“规定”，采购人可在规定范围内购置物品。对违反规定采取某种“罚款”政策；若符合规定，罚款为零；反之，征收罚款。此时，采购人付出的总代价应是价格和罚款的总和。采购者的目标是使总代价最小，这就是上述的无约束问题。当罚款规定得很苛刻时，违反规定支付的罚款很高，这就迫使采购人符合规定，在数学上表现为，当罚因子 M_i 足够大时，上述无约束问题的最优解应满足约束条件，而成为约束问题的最优解。



6.4 约束极值问题

障碍函数法(也称内点法)与罚函数法不同,它要求迭代过程始终在可行域内部进行。可以仿照罚函数法,通过函数叠加的办法来改造原来约束极值问题的目标函数,使改造后的目标函数具有这种性质:在可行域 R 的内部与边界面较远的地方,其值与原来的目标函数值尽可能相近;而在接近边界面时可以达到任意大的值。如果把初始迭代点取在可行域内部(不在可行域边界上,这样的点称为内点,也称严格内点),在进行无约束极小化时,这样的函数就会像屏障一样阻止迭代点到 R 的边界上去,而使迭代过程始终在可行域内部进行。经这样改造后的新目标函数,称为障碍函数。可以想见,满足这种要求的障碍函数,其极小解自然不会在 R 的边界上达到。这就是说,这时的极小化是在不包括可行域边界的可行开集上进行的,因而实际上是一种具有无约束性质的极值问题,可利用无约束极小化的方法进行计算。



谢谢大家