



分布与并行数据库

2 分布式数据库系统的结构

主讲教师：鄂金龙
中国人民大学信息学院







主要内容

- 物理结构和逻辑结构
- 体系结构
- 模式结构
- 组件结构
- 多数据库集成系统 (**MDBS**)
- **P2P**数据库系统 (**P2PDBS**)
- 分布式数据库系统分类
- 元数据的管理
- 分布式大数据数据库系统

物理结构和逻辑结构



DDBS的物理结构



DDBS的逻辑结构

体系结构

□ 系统的体系结构（**Architecture**）指按组件、组件功能以及它们的交互作用定义系统的结构。

□ 参考体系结构的目的

- 讨论的框架
- 标准


□ **DBMS 标准化**

- 基于功能
- 基于组件
- 基于数据
- 最早的是基于数据组织ANSI/SPARC **Architecture**（**external view, conceptual view, internal view**）的三级模式结构

American National Standards Institute, Standards Planning And Requirements Committee: 美国国家标准协会的计算机与信息处理委员会中的标准计划与需求委员会。

体系结构

□ 基于层次的DBMS系统结构



应用处理器(AP)

用于完成分布数据库处理的软件，如：处理访问多个场地的请求，查询全局字典中分布信息等。

数据处理器(DP)


负责进行数据管理的软件，类似于一个集中式数据库管理系统(DBMS)。

其中，AP：应用处理器 DP：数据处理器 CM：通信处理器

通信管理器(CM)负责为AP和DP在多个场地之间传送命令和数据。


体系结构

◆ 不同系统的系统结构图




a. 集中库

Timesharing Access to a Central Database




体系结构

不同系统的系统结构图




b. 多客户/单服务器(c/s)

Multiple Clients/Single Server




体系结构

□ 不同系统的系统结构图




b. 多客户/单服务器(c/s)

Task Distribution




体系结构

□ 不同系统的系统结构图



Multiple Clients/Multiple Servers


- directory
- caching
- query decomposition
- commit protocols



c. 多客户/多服务器 (mc/ms)

体系结构


不同系统的系统结构图



d. 服务器结构


Server-to-Server

- SQL interface
- programmatic interface
- other application support environments



体系结构

- 不同系统的体系结构图
- 负载均衡监测**:负责监控数据库服务器的状态及性能, 调度依据
- 数据处理**:负责处理从数据库返回的数据, 按一定的方式将数据传送给AP。
- 数据库管理器**:负责接收客户请求队列中的客户请求, 调用相应的驱动程序管理器, 完成相应的数据库查询任务。
- 驱动程序管理器**:负责调度相应的数据库驱动程序, 实现与相应的数据库的连接。




基于“中间件”的客户/服务器的体系结构¹¹

体系结构


■ 不同系统的系统结构图

Browse/Server



模式结构

□我国分布式数据库系统标准草案中给定的抽象为四层的模式结构：
全局外层、全局概念层、局部概念层和局部内层。模式与模式之间是映射关系。



模式结构

■ **全局外模式（GES）**：**全局外模式**即全局用户视图，是分布式数据库的全局用户对分布式数据库的最高层抽象。全局用户使用视图时，不必关心数据的分片和具体的物理分配细节。

■ **全局概念模式（GCS）**：**全局概念模式**即全局概念视图，是分布式数据库的整体抽象，包含了全部数据特性和逻辑结构。像集中式数据库中的概念模式一样，是对数据库全体的描述。全局概念模式再经过**分片模式**和**分配模式**映射到**局部模式**。

■ **分片模式**是描述全局数据的逻辑划分视图。即全局数据逻辑结构根据某种条件的划分为局部数据**逻辑结构**。每一个逻辑划分形成一个**分片**。在关系数据库中，一个关系中的一个子关系称该关系的一个片段。

■ **分配模式**是描述局部数据逻辑的局部**物理结构**，即划分后的分片的物理分配视图。

模式结构


■ **局部概念视图（LCS）**：局部概念模式为局部概念视图，是全局概念模式的子集，用于描述局部场地上的局部数据特征和逻辑结构。当全局数据模型与局部数据模型不同时，还涉及数据模型转换等内容。

■ **局部内模式**定义局部物理视图，是对物理数据库的描述，类似集中数据库的内层。

分布式数据库的四层结构及模式定义描述了分布式数据库是一组用网络联结的局部数据库的逻辑集合。它将数据库分为**全局数据库**和**局部数据库**。全局数据库到局部数据库由**1:N**的映射模式描述。全局数据库是**虚拟的**，由全局概念层描述。局部数据库是全局数据库的内层，由局部概念层和局部内层描述。**全局用户**只关心全局外层定义的数据库用户视图，其内部数据模型的转换、场地分配等由系统自动实现。



组件结构



组件结构

□ 应用处理器（AP）功能

- 用户接口：检查用户身份，接受用户命令，如：SQL命令。
- 语义数据控制器：视图管理、安全控制、语义完整性控制（全局概念模式）。这些约束定义在字典中。
- 全局查询处理器：将用户命令翻译成数据库命令；生成全局查询的分布执行计划；收集局部执行结果并返回给用户。
- 全局执行监控器（全局事务管理器）：调度协调和监视AP和DP之间的分布执行；保证复制数据的一致性；保证全局事务的原子性。


组件结构

□ 数据处理器DP功能

- **局部查询处理**：实现全局命令到局部命令的转换；访问路径选择器，选择最好的路径执行。
- **局部恢复管理器**：维护本地数据库一致性的故障恢复。
- **存储管理器**：按调度命令访问数据库；控制数据库缓存管理器；返回局部执行结果；保证子事务执行的正确性。
- **局部事务管理器**：以局部子事务为单位调度执行，保证子事务执行的正确性。
- **局部调度管理器**：负责局部场地上的并发控制，按可串行化调度和执行数据操作。



组件结构



多数据库集成系统（MDBS）


□ DDB 和 数据库集成系统

■ 通常，分布式数据库系统是自上而下（**top-down**）地设计数据库，可灵活地进行分片和分配设计。用户可得益于其“集中控制”和数据库系统具有的数据处理能力。但分布式数据库系统具有数据库组件数量的限制，通常不多于数十个数据库组件。

■ 数据集成系统通过约束数据管理能力（只支持只读），可将数据库组件数量扩展到数百个。在数据集成系统中，通常数据和数据库已存在，是遵循自下而上（**bottom-up**）地集成各局部场地上的数据。

多数据库集成系统 (MDBS)


□ 数据库集成的模式结构



多数据库集成系统 (MDBS)

□ 多数据库系统 (MDB)

■ MDBS 是在已经存在的数据库系统 (称为局部数据库系统 LDBs) 之上为用户提供一个统一的存取数据的环境。



多数据库系统逻辑结构

多数据库集成系统


□ DDB 和 MDB的不同

■ **MDB**: 本地数据管理器 (**data manager**) 都是完备的**DBMS**; 每个本地数据管理器都具有自己独立的**DDL**, **DML**和**TM**。

■ **DDB**: 只有一个数据管理器和依赖于该管理器的存在于各局部场地上的组件数据管理器 (**component-data-manager**)。


多数据库集成系统 (MDBS)

□ 具有全局概念模式的模型




多数据库集成系统 (MDBS)

□ 没有全局概念模式的模型



多数据库集成系统（MDBS）

□ 一种多数据库系统的实现结构



P2P数据库系统(P2PDBS)


□ 对等型模型，又称**P2P**模型，是一种新型的体系结构模型，面向大范围的多数据资源点的松散耦合。

□ 特点：

- 每个点均可贡献数据，系统资源具有丰富性、多样性；
- 可直接访问数据源中的数据资源，即时得到最新鲜的数据，不同于如数据仓库等集中的数据资源仓；
- 采用自组织原则，具有健壮性；
- 每个点可随时加入和退出，系统具有分散性、可扩展性；
- 以**Web**上的资源为**Peer**点，系统部署简单，不需要复杂的框架部署实现。


P2P数据库系统(P2PDBS)

□ P2PDBS的数据集成体系结构



P2P数据库系统(P2PDBS)

□ P2PDBS的体系结构




P2P数据库系统(P2PDBS)


□ P2PDBS与DDBS的典型区别

P2PDBS	DDBS
节点随时加入和离开	节点受控加入和退出
没有预定的全局模式	共享的模式
不能检索到满足查询的全部回答	检索到满足查询的全部回答
将查询转发到邻居，逐步定位内容	知道可回答查询的节点的位置
参加的主机数比存储的字节数更重要	扩展性主要指存储的字节数


P2P数据库系统(P2PDBS)



纯粹分布式P2P结构



集中目录式P2P结构



混合式P2P结构

分布式数据库系统分类

分布式数据库系统的分类方法很多。为全面、系统地对分布式数据库系统进行分类，采用分布式数据库的三个特性（**分布性**、**异构性**、**自治性**）组成的三维空间图来描述分布式数据库的类型。

□ 三个基本特性

■ **分布性**是指系统的各组成单元是否位于同一场地上。分布式数据库系统是物理上分散、逻辑上统一的系统，即具有分布性。而集中式数据库系统集中在一个场地上，所以不具有分布性。

分布式数据库系统分类

■ **异构性**是指系统的各组成单元是否相同，不同为异构，相同为同构。异构主要：

- ✓ **数据异构性**：指数据在格式上、语法和语义上存在不同。
- ✓ **数据系统异构性**：指各个场地上的局部数据库系统是否相同。如：均采用ORACLE数据库系统的同构数据系统，或某些场地采用SYBASE数据库系统，某些场地采用INFORMIX数据库系统的异构系统。
- ✓ **平台异构性**：指计算机系统是否相同。如：均为微机系统组成的平台同构系统或由VAX或ALPHA系统等异构平台组成的系统。

分布式数据库系统分类


■ **自治性**是指每个场地的独立自主能力。自治性通常由设计自治性、通讯自治性和执行自治性三方面来描述。根据系统的自治性，可分为**集中式系统**、**联邦式系统（Federated DB）**和**多数据库系统（Multi DB）**。

✓ **集中式系统**即为传统的数据库系统。

✓ **联邦式系统**：实现需要交互的所有数据库对之间的一对一连接。

✓ **多数据库系统**：是指若干相关数据库的集合。各个数据库可以存在于同一场地，也可分布在多个场地。对多数据库系统进行管理的软件称多数据库管理系统，多数据库管理系统是对一组自治的数据库进行管理，并提供透明访问。

分布式数据库系统分类



元数据的管理


□数据库系统中采用**数据字典**存储数据库定义、管理等信息。数据库系统中字典信息分**全局字典**和**局部字典**，其组织分两种方式：**集中式字典**和**分布式字典**。

□**集中式字典**是系统中的字典信息集中存储在一个场地上，进行统一管理。集中式字典维护方便，但会成为系统性能的瓶颈。

□**分布式字典**是将字典中的信息分布在多个场地上存放。分布式字典又分**复制式分布**和**非复制式分布**。**复制式分布**是局部字典在多个场地上存在副本。**非复制式分布**是指全局字典被分散存储在多个场地上，但每个局部字典必保存仅保存在一个场地上。


元数据的管理

□ 全局字典的组织方式由类型（局部或全局）、位置（分布或集中）、复制三维立体图来描述。




分布式大数据库管理系统

□ 分布式大数据库管理系统的分类




分布式大数据库管理系统

□ 分布式大数据库管理系统的体系结构



(a) Master-Slave体系结构



(b) P2P环形结构



分布式大数据库管理系统

□ Master-Slave结构和P2P环形结构分别具有各自的优势

M/S	P2P
设计简单，可控性好，但master中心节点易成为瓶颈；	无中心节点，自协调性好，扩展方便，可控性较差，且系统设计复杂；
需要维护master服务节点，由master节点维护其管理的slave节点，维护简单、方便；	P2P环形结构的系统，自协调维护网络，扩展方便，可扩展性好；
将master节点和slave节点的功能分开，可减轻节点的功能负载；	各节点平等，没有起到功能分布的作用；
通常基于水平分片的思想实现数据分布，方便支持范围查询；	适于基于Hash分布数据，负载均衡性好，但不利于支持范围查询；

分布式大数据库管理系统


基于HDFS的分布式数据库

从GFS(google file system)到HDFS

□GFS遵从主从式架构，定义了三种角色：client, master, chunkserver。

□master维护所有的元数据(metadata), master定期通过心跳(HeartBeat)消息与每一个 chunkserver 通信，给 chunkserver 传递指令并收集 chunkserver的当前状态

□客户与master的交互只限于对元数据的操作，所有数据方面的通信都直接和 chunkserver联系




分布式大数据库管理系统

□ 基于HDFS的分布式数据库

■ 从GFS到HDFS

HDFS (HDFS, Hadoop Distributed File System)
是GFS的一个最重要的开源实现

HDFS Architecture



□ HDFS采取Master-Slave架构，包括一个NameNode和众多的DataNode

□ NameNode节点管理整个HDFS的命名空间和客户端对集群数据的访问，保证集群中的DataNode正常运行和故障恢复等；

□ DataNode负责数据的存储和维护，还负责响应来自 NameNode 的创建、删除和复制数据块的命令；


□ NameNode 依赖于每个 DataNode 的定期心跳（HeartBeat）消息验证和更新元数据。如果NameNode没有收到某个 DataNode 的心跳消息，NameNode 将采取修复措施，重新复制在该节点上丢失的块。

□ 新加入集群的DataNode需要及时与NameNode保持心跳联系，报告自己的状态和资源使用情况。

分布式大数据库管理系统

□ 基于HDFS的分布式数据库

■ Bigtable的体系结构



□ Bigtable是在Google的三个云计算组件GFS、WorkQueue、Chubby的基础上构建的；

□ 采用Master-Slave体系结构；

□ GFS用于存储日志文件和数据文件；


□ WorkQueue用于处理分布式系统的任务调度、系统监控和故障处理；

□ Chubby是一个高可用、序列化的分布式锁管理器，用于副本管理、服务器管理和子表(Tablet)定位；

分布式大数据库管理系统

□ 基于HDFS的分布式数据库

■ Hbase的体系结构



□ HBase 遵从 Master-Slave 体系结构，由 HBase Master Server 和 HBase Region Server 构成的服务器集群；


□ master 负责将 Region 分配给 RegionServer、动态加载或卸载 RegionServer、对 RegionServer 实现负载均衡、管理全局数据模式定义等功能；

□ HRegionServer 充当 Slave 角色，负责与 Client 进行交互和数据的读写操作；

分布式大数据库管理系统

□ Cassandra

Cassandra是一套开源分布式NoSQL数据库系统，采用列存储思想和Key-Value数据模型，采用去中心化的P2P环形结构。



□Cassandra是由一堆数据库节点共同构成的一个分布式网络服务。是一种P2P模式的分布式结构化数据存储方案。

□对一个节点的写操作，会被复制到其他节点上；对于读操作，会被路由到某个节点上面读取。

□Facebook于2008将 Cassandra 开源，成为Apache的一个顶级项目。



第二章 结束