

社会网络分析-杜玮

目录


1. 社会网络分析概论	3
1.1. 红楼梦的人物网络图	3
1.2. 社会网络分析概论	3
1.2.1. What: 什么是社会网络分析?	3
1.2.2. Why: 为什么需要社会网络分析?	4
1.2.3. How: 如何开展社会网络分析研究?	4
1.3. 理论-150 定律	4
1.3.1. 强连接和弱连接	4
1.3.2. 150 定律应用	4
1.4. 理论-六度分隔理论	5
1.5. 理论-社会资本理论	5
1.5.1. 林南提出的三大假设	5
1.5.2. 社会资本理论应用	5
1.6. 关心的社会网络	6
1.6.1. 答题步骤	6
1.6.2. 关心的社会网络分析示例	6
2. 社会网络分析基础	7
2.1. 基础概念	7
2.1.1. 形式化表达	7
2.2. 社会网络类型	7
特点:	7
2.2.1. 社会网络类型关系图	7
2.2.2. 物以 • 类聚, 人以群分 “的朴素协同过滤推荐	8
2.2.3. Flavor network 应用	9
2.2.4. 同质异质网络	9
2.2.5. 加权图	9
2.2.6. 社会网络类型分类	10
复合型网络	10
2.2.7. 连通图	10
2.3. 节点测度指标	11
2.3.1. 度	11
2.4. 度中心性	11
2.4.1. 中介中心性	12
2.4.2. 中介中心性应用	12
2.4.3. 紧密性中心性	12
2.4.4. 调和中心性 (非联通图)	12
2.4.5. 特征向量中心性	12
2.5. PageRank	13
2.6. 网络指标	13
2.7. 路径搜索	13
2.7.1. 图与图径搜索	13
2.7.2. 最短路径	14
2.7.3. 随机游走	14

2.8. 社群发现	14
2.8.1. 聚类系数	14
2.8.2. 强关联部件	14
2.8.3. 标签传播算法	14
2.8.4. 模块度	15
2.8.5. 运行社群发现算法有什么意义	15
2.8.6. 社群发现算法的应用	15
2.8.7. Louvain 算法应用	16
3. 社会网络分析实践	16
3.1. 什么是软件	16
3.2. Gephi 的网络布局	16
3.2.1. Force Atlas 布局	17
3.2.2. Force Atlas2 布局	17
3.2.3. 力引导布局——Fruchterman Reingold	17
3.2.4. 力引导布局——OpenOrd	17
3.2.5. 力引导布局——Yifan Hu	17
3.2.6. 力引导布局——Yifan Hu Proportional	18
3.2.7. 辅助布局——Noverlap	18
3.2.8. 辅助布局——Rotate	18
3.2.9. 辅助布局——Contraction & Expansion	18
3.2.10. 辅助布局——Label Adjust	18
3.2.11. 辅助布局——Random Layout	19
3.3. 社交网络问题	19
3.3.1. 我的社交网络是什么？	19
3.3.2. 谁是社交网络的明星人物？	19
3.3.3. 特征向量中心度谁是社交网络中的灰衣主教？	20
3.3.4. 何发现社交网络中潜在社区？	20
3.3.5. 社交网络的潜在社区与地理位置是否相关？	20
4. 高级社会网络分析	21
4.1. 高级社会网络挖掘算法	21
4.1.1. 社会网络挖掘任务	21
4.1.2. 挖掘任务传统方法	21
4.1.3. 节点对之间的所有路径？	21
4.1.4. 传统机器学习的缺陷	22
4.1.5. 特征表示	23
4.1.6. 深度学习背景	23
4.1.7. 图神经网络原理	24
4.1.8. 图神经网络&图卷积网络	25
4.1.9. 图卷积网络	25
4.1.10. 图注意力网络	26
4.1.11. 小结	26
4.1.12. 作业：社会网络案例分析	26
4.2. 知识图谱	27
4.2.1. 什么是知识图谱	27
4.2.2. 知识图谱中的常见概念	27
4.2.3. 知识图谱的形式化表示	27
4.2.4. 为什么需要知识图谱	28
4.2.5. 知识图谱类型	28

4.2.6. 知识图谱生命周期	28
4.2.7. 知识体系构建	28
4.2.8. 知识获取目标来源	28
4.2.9. 结构化数据半结构化数据	28
4.2.10. 知识融合	29
4.2.11. 知识存储	29
4.2.12. 知识推理	29
4.2.13. 知识图谱中的典型推理任务	29
4.2.14. 知识图谱表示学习	29
4.2.15. TransE: 最具代表性的知识图谱嵌入	30
4.2.16. 语义匹配模型	31
4.2.17. RESCAL 模型（双线性模型）	31
4.2.18. 知识应用	32

1. 社会网络分析概论

1.1. 红楼梦的人物网络图



注：1-13 分别代表宝玉、熙凤、黛玉、宝钗、湘云、探春、李纨、迎春、惜春、元春、可卿、妙玉、巧姐

图 1 《红楼梦》第一至八十回的整体网络分析图

1.2. 社会网络分析概论

1.2.1. What: 什么是社会网络分析？

① 社会网络：

由多个节点（社会行动者，social actor）及其关系的组成的集合

- 点：vertex, node
- 关系：edge, link

② 社交网络分析(Social Network Analysis):

suibingyue

- 是指基于信息学、数学、社会学、管理学、心理学等多学科的融合理论和方法，为理解人类各种社交关系的形成、行为特点分析以及信息传播的规律提供的一种可计算的分析方法

- 网络科学；复杂网络分析；图挖掘（Graph mining）

1.2.2. Why: 为什么需要社会网络分析？

- 关注互动而非个人行为
- “没有人是孤岛”
- 可视化

1.2.3. How: 如何开展社会网络分析研究？

- 社交：好友推荐、社区发现...
- 科研：合作者推荐、研究动态演化...
- 电商：精准营销、商品推荐...
- 金融：金融风险分析、价格波动预测...
- 医疗：新药发现...
- 公共卫生：疾病传播...
- 舆情：意见领袖、网络舆情监控...

1.3. 理论-150 定律

- 150 定律(Rule Of 150) ，即著名的“邓巴 数字” ,or 邓巴数定律
- 20 世纪 90 年代，英国牛津大学人类学家罗 宾·邓巴（Robin Dunbar）提出一种理论： 一个人交朋友数量的最高上限，是 150 人 ，如果超出这一数值，不仅无法正常工作 和生活，还会降低自己在各方面的效率
- 人们可能拥有更多好友，但只维持与现实 生活中大约 150 个人的“内部圈子”。而 “内部圈子”好友在此理论中指一年至少 联系一次的人。

1.3.1. 强连接和弱连接

① 强连接和弱连接

- ü 强连接：亲人，恋人，宿舍同学
- ü 弱连接：泛泛之交，老师

② 关系：强连接改变行为，弱连接传递信息

人们找到工作主要作用是靠弱连接。新冠病毒通过弱连接即可传播

1.3.2. 150 定律应用

① 游戏设计：

- 根据邓巴数法则，高信任度和亲密 度的团体规模，只会发生在 5 人左右 的社交网络中。
- 游戏中的所有重要角色，例如重要的剧情 NPC、BOSS、队友 NPC 等的数量，应该尽量保持在 50 人左右。
- 算上次要剧情角色或者龙套角色，那么最好保持在 150 人到 500 人的规模之间

② 营销：

- 150 人是做小范围流行时的最有效的人数，也就是说，如果想要 在一个餐饮圈子里把品牌打出去 ，找到这个圈子里的 150 个 KOL 就足够了。
- 500 人是群体里面建立弱关系的最大人数，是最佳的群体数量人数。
- 1500 个人可以形成品牌的引爆点，“根据餐饮界经过多次实践，餐饮品牌的引爆用户数量在 2000-3000 人为最佳。

1.4. 理论-六度分隔理论

六度分隔（Six Degrees of Separation）理论

1967 年，哈佛大学的心理学教授 Stanley Milgram(1933-1984)想要描绘一个人 际联系网，结果发现了“六度分隔”现象。就是 “你和任何一个陌生人之间所间隔的人不会超过六个，也就是说，最多通过 六个人你就能够认识任何一个陌生人。” ——小世界现象（small world phenomenon）

有研究发现，Facebook、Twitter 等平台上已经出现了“五度分隔”“四度分 隔”甚至是“三度分隔”现象，网络上的圈子间的联系变得越来越紧密。

“六度分隔”人人都置身在连接的世界中，通过弱纽带（weak ties）人与人 之间的距离变得非常接近，这在社会关系中发挥着非常强大的作：

- 信息传播
- 疾病传播 （切断小团体之间的连接）

1.5. 理论-社会资本理论

所谓社会资本，一般是指个人在一种组织结构中，利用自己特 殊位置而获取利益的能力。

那些嵌入个人社会网络中的社会资源——权力、财富和声望， 并不为个人所直接占有，而是通过个人直接或间接的社会关系 来获取的。

1.5.1. 林南提出的三大假设

- 1、地位强度假设:人们的社会地位越高，摄取社会资源的机会越多;
- 2、弱关系强度假设:个人的社会网络的异质性越高，通过弱关系摄取社会资源的几率越高;
- 3、社会资源效应假设:人们的社会资源越丰富，工具性行动的结果越理想。

1.5.2. 社会资本理论应用

- 1，集体社会资本：知识共享、企业文化
- 2，个人社会资本：职业发展、项目表现
- 3，社会传染：微信（自杀群、朋友圈）、微博舆情（被操纵的社会传染）
- 4，组织环境：公司环境、同学，室友…

1.6. 关心的社会网络

1.6.1. 答题步骤

- 展示你关心的社会网络
- 你关心的网络：
 - 你的节点和边是什么
 - 您将收集什么数据，或者您将研究哪个数据集
 - 网络的预期大小(#节点，#边)（如果可以估计）
 - 你打算使用网络解决什么问题

1.6.2. 关心的社会网络分析示例

假设你是一个社区领导者，你想了解社区内的居民之间的关系和互动模式。你可以通过组织一次社区活动，收集居民之间的联系方式和互动数据，然后使用社会网络分析方法来分析和理解这些数据。

首先，你可以将居民视为节点，并将联系方式或互动行为视为链接。然后，你可以使用社会网络分析软件绘制一个图形，显示居民之间的连接关系。通过观察图形，你可以看到哪些居民处于网络的中心位置，哪些居民与其他居民联系更紧密，哪些居民处于边缘位置等。

接下来，你可以使用一些社会网络分析指标来进一步分析网络的结构和属性。例如，你可以计算网络的密度、连通性、中心性、介数等指标。通过这些指标的分析，你可以了解社区内居民之间的紧密程度、信息传播的路径和速度、以及社区的核心人物等。

最后，你可以根据社会网络分析的结果来制定社区发展的策略。例如，你可以通过鼓励和培养更多的核心人物来增强社区的凝聚力和影响力；你可以通过加强边缘人物与其他人物的连接来扩大社区的覆盖范围；你也可以通过优化信息传播路径来提高社区宣传和推广的效果。

2. 社会网络分析基础


2.1. 基础概念

2.1.1. 形式化表达

形式化表达



图形表示, 矩阵表示, 三元组表示



Node	Feature 1	Feature 2	Feature 3	Feature 4	Feature 5
1	1	1	1	0	0
2	1	1	1	0	0
3	1	1	1	1	0
4	0	0	1	1	1
5	0	0	0	1	1

(1, 2, 1)

(1, 3, 1)

(2, 3, 1)

(3, 4, 1)

(4, 5, 1)

2.2. 社会网络类型

依据研究群体分类: 自我中心网络 (Ego-centered Networks) VS 整体网络 (Whole Networks)

- 自我中心网络: 是从个体的角度来界定社会网络, 以特定行动者为研究中心, 主要考虑与该行动者相关的联系, 以此来研究个体行为如何受到其人际网络关系的影响。则分析个体成员之间关系的异质性、同质性、结构洞等。
- 整体网络: 关注的焦点则是网络整体中角色关系的综合结构或群体中不同角色的关系结构。一般关注密度、互惠性、关系的传递性、子群结构、核心-边缘结构等。

A. Ego network 应用案例-非法传销网络


通过分析用户电信网络通话记录, 处理成无向图, 用户可以分为普通用户、某大型企业员工、传销组织人员等提取不同类别用户的 ego network, 识别传销组织人员

特点:

节点之间不跨级联系; 同级不抢占下线; 同级非同上下线节点不联系

2.2.1. 社会网络类型关系图

✓ 依据关系方向分类: 有向图 (Directed) VS 无向图 (Undirected) (对称关系)




EG: 关注关系、投资关系、引用关系...



EG: 好友关系、合作关系、共现关系.....

有向图示例-好友 (like) 网络

- 有向图绘制了一个简单的同学网络，边的方向代表着“喜欢”。那么从图中，我们可以知道，同学中“最受欢迎的”的人是“A”和“C”。



矩阵表示

Undirected

$$A_{ij} = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

$$A_{ij} = 0 \quad A_{ij} = A_{ji}$$

$$L = \frac{1}{2} \sum_{i,j=1}^N A_{ij} < k \leq \frac{2L}{N}$$

Actor network, protein-protein interactions

Directed

$$A_{ij} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

$$A_{ij} = 0 \quad A_{ij} \neq A_{ji}$$

$$L = \sum_{i,j=1}^N A_{ij} < k \leq \frac{L}{N}$$

WWW, citation networks

有向图示例-专利引用网络

- P1引用P3




Fig. 2 An illustration of an intra-college citation network

Scientometrics
https://doi.org/10.1007/s11023-021-04588-4

A personalized recommendation system for high-quality patent trading by leveraging hybrid patent analysis

Wei Du¹, Yiluo Wang², Wei Xu³, Jian Ma²

Received: 1 November 2020 / Accepted: 7 October 2021
© The Author(s) 2021

13

社会网络类型

1-mode, 2-mode, multi-mode

- 依据节点类型分类: 1-模网 VS 2-模网


• 1-模网

由一个行动者集合内部各个行动者之间的关系构成的网络。

	A	B	C
A			
B			
C			




	C	D	E
A			
B			
C			



• 2-模网

一类行动者集合与另一类行动者集合之间关系构成的网络。
(eg: 隶属网络)



典型二分图-user-item interaction



	1	2	3	4
1	1			1
2	?	1	?	?
3		1		1
4			1	1

collaborative: similar interactions

2.2.2. 物以类聚，人以群分“的朴素协同过滤推荐



2.2.3. Flavor network 应用


p 西方烹饪倾向于使用具有许多共同风味化合物的食材对

p 相比之下，东亚和南欧的菜系则避免使用含有相同风味成分的食谱

2.2.4. 同质异质网络

社会网络类型

同质网络与异质网络 homogeneous & heterogeneous






2.2.5. 加权图


加权图应用

• 未加权图与加权图

- 未加权图 (Unweighted Graphs) 的节点和边上均没有权重。
- 加权图 (Weighted Graphs)，所加权重可以代表：成本、时间、距离、容量等，权重代表关系的强度。



What's the Shortest Path Between A and E?



2.2.6. 社会网络类型分类

复合型网络

社会网络类型



✓ 依据成员紧密程度分类：完备图 VS 非完备图

如果图中任意两个节点之间都有连线，则该图为完备图，否则为非完备图。



完备图的中心势为0（每个点都有相互联系，无所谓中心不中心），星型或辐射型的网络的中心势接近1

2.2.7. 连通图

• “连通图” (connected graph) 与 “成分” (components)

✓ 如果网络图中的任何两点之间都存在一个途径 (Path)，则称这两点是相互可达的，称该图时连通图 (connected graph)。也就是说，关联图中的任何两点之间都是可达的。




• 在有向图G中，如果两个顶点 v_i, v_j 间 ($v_i \neq v_j$) 有一条从 v_i 到 v_j 的有向路径，同时还有一条从 v_j 到 v_i 的有向路径，则称两个顶点**强连通**(strongly connected)。如果有向图G的每两个顶点都强连通，称G是一个**强连通图**。

• “连通图” (connected graph) 与 “成分” (components)



✓ 如果一个图不是连通的，就称之为“不连通图”，其可以分为两个或者多个连通的子图，我们称之为连通子图。

✓ 一个图中的各个连通子图都叫做“成分” (components)。“成分”内部的任何点之间都存在途径。但是，成分内部的一点与任何外在于该成分的点之间都不存在任何途径。



• $C1 = \{A, B, C, D, E, F\}$
• $C2 = \{G, H, I\}$
• $C3 = \{J\}$

矩阵表示




2.3. 节点测度指标

2.3.1. 度

- 度 (degree)
- 中心性 (centrality)：用于识别图中特定节点的角色及其对网络的影响；中心性算法能够帮助我们识别最重要的节点，例如可信度、可访问性、事物传播的速度等。
- “度数” (degree)：与某节点直接相连的点称为该点的“邻点”(neighborhood)，一个节点的邻点个数称为该点的“度数”也叫关联度(degree of connection)。(度数为0称之为“孤立点”(isolate))例如，在一个社交网络中，一个拥有更多 degree 的人 (节点) 更容易与人发生直接接触，也更容易获得流感。
- 点入度”(indegree) 和“点出度”(out-degree)：在有向网络中，点入度指的是直接指向该点的点的总数;点出度指的是该点所直接指向的点的总数。

• 度、入度、出度




2.4. 度中心性

- 点度中心性 (degree centrality)：一个节点的度数
- 中介中心性 (betweenness centrality)：如果一个节点位于其他节点的多条最短路径上，那么该节点具有较大的中介中心性。
- 接近中心性 (closeness centrality)：如果节点到图中其他节点的最短距离都很小，那么它的接近中心性就很高。相比中介中心性，接近中心性更接近几何上的中心位置。(平均值)
- 特征向量中心性 (eigenvector centrality)：一个节点的中心性是相邻节点中心性的函数节点所连接的节点越重要，其自身中心性也就越高。

- Degree Centrality (度中心性)——最简单的社会网络分析“算法”

- Degree 可以简单理解为一个节点的访问机会的大小。

例如，在一个社交网络中，一个拥有更多 degree 的人 (节点) 更容易与人发生直接接触，也更容易获得流感。



2.4.1. 中介中心性

- 中介中心性（Betweenness Centrality）是一种检测节点对图中信息或资源流的影响程度的方法。
- 它通常用于寻找连接图的两个部分的桥梁节点，系统重要“媒介”，它们掌握着资源或者信息的流动性。

● 中心性测量：中介中心度

绝对中介/中间中心度：

$$C_{ABi} = \sum_j \sum_k b_{jk}(i), \quad j \neq k \neq i, \text{ 且 } j < k$$

相对中介/中间中心度：

$$C_{RBI} = \frac{2C_{ABi}}{n^2 - 3n + 2}, \quad 0 \leq C_{RBI} \leq 1$$

$C_n^m = \frac{A_n^m}{m!} = \frac{n!}{m!(n-m)!} = C_{n-m}^{n-m}$! - Factorial阶乘

● 中介中心性（Betweenness Centrality）计算

绝对中介/中间中心度：

$$C_{ABi} = \sum_j \sum_k b_{jk}(i), \quad j \neq k \neq i, \text{ 且 } j < k$$

相对中介/中间中心度：

$$C_{RBI} = \frac{2C_{ABi}}{n^2 - 3n + 2}, \quad 0 \leq C_{RBI} \leq 1$$

$C_n^m = \frac{A_n^m}{m!} = \frac{n!}{m!(n-m)!} = C_{n-m}^{n-m}$! - Factorial阶乘

2.4.2. 中介中心性应用

节点的控制力：传播瓶颈（信息、疾病等）；一个在计算机科学学术世界和音乐世界的跨界者

2.4.3. 紧密性中心性

Closeness Centrality（紧密性中心性）计量一个节点到所有其他节点的紧密性（距离的倒数），一个拥有高紧密性中心性的节点拥有着到所有其他节点的距离最小值。

——适用于连通图

绝对接近中心度

$$C_{APi}^{-1} = \sum_{j=1}^n d_{ij} \quad (\text{dij为点i和j之间的捷径距离/测地线})$$

相对接近中心度

$$C_{RPI}^{-1} = \frac{C_{APi}^{-1}}{n-1} \quad (n \text{ 为网络节点数})$$

网络中传播信息最快的节点

2.4.4. 调和中心性（非联通图）

调和中心性提出的“平均最短距离”则是对这些最短距离的倒数求和，这使它可以处理非连通图中会出现的无限值。


2.4.5. 特征向量中心性

- 特征向量中心性（eigenvector centrality）度量的是节点影响的传递。
- 来自高分值邻居节点对节点分值的贡献大于来自低分值邻居节点，节点有高分值意味着它连接到许多高分值节点。
- 特征向量中心性强调节点所处的周围环境，例如在疾病传播中，特征向量中心性较大的节点距离传染源更近的可能性更大，需要格外防范。

特征向量中心性（eigenvector centrality）计算：

• 特征向量中心性 (eigenvector centrality) 计算

对邻接矩阵求特征值，绝对值最大的特征值称为主特征值，主特征值对应的特征向量即为主特征向量，它包含矩阵最多的信息。



$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 1 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$\lambda_1 = 2.686$$

$$\lambda_2 = -1.749$$

$$\lambda_3 = -1.271$$

$$\lambda_4 = 0.335$$

$$\lambda_5 = 0$$

Eigenvalues

$|\lambda_1|$ is the largest, so λ_1 is the dominate eigenvalue

$$x_1 = \begin{bmatrix} 1.899 \\ 2.686 \\ 1.899 \\ 2.414 \\ 1 \end{bmatrix}$$

Dominate Eigenvector

2号节点特征向量中心性最大，5号节点最小

2.5. PageRank

Google 著名的 PageRank 算法是特征向量中心性算法的一个变种，用来进行网页排名。

假设互联网是一个有向图，在其基础上定义随机游走模型，即一阶马尔可夫链，表示网页浏览者在互联网上随机浏览网页的过程。

PageRank 应用：

- 寻找最重要的基因：我们要寻找的基因可能不是与生物功能联系最多的基因，而是与最重要功能有紧密联系的基因；

who to follow service at twitter Twitter 使用个性化的 PageRank 算法向用户推荐他们可能希望关注的其他帐户。该算法通过兴趣和其他的连接，为用户展示感兴趣的其他用户；

- 交通流量预测 使用 PageRank 算法计算人们在每条街道上停车或结束行程的可能性

2.6. 网络指标

网络密度	聚集系数
作用：衡量网络中节点间的边的密集程度	作用：衡量节点的好友之间有多大可能性是好友
定义：网络中实际存在的边数与可容纳的边数上限的比值	定义：节点的相邻节点间，边数与所有潜在可能边数的比例

2.7. 路径搜索

2.7.1. 图与图径搜索

图搜索 (Graph search) :探索一个图，用于一般发现或显式搜索，通常是许多其他类型分析的第一步。

路径搜索 (Pathfinding) :

探索节点之间的路径，这些路径从一个节点开始，遍历关系，直到到达目的地。

路径搜索算法识别最优路径，用于物流规划，最低成本呼叫或者 IP 路由问题，以及游戏模拟等。

图搜索算法:包括广度优先搜索 (Breadth First Search, 简称 BFS) 和深度优先搜索 (Depth First Search, 简称 DFS)，它们是遍历图的基础：

BFS 从选定的节点出发，优先访问所有一度关系的节点之后再继续访问二度关系节点，以此类推。

DFS 从选定的节点出发，选择任一邻居之后，尽可能的沿着边遍历下去，直到不能前进之后再回溯。

2.7.2. 最短路径

最短路径（Shortest Paths）算法计算给定的两个节点之间最短（最小权重和）的路径，可以计算两点之间成本最低的路线。如导航：谷歌、百度、高德地图均提供了导航功能，它们就使用了最短路径算法。如疾病传播：最短距离→有效距离。

2.7.3. 随机游走

随机游走（Random Walk）算法从图上获得一条随机的路径。从一个节点开始，随机沿着一条边正向或者反向寻找到它的邻居，以此类推，直到达到设置的路径长度。

随机游走算法一般用于随机生成一组相关的节点数据，作为后续数据处理或者其他算法使用。

2.8. 社群发现

在社会网络中，有的用户之间的连接较为紧密，有的用户之间的连接关系较为稀疏。

其中连接较为紧密的部分可以被看成一个社群/社区（community），其内部的节点之间有较为紧密的连接，而在两个社区间则相对连接较为稀疏。

社群发现算法（Community Detection Algorithms）有助于发现社群中群体行为或者偏好，寻找嵌套关系，或者成为其他分析的前序步骤

2.8.1. 聚类系数

三角计数（Triangle Count）计算图中由节点组成的三角形的数量，要求任意两个节点间有边（关系）连接。

聚类系数（Clustering Coefficient）算法的目标是测量一个组的聚类紧密程度。该算法计算网络中三角形的数量，与可能的关系的比率。聚类系数为 1 表示这个组内任意两个节点之间有边相连

2.8.2. 强关联部件

强关联部件（Strongly Connected Components，简称 SCC）算法寻找有向图内的一组节点，每组节点可以通过关系互相访问

- 每组节点内部不需要直接相连，只要通过路径访问即可。

关联类算法

- 标签传播算法（Label Propagation Algorithm，简称 LPA）
- Louvain Modularity Algorithm

2.8.3. 标签传播算法

- 标签传播算法（Label Propagation Algorithm，简称 LPA），由 Raghavan 等人于 2007 年提出，是一个在图中

快速发现社群的算法。

- 在 LPA 算法中，节点的标签完全由它的直接邻居决定。
- 形象地理解算法的传播过程：
 - 当标签在紧密联系的区域，传播非常快，但到了稀疏连接的区域，传播速度就会下降。
 - 当出现一个节点属于多个社群时，算法会使用该节点邻居的标签与权重，决定最终的标签。
 - 传播结束后，拥有同样标签的节点被视为在同一群组中。

2.8.4. 模块度

模块度（Modularity）：Newman 在 2003 年提出，用来衡量一个社区的划分是否 优良。

一个好的划分结果其表现形式是：在社区内部的节点相似度较高，而在社区外部节点的相似度较低。

Louvain 模块度算法：该算法在效率和效果上都表现较好，并且能够发现层次性的社区结构，适合庞大网络的社群发现。

算法思想：

Louvain 算法包括两个阶段： -

步骤一，不断地遍历网络中的结点，尝试将单个结点加入能够使 modularity 提升最大的社区中，直到所有结点都不再变化。

- 步骤二，处理第一阶段的结果，将一个个小的社区归并为一个超节点来重新构造网络，这时边的权重为两个节点内所有原始节点的边权重之和。

- 迭代这两个步骤直至算法稳定。

Louvain 算法是一个迭代算法，每一轮迭代都会产生一个当前局部最优的社区结构。

2.8.5. 运行社群发现算法有什么意义

社群发现算法是一种用于识别和划分社会网络中的社群或社区的算法。运行社群发现算法有以下意义：

1. 理解用户行为和偏好：通过识别网络中的社群，我们可以更好地理解用户的行为和偏好。例如，在社交媒体网站上，通过分析用户之间的连接关系和互动模式，我们可以将用户划分为不同的社群，每个社群有自己独特的兴趣和话题。通过了解这些，我们可以更好地了解每个社群的需求和偏好，从而更好地推荐内容和服务。
2. 制定营销策略：在市场营销中，运行社群发现算法可以帮助企业更好地了解客户群体，并制定更有针对性的营销策略。例如，如果一个公司发现其客户可以分为几个不同的社群，每个社群有不同的需求和偏好，那么它可以针对每个社群制定不同的营销策略，如提供不同的产品或服务组合、制定不同的价格策略等。
3. 社交关系分析：社群发现算法可以用于分析社交关系，从而帮助人们更好地了解自己的社交圈子。例如，在个人社交网络中，通过识别紧密联系的社群，我们可以了解自己的社交圈子中的人群和话题。这可以帮助我们更好地了解自己的职业发展机会、人脉资源等。
4. 网络安全和监控：在网络安全和监控领域，社群发现算法可以用于识别网络中的社群和社区，并监控它们之间的互动和行为。例如，在一个企业网络中，通过识别不同部门之间的联系和互动模式，我们可以更好地了解网络中的社群和社区，并监控它们之间的行为和活动，以发现潜在的安全问题和违规行为。

总之，运行社群发现算法可以帮助我们更好地理解和分析社会网络中的结构和属性，从而在市场营销、社交关系分析、网络安全等领域中发挥重要作用。

2.8.6. 社群发现算法的应用

在社交媒体平台上，用户通常会关注和互动的人群可以分为不同的社群。这些社群可能由共同的兴趣爱好、地理位

置、职业、年龄等因素组成。通过社群发现算法，社交媒体平台可以更好地了解用户群体，并提供更符合用户需求的推荐内容、广告和营销策略。

例如，社交媒体平台可以使用基于图论的社群发现算法，将用户关系图谱划分为不同的社群。这种算法通常会使用节点之间的连接关系和互动模式作为输入数据，然后通过聚类或社区检测算法来识别和划分社群。

一旦社群被识别和划分，社交媒体平台可以采取以下措施：

1. 提供更个性化的推荐内容：社交媒体平台可以根据每个社群的兴趣爱好和话题，提供更个性化的推荐内容，如推荐相关的帖子、视频、文章等。这可以帮助用户更好地发现感兴趣的内容，提高用户的参与度和留存率。
2. 制定营销策略：社交媒体平台可以根据不同社群的需求和偏好，制定更有针对性的营销策略。例如，针对不同年龄段的用户，可以推荐不同类型的产品和服务；针对不同职业的用户，可以推荐相关的职业发展机会和培训课程。
3. 增强社交圈子：社交媒体平台可以通过推荐与其他社群成员的连接，帮助用户扩大社交圈子。这可以帮助用户更好地了解不同群体之间的互动和交流，促进用户的社交和参与度。

总之，社群发现算法在社交媒体平台上的应用可以帮助平台更好地了解用户群体，提供更个性化的推荐内容和服务，增强用户的参与度和留存率，提高平台的用户满意度和忠诚度。

2.8.7. Louvain 算法应用

金融风控：在金融风控场景中根据用户行为特征进行团伙识别。

社交网络：基于网络关系中对（一条边连接的两个顶点）之间关联的广度和强度进行社交网络划分；对复杂网络分析、电话网络分析人群之间的联系密切度。

推荐系统：基于用户兴趣爱好的社区发现，可以根据社区并结合协同过滤等推荐算法进行更精确有效的个性化推荐。

3. 社会网络分析实践

3.1. 什么是软件

Pajek, Gephi, Ucinet, Python, R

– Gephi

- 简单易学的图形化界面；绚丽的可视化展示；动态网络图分析；大型网络分析
- 支持 iOS, windows, ...

3.2. Gephi 的网络布局

布局算法是 Gephi 的核心，默认提供 12 种布局算法，可分为两类：

- 力引导布局通过能够模仿物理世界中的引力和斥力，将图中的节点模拟成原子，通过模拟原子间的力场来计算节点间的位置关系，使系统最终进入一种动态平衡。

suibingyue

- Gephi 的力引导布局有 6 种，即 Force Atlas、Force Atlas 2、Fruchterman Reingold、OpenOrd、Yifan Hu、Yifan Hu Proportional。 – 辅助布局是根据某种预先定义的规则对图进行布局
- 辅助布局有 6 种，Noverlap、Rotate、Contraction、Expansion、标签调整、随机布局。

3.2.1. Force Atlas 布局

使图更紧凑、可读性强。主要参数如下：

- Inertia(惯性)：值愈大，图的摇摆幅度越大。
- Repulsion strength(斥力强度)：每个节点排斥其他节点的强度，值越大，节点的距离越大。
- Attraction strength(吸引强度)：连接节点之间的吸引力的强度，值越大，有连接的节点越被拉近。
- Gravity(重力)：值越小，图越分散；值越大，图越压缩。
- Speed(速度)：布局运动的速度，值越大，图的布局速度越快。

3.2.2. Force Atlas2 布局

改进的 Force Atlas 算法，速度更快。主要参数：

- Scaling(缩放)：节点的斥力强度，值越大，斥力越大，图越稀疏。
- Stronger Gravity(更强的重力)：一个已经定义好的较强的重力。
- Gravity(重力)：自定义的重力值，可以比“更强的重力”更强。
- Dissuade Hubs(劝阻 Hubs)：只有输入的边会被推到边缘。
- LinLog 模式：线性和对数模式的切换。
- Prevent Overlap(防止重叠)：可以把重叠的节点展开
- Tolerance(Speed) / 容差（速度）：布局速度的选取，较小的数值速度较慢，但精度更高。

3.2.3. 力引导布局——Fruchterman Reingold

Fruchterman Reingold 简称 FR，FR 布局基于再次改进的弹性模型，该布局算法遵循两个简单的原则，即有连接的节点互相靠近和无连接的节点互相排斥。主要参数：

- Area(区)：定义图形的幅度，值越大图越大，也越稀疏。
- Gravity(重力)：定义重力值，值越大重力越强，节点越被中心吸引。
- Speed(速度)：定义布局的速度，值越大布局速度越快，但也越不精确。

3.2.4. 力引导布局——OpenOrd

OpenOrd 布局是一种新的力引导布局，支持多核、并行。

- OpenOrd 布局的 Stages（阶段）分为 Liquid（液体）、Expansion（扩张）、Cooldown（冷却）、Crunch（紧缩）和 Simmer（煨）5 个过程，适合处理节点较多的图；对于节点较少的图形，运行起来效果并不是很好。

3.2.5. 力引导布局——Yifan Hu

Yifan Hu 布局也是力引导布局的改进版，由胡一凡在 2005 年提出，在多层级力引导算法中引入了超节点的概念。

- 该布局算法中，将一个节点与它远处一簇节点之间的斥力当作此节点与一个超节点间的斥力来计算，从而大大减少了计算量，使得总计算复杂度下降，可处理几十万个节点规模的图。

主要参数如下：

suibingyue

- Optimal Distance(最佳距离): 值越大, 整个图的尺寸越大。
- Relative Strength(相对强度): 值越大, 节点越稀疏; 值越小, 节点越紧密。

3.2.6. 力引导布局——Yifan Hu Proportional

Yifan Hu 比例布局的参数与 Yifan Hu 布局的参数相同, 实际上这两个布局所起到的作用是相同的, 扩展(收缩布局的参数只有比例因子, 比例因子的设置方法如下:

- 如果比例因子为 1, 那么图不会放大也不会缩小。
- 如果比例因子大于 1, 那么图会放大, 且值越大, 放大的比例越大。
- 如果比例因子小于 1, 那么图会缩小, 且值越小, 缩小的比例越大。
- 如果比例因子为负数, 那么在放大或缩小的同时, 也会从上下、左右两个方面颠倒图形。

3.2.7. 辅助布局——Noverlap

Noverlap(交叠布局)可以防止参数的重叠, Noverlap 布局中不考虑标签的重叠。

主要参数如下:

- speed(速度): 布局速度。一般都是速度越快, 布局越差
- ratio(节点边距): 间距为 1 的时候, 节点会连在一起, 随着间距增大, 节点变的越来越分开。当间距小于 1 的时候, 允许节点重叠。
- margin(幅度): 增加幅度半径。当幅度为 0 的时候, 没有余量; 幅度增大节点分离越大, 负的幅度的时候允许重叠。

3.2.8. 辅助布局——Rotate

Rotate 布局很简单, 其可以将图形从整体上进行顺时针或者逆时针的旋转, 从而进行布局。

- 唯一的参数是 Angle (旋转角度, 旋转角度可以是正的, 也可以是负的值)。

3.2.9. 辅助布局——Contraction & Expansion

Expansion(扩展)、Contraction(收缩)布局是对原始图的按照比例的扩展和收缩, 两者唯一的参数是 Scale factor(因子)。

Scale factor 取值有以下几种情况:

- 因子=1, 不扩展, 不收缩。
- 因子>1, 扩展, 值越大, 扩展越大。
- 因子<1, 收缩, 值越小, 越收缩。
- 因子为负数: 在扩展和收缩的同时, 进行图形的颠倒。

3.2.10. 辅助布局——Label Adjust

Label Adjust(标签调整)布局主要可以防止标签的重叠, 参数包括:

- Speed (速度), 决定了布局的速度。
- Include Node size (包括节点大小): 是否使得重叠的节点分散。

3.2.11. 辅助布局——Random Layout

Random Layout(随机布局)在一个 Space size(空间大小的参数)上进行随机的布局。

3.3. 社交网络问题

3.3.1. 我的社交网络是什么？

社交网络是指您与其他人之间建立的社会关系网络。这些关系通常基于共同的兴趣爱好、价值观、职业、地理位置等因素，并通过不同的社交渠道进行沟通和互动。

以下是一些可能构成您社交网络的因素：

1. 社交渠道：您的社交网络可能包括不同的社交渠道，如在线社交媒体平台、社交网络应用程序、线下社交活动等。您可以通过这些渠道与其他人建立联系和互动，并分享信息、经验和观点。
2. 共同兴趣爱好：您的社交网络可能由具有共同兴趣爱好的人组成。这些兴趣爱好可能包括音乐、电影、运动、旅游等。通过共同的兴趣爱好，您可以与其他人建立联系和互动，并分享相关的信息和资源。
3. 职业和行业：您的社交网络可能由与您从事相同或相似职业的人组成。这些职业可能包括学生、教师、企业家、专业人士等。通过共同的职业或行业，您可以与其他人建立联系和互动，并分享经验和资源，以帮助彼此在职业生涯中取得成功。
4. 地理位置：您的社交网络可能由与您居住在同一地理位置的人组成。这些地理位置可能包括城市、社区、学校等。通过共同的地理位置，您可以与其他人建立联系和互动，并分享当地的资源和信息，例如活动、事件和社区服务。

总之，您的社交网络是由您与其他人之间建立的社会关系网络组成的，这些关系通常基于共同的兴趣爱好、价值观、职业、地理位置等因素。您的社交网络可以帮助您扩大人脉圈子，获取信息和资源，以及建立更紧密的关系和信任。

3.3.2. 谁是社交网络的明星人物？

社交网络的明星人物通常是指在社交网络中具有较高关注度和影响力的用户。这些用户通常具有以下特点：

拥有大量的关注者：社交网络的明星人物通常拥有大量的关注者，这些关注者包括粉丝、朋友、家人等。这些关注者是社交网络中的主要受众，他们可以接收到这些明星人物发布的信息、内容、帖子等，并与他们进行互动和交流。

1. 具备影响力：社交网络的明星人物通常具有较高的影响力，他们的言论和行为可以影响到他们的关注者和粉丝。这些明星人物可以通过发布信息、分享经验、评论事件等方式来影响他们的关注者和粉丝，甚至可以引发社会话题和讨论。
2. 活跃度高：社交网络的明星人物通常具有较高的活跃度，他们经常在社交网络上发布内容、回复评论、与粉丝互动等。这些明星人物通过积极参与社交网络，可以吸引更多的关注者和粉丝，同时也可以增强与现有关注者和粉丝的互动和信任。
3. 内容质量高：社交网络的明星人物通常会发布高质量的内容，包括照片、视频、文章等。这些内容通常具有较高的吸引力和价值，可以吸引更多的关注者和粉丝，并增强与他们的互动和交流。

总之，社交网络的明星人物通常具有较高的关注度和影响力，他们的言论和行为可以影响到他们的关注者和粉丝。这些明星人物通常具有活跃度高、内容质量高等特点，是社交网络中的重要角色之一。

3.3.3. 特征向量中心度谁是社交网络中的灰衣主教？

在社交网络中，特征向量中心度是一种衡量节点中心性的指标，可以用来确定节点在社交网络中的重要性和影响力。灰衣主教是指社交网络中具有较高影响力和权威性的用户，他们通常具有以下特点：

1. 高影响力：灰衣主教通常具有较高的影响力，因为他们在社交网络中拥有大量的关注者和粉丝。这些关注者和粉丝可以接收到灰衣主教的言论和信息，并受到影响和启发。
2. 高权威性：灰衣主教通常具有较高的权威性，因为他们在社交网络中具有较高的声望和信任度。这些特点使得灰衣主教可以影响和引导其他用户的行为和决策，从而对社交网络的舆论和话题产生影响。
3. 参与度高：灰衣主教通常具有较高的参与度，他们经常在社交网络上发布内容、回复评论、与粉丝互动等。这些灰衣主教的积极参与可以增强与关注者和粉丝的互动和信任，同时也可以吸引更多的关注者和粉丝。
4. 社交网络中的关键节点：灰衣主教通常被认为是社交网络中的关键节点，因为他们可以通过与其他关键节点的连接来影响信息的传播和资源的流动。这些特点使得灰衣主教成为社交网络中的重要角色之一。

因此，在社交网络中，特征向量中心度高的节点通常被认为是具有较高影响力和权威性的灰衣主教。这些灰衣主教可以帮助社交网络中的其他用户建立联系、传播信息和形成社群，同时也可以影响和引导社交网络的舆论和话题。

3.3.4. 何发现社交网络中潜在社区？

发现社交网络中的潜在社区可以通过社群发现算法来实现。以下是一些常见的社群发现算法：

1. 基于图论的社群发现算法：这种算法将社交网络视为一个图，并通过节点之间的连接关系和相似性来识别社群。常见的基于图论的社群发现算法包括社区检测算法（如 Louvain 算法、GN 算法等）和模块度最大化算法（如 Newman 算法等）。
2. 基于密度的社群发现算法：这种算法通过关注节点之间的连接密度和连通性来识别社群。常见的基于密度的社群发现算法包括 DBSCAN 算法、HDBSCAN 算法等。
3. 基于层次的社群发现算法：这种算法将社交网络视为一个树状结构，并通过节点之间的层次关系来识别社群。常见的基于层次的社群发现算法包括层次聚类算法、谱聚类算法等。
4. 基于模型的社群发现算法：这种算法通过建立一个数学模型来描述社交网络的结构和行为，并通过模型推断来识别社群。常见的基于模型的社群发现算法包括概率模型算法、潜在狄利克雷分布（LDA）模型等。

这些社群发现算法可以应用于社交网络数据，帮助我们识别和划分不同的社群。通过分析每个社群的节点特征、连接关系和行为模式，我们可以了解每个社群的特点和偏好，从而更好地理解用户群体和引导营销策略。

3.3.5. 社交网络的潜在社区与地理位置是否相关？

社交网络的潜在社区与地理位置之间可能存在一定的相关性。以下是一些可能的影响因素：

1. 地理位置的相似性：社交网络的潜在社区可能受到地理位置相似性的影响。如果一群用户位于相似的地理位置，例如同一城市或同一地区，那么他们可能在社交网络中形成一个潜在社区。这是因为相似的地理位置可能会促进用户之间的互动和交流，从而增加他们之间的联系和相似性。
2. 地理位置的聚集性：社交网络的潜在社区可能受到地理位置聚集性的影响。在某些情况下，用户可能会因为地理位置的聚集而形成一个潜在社区。例如，在一个城市中，不同区域的用户可能会因为地理位置的聚集而形成不同的潜在社区。
3. 地理位置的影响力：社交网络的潜在社区可能受到地理位置的影响力。某些地理位置可能会对社交网络中的用

户产生更大的影响力和权威性，从而影响用户的决策和行为。例如，在一个城市中，市中心的用户可能会对其他区域的用户产生更大的影响力，从而形成一个潜在社区。

然而，需要注意的是，地理位置并不是构成社交网络潜在社区的唯一因素。社交网络中的用户可能受到多种因素的影响，例如兴趣爱好、职业、文化背景等。因此，在分析社交网络的潜在社区时，需要综合考虑多种因素，而不能仅仅局限于地理位置这一因素。

4. 高级社会网络分析

4.1. 高级社会网络挖掘算法

4.1.1. 社会网络挖掘任务

- 1, 节点分类/预测 (node classification)
 - 分类：信用评级
 - 异常检测：反欺诈；风险预警
- 2, 链接预测 (link prediction)
 - 推荐：电影推荐；商品推荐；合作者推荐；论文引用推荐
- 3, 其他任务：社区检测；路径抽取等

4.1.2. 挖掘任务传统方法

网络特征抽取 → 机器学习模型 (SVM、RF 等) → 分类/预测 结果

基于距离的特征

局部邻居重叠特征


全局邻居重叠特征

4.1.3. 节点对之间的所有路径？


- Recall: $A_{uv} = 1$ if $u \in N(v)$
- Let $P_{uv}^{(K)} = \# \text{paths of length } K \text{ between } u \text{ and } v$
- We will show $P^{(K)} = A^k$
- $P_{uv}^{(1)} = \# \text{paths of length 1 (direct neighborhood)}$
between u and $v = A_{uv}$

$$P_{12}^{(1)} = A_{12}$$

$$A = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix}$$



$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{pmatrix}$$

$$A^2(1,1) = \sum_{k=1}^4 a_{1k} \cdot a_{k1}$$


4.1.4. 传统机器学习的缺陷



传统算法

- 人工设计特征 → 机器学习模型
- 特征工程：专业知识；特征不全面；费时费力


高级社会网络挖掘算法

- 基础特征 → 模型学习复杂特征
- 图神经网络算法 (GNN)

4.1.5. 特征表示

- 图的表示：节点特征矩阵 $A \in \mathcal{R}^{n \times f}$

Node	Feature1	Feature2	Feature3	Feature4	Feature5
1	1	1	1	0	0
2	1	1	1	0	0
3	1	1	1	1	0
4	0	0	1	1	1
5	0	0	0	1	1



缺点：

1. 当节点数量多时，大量0值， n 维特征向量
2. 难以反映节点间的高阶关联，如节点2和节点5

4.1.6. 深度学习背景

DNN。Deep neural network 深度神经网络

RNN。Recurrent neural network 循环神经网络-处理时间/空间序列数据

- 自然语言处理：上下文
- 时间序列预测

CNN。Convolutional neural network 卷积神经网络

- 处理图像 image

DNN 直接处理大尺寸图像具有三个明显的缺点：

- (1) 首先将图像展开为向量会丢失空间信息；
- (2) 其次参数过多效率低下，训练困难；
- (3) 同时大量的参数也很快会导致网络过拟合

CNN 步骤：

- 1.卷积-提取特征。
- 2.池化-下采样，数据降维
- 3.全连接层-输出结果

4.1.7. 图神经网络原理

- 聚合信息

□ 对于A点其邻居信息 $N = a * (2,2,2,2,2) + b * (3,3,3,3,3) + c * (4,4,4,4,4)$

- 更新信息


□ A的信息 = $\sigma(W((1,1,1,1,1) + \alpha * N))$

- 多层循环传播信息

□ 经过一次聚合更新之后，A中含有B,C,D的信息，C中有A,B,D,E的信息...

□ 第二次聚合时，以A节点为例，此时A可以获得二阶邻居E点的特征

□ 最终得到节点表示



图神经网络原理



□ 给定一张图 G ，用 $\mathbf{x}_v$ 表示结点 v 的特征，用 $\mathbf{x}(u, v)$ 表示结点 u 与结点 v 之间边的特征

□ **GNN的学习目标：** 获得每个结点的图感知的隐藏状态 $\mathbf{h}_v$ (state embedding)，对于每个节点，它的隐藏状态包含了来自邻居节点的信息。

那么，如何让每个结点都感知到图上其他的结点呢？

GNN通过迭代式更新所有结点的隐藏状态来实现，在 $t+1$ 时刻，结点 v 的隐藏状态按照如下方式更新：

$$\mathbf{h}_v^{t+1} = f(\mathbf{x}_v, \mathbf{x}_o[v], \mathbf{h}_n^t e[v], \mathbf{x}_n e[v]),$$

f ：隐藏状态的状态更新函数

$\mathbf{x}_n e[v]$ ：结点 v 的邻居节点的特征


$\mathbf{x}_o[v]$ ：与结点 v 相邻的边的特征

$\mathbf{h}_n^t e[v]$ ：邻居节点在 t 时刻的隐藏状态

图神经网络原理

- 假设结点5为中心结点，其隐藏状态的更新函数如图所示。
- 这个更新公式表达的思想自然又贴切：


不断地利用当前时刻邻居结点的隐藏状态作为部分输入来生成下一时刻中心结点的隐藏状态，直到每个结点的隐藏状态变化幅度很小，整个图的信息流动趋于平稳。



$$h_5 = f(x_5, x_{(3,5)}, x_{(5,6)}, h_3, h_6, x_3, x_6)$$

图神经网络原理

- f 是对所有结点都成立的，是一个全局共享的函数，利用神经网络(Neural Network)来拟合这个复杂函数 f



4.1.8. 图神经网络&图卷积网络

- DNN→GNN: - GNN 可以看作是对现有的神经网络的扩展，关注处理图(graph) 中表示的数据。
- CNN→GCN: - GCN 希望将卷积操作应用在图结构数据上，可以视作 CNN 的扩展

4.1.9. 图卷积网络

输入的是整张图，在 Convolution Layer 1 里，对每个结点的邻居都进行一次卷积操作，并用卷积的结果更新该结点；

- 然后经过激活函数如 ReLU，然后再过一层卷积层 Convolution Layer 2 与一层激活函数；

suibingyue

- 反复上述过程，直到层数达到预期深度

GCN 中通过级联的层捕捉邻居的消息，层与层之间的参数不同；

GNN 通过级联的时间来捕捉邻居的消息，全局共享参数。

消息传递机制：

边上的源节点，往目标节点发送特征

目标节点对收到的特征进行聚合

4.1.10. 图注意力网络

GCN 中边的权重：

p 与节点的度相关

p 不可学习

GAT 中边的权重：

p 权重变成节点间的函数

p 权重与两个节点相关性有关 p 可学习

4.1.11. 小结

一般算法：GNN GCN

- 区分节点作用：GAT
- 大规模图：GraphSAGE
- 异构图：RGCN

4.1.12. 作业：社会网络案例分析

假设你现在正在承担某银行大数据风控建模工作，针对借款人进行信贷评估，目前可以获得借款人的工作地址、姓名、身份证、单位、IP 地址、联系人手机号等信息，请尝试采用社会网络分析方法解决该问题。

1, 请描述该社会网络的节点和边，并画出该网络

该社会网络的节点可以包括借款人、单位、IP 地址等。其中，借款人是最主要的节点类型，因为我们需要对每个借款人进行信贷评估。单位和 IP 地址等节点类型可以作为辅助信息，帮助我们更好地理解借款人的行为和互动。

2, 请阐述什么网络特征可用于解决信贷评估问题，为什么

- 节点中心性：节点中心性是指网络中节点在连接关系中所处的中心位置。在社交网络中，节点中心性可以反映节点的权威性和影响力。如果一个节点的中心性较高，说明它与其他节点的连接较多，对其他节点的影响力也较大。在信贷评估中，我们可以利用节点中心性来判断借款人的影响力和权威性，从而评估其信用等级和还款能力。
- 紧密程度：紧密程度是指网络中节点之间的连接紧密程度。在社交网络中，紧密程度可以反映节点之间的互动和信任关系。如果两个节点之间的紧密程度较高，说明它们之间的联系较为紧密，信任程度也较高。在信贷评估中，我们可以利用节点之间的紧密程度来判断借款人之间的关系和互动程度，从而评估其信用等级和还款意愿。
- 社区结构：社区结构是指网络中节点的聚类 and 交互模式。在社交网络中，社区结构可以反映用户的兴趣爱好、职业背景、文化习惯等方面的相似性和聚集程度。在信贷评估中，我们可以利用社区结构来判断借款人之间的

相似性和风险水平，从而评估其信用等级和还款意愿。

这些网络特征之所以可以用于解决信贷评估问题，是因为它们可以帮助我们更好地理解借款人之间的关系和互动，从而更好地进行信贷评估。通过分析网络特征，我们可以更准确地判断借款人的影响力和权威性、信用等级和还款能力，以及风险水平和还款意愿。这些信息可以帮助银行做出更准确的贷款决策，降低风险并提高贷款回收率。

4.2. 知识图谱

4.2.1. 什么是知识图谱

知识图谱是一种具有图结构的知识库，通过边将节点连接在一起

- 知识图谱可以看做一类语义网络（semantic network）
- 在搜索引擎中，知识图谱可以提高用户搜索体验

知识图谱就是用图的形式将知识表示出来。图中的结点代表语义 实体或概念，边代表结点间的各 种语义关系。

4.2.2. 知识图谱中的常见概念

实体 - 知识图谱中的结点，人、地方、组织机构、概念等

属性 - 描述一类实体的特性，如身高、年龄等，属性也可以定义为 关系

关系 - 对应实体之间的关系，将实体链接起来，如姚明的国籍是中 国

4.2.3. 知识图谱的形式化表示

知识图谱的形式化表示



- 以结构化三元组的形式存储现实世界中的实体以及实体之间的关系，

$$G = (\mathcal{E}, \mathcal{R}, \mathcal{S})$$

$\mathcal{E}$ 实体集合， $\mathcal{R}$ 关系集合， $\mathcal{S}$ 三元组集合。

- 实体也可以是音频、视频等 【多模态知识图谱】

4.2.4. 为什么需要知识图谱

4.2.5. 知识图谱类型

通用知识图谱

- 语言知识图谱: WordNet; 中文知网词库 HowNet
- 常识知识图谱: Cyc/OpenCyc; ConceptNet
- 百科知识图谱 [众包]: Freebase; DBpedia; YAGO; Wikidata
- 领域知识图谱: 医学知识图谱 SIDER (Side Effect Resource); 电影知识图谱 IMDB (Internet Movie Database); 音乐知识图谱 (MusicBrainz)

4.2.6. 知识图谱生命周期

知识体系 构建,知识获取, 知识融合, 知识存储, 知识推理, 知识应用

4.2.7. 知识体系构建

目标: 构建一个本体对目标知识进行描述

- 在这个本体中, 需要定义出:
 - 知识的类别体系
 - 每个类别下所属的概念和实体
 - 某类概念和实体所具有的属性
 - 概念之间、实体之间的语义关系
- 常用工具: Protégé本体编辑器

4.2.8. 知识获取目标来源

目标: 从海量的文本数据中通过信息抽取的方式获取知识。

来源: 结构化数据、半结构化数据、非结构化文本数据。

4.2.9. 结构化数据半结构化数据

结构化数据:

数据库; 网页表格数据 (可通过固定模板直接获得)

- 数据质量较高; 长期存在, 不易随时间的变化而改变
- 优点: 置信度高, 数据质量可靠
- 缺点: 数据规模小, 不易获得

半结构化数据:

不能够通过固定的模板直接获得的结构化数据

- 相对于结构化数据较为松散, 具有结构多变、模式不统一的特点
- 优点: 置信度高, 规模比较大, 个性化信息丰富而且形式多样
- 缺点: 样式多变且含有噪声, 很难通过人工编写模板的方式进行抽取

非结构化文本数据：

- 邓丽君 1953 年出生于台湾省云林县”
- 当前互联网上大多数信息以非结构化的文本形式存储
 - 新闻；聊天内容；帖子；博文；微博等
- 知识抽取：实体识别；实体消歧；关系抽取；事件抽取

4.2.10. 知识融合

对不同来源、不同语言和不同结构的知识进行融合，从而对已有知识图谱进行补充：

对两个或多个异构知识体系进行融合，对相同的属性、类别、关系进行映射；
实体实例、关系实例进行融合；

4.2.11. 知识存储

知识图谱数据模型基于图论中图的定义，主要有两种图数据模型

– RDF 图 – 属性图

图数据库存储：Neo4j，具有完善的 图查询语言，支持图挖掘算法

4.2.12. 知识推理

- 由于处理数据的不完备性，所构建的知识图谱肯定存在知识缺失（实体缺失；关系缺失）
- 利用推理发现已有知识中隐含的知识
 - A 是 B 的爸爸，B 是 C 的爸爸 $\Rightarrow$ A 是 C 的爷爷
- 知识推理也可以直接用于相关应用任务，如推荐、自动问答系统等

4.2.13. 知识图谱中的典型推理任务

知识问答：

基于符号表示的知识库问答——映射自然语言表达式到知识图谱元素词汇
基于分布式表示的知识库问答

4.2.14. 知识图谱表示学习

- 知识图谱表示：张量矩阵 $X \in \mathcal{R}^{n \times f \times r}$

知识图谱表示学习，又称知识图谱嵌入 Knowledge Graph Embedding, KGE

-翻译距离模型（translational distance models） – 基于距离的评分函数

-语义匹配模型（semantic matching models） – 基于相似度的评分函数

翻译距离模型：利用基于距离的评分函数。通常是在通过关系进行翻译之后，用两个实体之间的距离来衡量一

4.2.15. TransE: 最具代表性的知识图谱嵌入


实体和关系都在同一空间
对于每一个三元组 (h, r, t) , TransE 希望:

$$\mathbf{h} + \mathbf{r} \approx \mathbf{t}$$

评分函数为:


$$f_r(\mathbf{h}, \mathbf{t}) = -\|\mathbf{h} + \mathbf{r} - \mathbf{t}\|_2^2$$

缺点: 复杂关系例如, 一对多、多对一、多对多关系不适用。



(a) TransE.

Translating Embeddings for Modeling Multi-relational Data, NIPS2013



TransH: 解决TransE在多元关系上的缺陷



- TransH引入超平面来代替原有关系向量, 可以让一个实体在不同的关系下拥有不同的表示
- TransH 首先将头实体向量 $\mathbf{h}$ 和尾实体向量 $\mathbf{t}$, 沿法线 $\mathbf{w}_r$ 投影到关系 r 对应的超平面上, 用 $\mathbf{h}_\perp$ 和 $\mathbf{t}_\perp$ 表示如下:

$$\mathbf{h}_\perp = \mathbf{h} - \mathbf{w}_r^T \mathbf{h} \mathbf{w}_r$$


$$\mathbf{t}_\perp = \mathbf{t} - \mathbf{w}_r^T \mathbf{t} \mathbf{w}_r$$

$\mathbf{w}_r^T \mathbf{h} = |\mathbf{w}| |\mathbf{h}| \cos \theta$ 表示 $\mathbf{h}$ 在 $\mathbf{w}_r$ 方向上投影的长度, $\mathbf{w}_r^T \mathbf{h} \mathbf{w}_r$ 即 $\mathbf{h}$ 在 $\mathbf{w}_r$ 上的投影

评分函数为:

$$f_r(\mathbf{h}, \mathbf{t}) = -\|\mathbf{h}_\perp + \mathbf{d}_r - \mathbf{t}_\perp\|_2^2$$

其中 $\mathbf{d}_r$ 是关系 r 的 translation vector



(b) TransH.

Knowledge Graph Embedding by Translating on Hyperplanes, AAAI2014

TransR: 实体和关系在不同的语义空间中

- TransR提出一种新的策略，将实体和关系分别映射到不同的语义空间中，分别为entity space（实体空间）和relation space（关系空间）
- 对于每个关系 r ，给定一个从实体空间到关系空间的映射矩阵 M_r

$$\mathbf{h}_r = \mathbf{h}M_r$$

$$\mathbf{t}_r = \mathbf{t}M_r$$

评分函数为:

$$f_r(\mathbf{h}, \mathbf{t}) = -\|\mathbf{h}_r + \mathbf{r} - \mathbf{t}_r\|_2^2$$

- 缺点：转换方式是空间投影，复杂度高。
- TransD**：对TransR的简化




Figure 1: Simple illustration of TransR.

Learning Entity and Relation Embeddings for Knowledge Graph Completion, AAAI2015

4.2.16. 语义匹配模型

语义匹配模型利用基于相似性的评分函数。通过匹配实体和关系在嵌入向量空间的潜在语义衡量三元组事实成立的可能性。

4.2.17. RESCAL 模型（双线性模型）

RESCAL模型（双线性模型）

- RESCAL又称双线性模型，该模型用向量表示实体，用矩阵表示关系，并通过自定义的打分函数捕捉三元组的内部交互。
- 核心思想**：三维张量分解

Given a $n \times n \times m$ tensor χ , each slice χ_k is factorized as:

$$\chi_k \approx AR_kA^T, \text{ for } k = 1, 2, \dots, m$$

A : a $n \times r$ matrix that contains the latent-component representation of the entities

R_k : is an asymmetric $r \times r$ matrix that models the interactions of the latent components in the k -th predicate

- 优化目标: $\min_{A, R_k} f(A, R_k) + g(A, R_k)$
模型重构 防止过拟合

$$f(A, R_k) = \frac{1}{2} \left(\sum_k \|\chi_k - AR_kA^T\|_F^2 \right) \quad g(A, R_k) = \frac{1}{2} \lambda \left(\|A\|_F^2 + \sum_k \|R_k\|_F^2 \right)$$





Figure 1: Tensor model for relational data. $E_1 \dots E_n$ denote the entities, while $R_1 \dots R_m$ denote the relations in the domain

A tensor entry $x_{ijk} = 1$ denotes the fact that there exists a relation (i -th entity, k -th predicate, j -th entity).



$$\mathbf{a}_{\text{Bill}}^T R_{\text{party}} \mathbf{a}_{\text{PartyX}} \approx \mathbf{a}_{\text{John}}^T R_{\text{party}} \mathbf{a}_{\text{PartyX}}$$

A Three-Way Model for Collective Learning on Multi-Relational Data, IJML 2011

4.2.18. 知识应用

智能搜索、自动问答、推荐、决策支持、电商知识图谱（智能导购 p 消费者精准画像 p 商品推荐）、金融知识图谱（企业关系发现 p 公司表现研究 p “组团骗贷”）、医疗健康知识图谱（p 新药发现 p 特定人群药物推荐 p 辅助医生决策）