

Hadoop与Spark

MapReduce Java开发环境配置



MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 我们把Hadoop安装在Linux上
 - ◆ 下面讲述如何在Windows上通过Eclipse进行MapReduce的程序开发
 - ◆ 配置好开发环境后
 - ◆ 我们使用Word Count 实例，来演示如何编译和运行MapReduce程序
 - ◆ 此外，我们还可以使用开发环境的调试功能，调试MapReduce程序

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 准备工作
 - ◆ 首先，在windows上安装JDK，运行jdk-8u101-windows-x64.exe(jdk 1.8.0_101)安装文件，完成安装。
 - ◆ 接着，在windows上安装Eclipse，把eclipse-java-mars-2-win32-x86_64.zip(eclipse Mars.2 Release 4.5.2)文件解压缩到D盘根目录下，完成安装，即把Eclipse安装在D:\eclipse目录下

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ (1) 从网址https://github.com/rucyang/hadoop.dll-and-winutils.exe-for-hadoop2.7.3-on-windows_X64下载hadoop-2.7.3-winutils.zip文件(2017年1月版本), 包含hadoop.dll & winutils.exe等文件。
 - ◆ (2) 从网址<https://github.com/huangqichuan/hadoop-eclipse-plugin-2.7.3>下载Hadoop Plugin, 即hadoop-eclipse-plugin-2.7.3.jar。注意, hadoop-eclipse-plugin-2.7.3.jar似乎有问题, 所以请用Google搜索并且下载hadoop-eclipse-plugin-2.6.0.jar。
 - ◆ (3) 把hadoop2.7.3.tar.gz解压到D盘的D:\hadoop-2.7.3目录下。
 - ◆ (4) 把hadoop-2.7.3-winutils.zip, 解压缩到d:\hadoop2.7.3\bin目录下

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ (5) 为Windows添加环境变量。右键点击我的电脑图标，选择“属性→高级系统设置→环境变量→系统变量→新建”等命令和菜单(界面元素)序列，添加如下变量

变量名	变量值
HADOOP_HOME	D:\hadoop-2.7.3
HADOOP_USER_NAME	root


- ◆ 在“系统变量”对话框里，选择Path环境变量，选择“编辑”，增加一项为d:\hadoop-2.7.3\bin。
- ◆ 重启windows，让新的Path变量起作用

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ (6) 把hadoop-eclipse-plugin-2.7.3.jar文件(应该使用hadoop-eclipse-plugin-2.6.0.jar)放在eclipse安装路径的plugins的目录里, 即D:\eclipse\plugins目录。
 - ◆ (7) 重启电脑, 然后重启Eclipse。

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ (8) 配置Eclipse。
 - ◆ 按照“Window - Preference- Hadoop Map/Reduce - Hadoop install directory”等命令和菜单(其它界面元素)序列，在对话框里设定Hadoop的安装路径，即为D:\hadoop-2.7.3。
 - ◆ 按照“Window - Perspective - Open Perspective - Other-MapReduce locations”等命令和菜单(其它界面元素)序列，打开Hadoop插件对话框。
 - ◆ DSF Master的参数设定为，IP地址192.168.31.129，端口9000
 - ◆ 请参考192.168.31.129机器上/opt/linuxsir/hadoop/etc/hadoop/core-site.xml文件的fs.defaultFS配置项。
 - ◆ MapReduce V2 Master的参数设定为，IP地址192.168.31.129，端口9032，
 - ◆ 请参考192.168.31.129机器上/opt/linuxsir/hadoop/etc/hadoop/yarn-site.xml文件的yarn.resourcemanager.address配置项



Define Hadoop location

Define the location of a Hadoop infrastructure for running MapReduce applications.

General Advanced parameters

Location name: hadoop

Map/Reduce(V2) Master: DFS Master

Host: 192.168.31.129

Port: 9032

User name: root

☒ Use M/R Mas

Host: 192.168.31.129

Port: 9000

SOCKS proxy

☐ Enable SOCK

Host: host

Port: 1080

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ (8) 配置Eclipse

注意：Hadoop MapReduce已经从1.0版发展到2.0版，两者在配置上有很大差别。

Hadoop 2.2.0版本已经取消了JobTracker，它把JobTracker分解为两个组件即resourcemanager和YARN调度器。

在配置文件mapred-site.xml文件里的“mapred.jobtracker.address”配置项，已经被yarn-site.xml文件里的“yarn.resourcemanager.address”配置项所替代，即：

```
<property>  
    <name>yarn.resourcemanager.address</name>  
    <value>hd-master:9032</value>  
</property>
```

Define Hadoop location

Define the location of a Hadoop infrastructure for running MapReduce applications.

General Advanced parameters

Location name: hadoop

Map/Reduce(V2) Master: DFS Master

Host: 192.168.31.129

Port: 9032

User name: root

Use M/R Mas: ☒

Host: 192.168.31.129

Port: 9000

SOCKS proxy

☐ Enable SOCK

Host: host

Port: 1080

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ (9) 新建项目WordCount.java, 具体代码请参考4.14节
 - ◆ (10) 新建 Run Configuration并运行Java 程序。
 - ◆ 选择Run菜单的Run Configurations菜单项, 在对话框里新建一个Run Configuration, 类型为Java Application。设定main class为WordCount的主类。设定arguments如下:
 - ◆ hdfs://192.168.31.129:9000/input
 - ◆ hdfs://192.168.31.129:9000/output

覃雄派,陈跃国.Hadoop与Spark入门.清华大学出版社, 2023.

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ 为了运行上述Word Count程序，需要把HDFS上的/output目录删除(如果存在的话)
 - ◆ 可以使用如下命令删除HDFS的/output目录

\\在Linux终端运行如下命令

```
cd /opt/linuxsir/hadoop/bin  
./hdfs dfs -ls /output  
./hdfs dfs -rm /output/*  
./hdfs dfs -rmdir /output
```

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 配置过程
 - ◆ 运行Word Count程序，选择Run As菜单的 Run Configurations菜单项，在对话框里选择建立好的Run Configuration，点击Run按钮即可
 - ◆ 如果要调试Word Count程序，需要建立Debug Configuration，办法和建立Run Configuration类似。然后，选择Debug As菜单的 Debug Configurations菜单项，在对话框里选择建立好的Debug Configuration，点击Debug按钮即可

pause



MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 问题1: **log4j**没有提示
 - ◆ 在项目根目录下, 新建log4j.properties文件, 内容如下

```
log4j.rootLogger=debug, stdout
log4j.appender.stdout=org.apache.log4j.ConsoleAppender
log4j.appender.stdout.layout=org.apache.log4j.PatternLayout
log4j.appender.stdout.layout.ConversionPattern=%-4r [%t] %-5p %c %x -
%m%n
```

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
 - ◆ 问题2: **hdfs:// CentOS7SMB:9000**解析错误
 - ◆ 修改C:\Windows\System32\drivers\etc\hosts文件, 添加内容如下

```
192.168.31.129 hd-master
192.168.31.130 hd-slave1
192.168.31.131 hd-slave2
192.168.31.129 CentOS7SMB
```

- ◆ 为了能够编辑C:\Windows\System32\drivers\etc\hosts文件, 需要对该文件进行授权。选择该文件, 按右键, 然后按照“属性→安全→编辑→勾选写入”等命令和菜单序列操作即可

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
- ◆ 问题3:NativeIO出问题
- ◆ 从源代码包(需要从Hadoop网站下载hadoop-2.7.3-src.tar.gz文件), 并且解压缩出org.apache.hadoop.io.nativeio.NativeIO.java文件, 把这个文件放到项目里面, 做如下修改, 即直接return true, 不做任何检查

```
public static boolean access(String path, AccessRight
desiredAccess) throws IOException {
    //@FIX 2020-08-08 by PAI
    return true;
    //return access0(path, desiredAccess.accessRight());
}
```

MapReduce Java开发环境配置

- ◆ MapReduce Java开发环境配置
- ◆ 软件下载

