

数据挖掘的两种建模形式

- 预测建模
- 描述建模

预测建模

- 预测建模的目的则是根据观察到的对象特征值预测它的其他特征值。这里的特征有时也称为变量或属性

预测模型： 分类

- 在预测模型中，一个变量被表达成其他变量的函数
- 可以把预测建模的过程看作是学习一种映射或函数 $Y=f(X;\theta)$ 。其中：
 - f 是模型结构的函数形式
 - θ 是 f 中的未知参数。
 - X 通常被称为输入变量，是一个 p 维向量，代表观察到的对象的 p 个属性值。
 - Y 通常被称为响应变量，是一个标量，代表预测的结果

预测模型： 分类

- 在函数 $Y=f(X;\theta)$ 中：
 - 如果 Y 是数量型变量，那么学习从向量 X 到 Y 的映射的过程叫做回归
 - 如果 Y 是范畴型变量，则叫做分类

预测模型


- 在函数 $Y=f(X;\theta)$ 中：
 - 如果 Y 是**范畴型**变量，那么学习从向量 X 到 Y 的映射的过程叫做**分类**

$f($



$) = \text{“小狗”}$

$f($



$) = \text{“我正在上课”}$

$f($



$) = \text{移到“第6行第7列”}$

(棋盘上每一个位置都是一个类别，共 19×19 个类别)

$f($



$) = \text{核酸检测“阴性”}$

预测模型

- 在函数 $Y=f(X;\theta)$ 中:
 - 如果Y是数量型变量，那么学习从向量X到Y的映射的过程叫做回归

$$f(\begin{matrix} \text{电影导演} \\ \text{电影主要演员} \\ \text{电影编剧} \\ \text{电影摄影} \\ \text{电影制片} \\ \text{电影市场} \end{matrix}) = \text{票房 (*亿)}$$

预测模型

- 从学习一个 p 维向量 X 到 Y 的映射这个角度来讲，分类和回归这两种任务都可以看作是函数逼近(function approximation)问题。

预测建模的训练数据

- 由 n 对 (X, Y) 组成。每对数据中的向量 $X(i)$ 和目标值 $Y(i)$ 都是从已知数据中观察得到的 ($0 \leq i \leq n$)。
- 预测建模就是：根据训练数据拟合出模型 $Y = f(X; \theta)$ ，该模型可以在给定输入向量 X 和模型 f 的参数 θ 的情况下预测出 Y 的值。

预测模型的拟合过程

- 需要完成以下事情：
 - 1) 确定模型 f 的结构；
 - 2) 确定参数 θ 的值。 θ 值是通过在数据集上最小化（或最大化）一个评分函数来确定的，而搜索最佳 θ 值的过程就是优化的过程，通常是数据挖掘算法的核心部分。

因此，从算法组件的角度出发，模型拟合的过程实际上也就是要确定模型结构、评分函数以及搜索优化策略。

用于预测的模型结构

- 由于事先不知道模型 $f(\mathbf{X};\theta)$ 的形式，为 f 本身选择一个合适的函数形式本身是非常具有挑战性的。
- 回归模型和分类模型都建立在很多相同的数学和统计基础之上，用于其中一种任务的模型通常也可以应用于另一种任务。

用于分类的预测模型


- 判别模型
- 概率模型

判别模型

- 判别模型的输入是输入向量 X ，输出是响应变量 Y 。 Y 的取值为 $\{C_1, C_2, \dots, C_m\}$ ，其中 C_i 表示类别。

判别模型


- 例如，当维数 $p=1$ 时，判别模型实际上是二维空间中的分段直线。在一定的区域内，直线的取值为 $C_i (0 \leq i \leq m)$ 。




- 当维数 $p=2$ 时，判别模型实际上是三维空间中的一个分段曲面。
- 仅当输入变量 X 的分量 X_1 和分量 X_2 共同构成的平面 (X_1, X_2) 位于一定区域时，该曲面的取值为 $C_i(0 \leq i \leq m)$ 。
- 取值为 C_i 的所有区域的联合称为 C_i 类的决策区域。意思是，只要输入变量 X 落入这个区域，它的类别就被预测为 C_i 。

- 在判别模型中，分类的主要任务是要确定各个类别的决策区域
- 或者说，我们所感兴趣的是不同类别之间的边界。


- 和回归的情况类似，可以对类别间边界的函数形式做一个简单的假定。
- 例如，可以用线性边界将X空间分割成不相交的决策区域，每个区域对应一个类别。



- 也可以将线性决策边界分段组合起来



决策树的判别模型



概率模型

- 分类的概率建模是要针对每一个类别 C_i ，估计一种分布或密度函数 $p(X|C_i, \theta_i)$ ，其中 θ_i 是该函数的参数，它反映了 C_i 类的主要特征。

概率模型

- 例如，对于多变量的实数值数据，可以假定每个类别的模型结构都是多元正态分布，而且参数 θ_i 代表每个类的均值（位置）和方差（范围）特征。
- 如果各个均值离得足够远，而且方差足够小，则各个类在输入空间中可以被很好地分割开来，从而使得分类的准确性最高

用于预测的评分函数


- 对于分类，普遍使用的是误分类率
- 对于回归，普遍使用的评分函数是误差平方和

用于回归的预测模型

- 线性回归模型
- 非线性回归模型
- 分段线性模型
- 逻辑回归模型

线性回归模型

- $\hat{Y} = a_0 + a_1X_1 + a_2X_2 + \dots + a_pX_p$
- $\hat{Y}$ 代表的是模型的预测值，而 Y 代表实际观察到的值。



非线性回归模型

- $\hat{Y} = a_0 + a_1X_1 + a_2X_2^2 + a_3X_3^3$
- 令 $Z_1 = X_1$, $Z_2 = X_2^2$, $Z_3 = X_3^3$

$$\hat{Y} = a_0 + a_1Z_1 + a_2Z_2 + a_3Z_3$$

[https://www.cnblogs.com/wuliyt
Taotao/p/10837533.html](https://www.cnblogs.com/wuliytTaotao/p/10837533.html)

- 线性回归是用线性函数拟合数据，用 **Mean Square Error (MSE)** 计算损失 (**Loss**)，然后用梯度下降法找到一组使 **MSE** 最小的权重。

- **lasso 回归和岭回归 (ridge regression)** 其实就是在标准线性回归的基础上分别加入 **L1 和 L2 正则化 (regularization)** 。
- **L1 正则化** 会比 **L2 正则化** 让线性回归的权重更加稀疏，即使得线性回归中很多权重为 0，而不是接近 0。或者说，**L1 正则化 (lasso)** 可以进行 **feature selection**，而 **L2 正则化 (ridge)** 不行。

线性回归——最小二乘

线性回归 (linear regression) , 就是用线性函数 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ 去拟合一组数据

$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$ 并使得损失 $J = \frac{1}{n} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2$ 最小。

线性回归的目标就是找到一组 $(\mathbf{w}^*, b^*)$, 使得损失 J 最小。

线性回归的拟合函数 (或 hypothesis) 为:

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b \quad (1)$$

cost function (mse) 为:

$$\begin{aligned} J &= \frac{1}{n} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2 \end{aligned} \quad (2)$$

Lasso回归和岭回归

Lasso 回归和岭回归 (ridge regression) 都是在标准线性回归的基础上修改 cost function, 即修改式 (2), 其它地方不变。

Lasso 的全称为 least absolute shrinkage and selection operator, 又译最小绝对值收敛和选择算子、套索算法。

Lasso 回归对式 (2) 加入 L1 正则化, 其 cost function 如下:

$$J = \frac{1}{n} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{w}\|_1 \quad (3)$$

岭回归对式 (2) 加入 L2 正则化, 其 cost function 如下:

$$J = \frac{1}{n} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{w}\|_2^2 \quad (4)$$

Lasso回归和岭回归的同和异:

- 相同:
 - 都可以用来解决标准线性回归的过拟合问题。
- 不同:
 - lasso 可以用来做 feature selection, 而 ridge 不行。或者说, lasso 更容易使得权重变为 0, 而 ridge 更容易使得权重接近 0。
 - 从贝叶斯角度看, lasso (L1 正则) 等价于参数 w 的先验概率分布满足拉普拉斯分布, 而 ridge (L2 正则) 等价于参数 w 的先验概率分布满足高斯分布。具体参考博客 [从贝叶斯角度深入理解正则化 -- Zxdon](#)。

也许会有个疑问，线性回归还会有过拟合问题？

加入 L1 或 L2 正则化，让权值尽可能小，最后构造一个所有参数都比较小的模型。因为一般认为参数值小的模型比较简单，能适应不同的数据集，也在一定程度上避免了过拟合现象。

可以设想一下对于一个线性回归方程，若参数很大，那么只要数据偏移一点点，就会对结果造成很大的影响；但如果参数足够小，数据偏移得多一点也不会对结果造成什么影响，一种流行的说法是『抗扰动能力强』。具体参见博客 [浅议过拟合现象\(overfitting\)以及正则化技术原理](#)。

为什么 lasso 更容易使部分权重变为 0 而 ridge 不行?

lasso 和 ridge regression 的目标都是 $\min_{\mathbf{w}, b} J$, 式 (3) 和 (4) 都是拉格朗日形式 (with KKT条件), 其中 λ 为 KKT 乘子, 我们也可以将 $\min_{\mathbf{w}, b} J$ 写成如下形式:

- lasso regression:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2 \\ \text{s.t.} \quad & \|\mathbf{w}\|_1 \leq t \end{aligned} \tag{5}$$

- ridge regression:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2 \\ \text{s.t.} \quad & \|\mathbf{w}\|_2^2 \leq t \end{aligned} \tag{6}$$

式 (5) 和 (6) 可以理解为, 在 $\mathbf{w}$ 限制的取值范围内, 找一个点 $\hat{\mathbf{w}}$ 使得 mean square error 最小, t 可以理解为正则化的力度, 式 (5) 和 (6) 中的 t 越小, 就意味着式 (3) 和 (4) 中 λ 越大, 正则化的力度越大。

以 $\mathbf{x} \in R^2$ 为例, 式 (5) 中对 $\mathbf{w}$ 的限制空间是方形, 而式 (6) 中对 $\mathbf{w}$ 的限制空间是圆形。因为 lasso 对 $\mathbf{w}$ 的限制空间是有棱角的, 因此 $\arg \min_{\mathbf{w}, b} \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2$ 的解更容易切在 $\mathbf{w}$ 的某一个维为 0 的点。如下图所示:





Fig. 1 中的坐标系表示 $\mathbf{w}$ 的两维，一圈又一圈的椭圆表示函数

$J = \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2$ 的等高线，椭圆越往外， J 的值越大， $\mathbf{w}^*$ 表示使得损失 J 取得全局最优的值。使用 Gradient descent，也就是让 $\mathbf{w}$ 向着 $\mathbf{w}^*$ 的位置走。如果没有 L1 或者 L2 正则化约束， $\mathbf{w}^*$ 是可以被取到的。但是，由于有了约束 $\|\mathbf{w}\|_1 \leq t$ 或 $\|\mathbf{w}\|_2^2 \leq t$ ， $\mathbf{w}$ 的取值只能限制在 Fig. 1 所示的灰色方形和圆形区域。当然调整 t 的值，我们也能扩大这两个区域。

等高线从低到高第一次和 $\mathbf{w}$ 的取值范围相切的点，即是 lasso 和 ridge 回归想要找的权重 $\hat{\mathbf{w}}$ 。

lasso 限制了 w 的取值范围为有棱角的方形，而 ridge 限制了 w 的取值范围为圆形，等高线和方形区域的切点更有可能在坐标轴上，而等高线和圆形区域的切点在坐标轴上的概率很小。这就是为什么 lasso (L1 正则化) 更容易使得部分权重取 0，使权重变稀疏；而 ridge (L2 正则化) 只能使权重接近 0，很少等于 0。

正是由于 lasso 容易使得部分权重取 0，所以可以用其做 feature selection，lasso 的名字就指出了它是一个 selection operator。权重为 0 的 feature 对回归问题没有贡献，直接去掉权重为 0 的 feature，模型的输出值不变。

对于 ridge regression 进行 feature selection, 你说它完全不可以吧也不是, weight 趋近于 0 的 feature 不要了不也可以, 但是对模型的效果还是有损伤的, 这个前提还得是 feature 进行了归一化。

References

- [1] Tibshirani, R. (1996). Regression Shrinkage and Selection Via the Lasso. Journal Of The Royal Statistical Society: Series B (Methodological), 58(1), 267-288. doi: 10.1111/j.2517-6161.1996.tb02080.x
- [2] Lasso算法 -- 维基百科
- [3] 机器学习总结(一): 线性回归、岭回归、Lasso回归 -- 她说巷尾的樱花开了
- [4] 从贝叶斯角度深入理解正则化 -- Zxdon
- [5] 浅议过拟合现象(overfitting)以及正则化技术原理 -- 闪念基因

分段线性模型


- 另一个对基本的线性回归模型进行推广的方法，就是假定响应变量 Y 是输入向量 X 的局部线性函数。
- 该模型在 p 维空间的不同区域，具有不同的函数形式，这便是分段线性模型。

分段线性模型

- 分段线性模型是通过把简单模型分段组合在一起构建起来的相对复杂的模型。
- 这种模型结构的参数既包括各个区域上的局部函数的参数，又包括各个区域的边界。

分段线性模型

- 当 $p = 1$ 时，该模型表示由 k 个不同的线段逼近的一条曲线。不同线段末端可以连接，也可以不连接。因此，曲线可以是连续的，也可以不连续。



分段线性模型

- 当 $p > 1$ 时，该模型表示由多个超平面逼近的一个曲面。该曲面可以连续，也可以不连续。