



模型评估与选择

- 有监督学习的目的是：为了得到好的模型预测性能
- 在现实任务中，要处理一个问题，往往有多种算法（模型）可以选择，即使是同一个模型，也有多种（超）参数可以选择
- 模型评估与选择
 - 评估模型的预测性能
 - 选择预测性能最好的模型

模型评估与选择

- 如何获得测试结果?  数据集划分
- 如何评估性能优劣?  评价指标、偏差与方差
 -  数值角度
 -  理论分析

有监督学习

- 什么是有监督学习?
- 模型评估与选择
 - 数据集划分
 - 评价指标
 - 偏差和方差

数据集划分---为何要进行数据集划分?

目标: 获得最终模型

方法: 参数调节 (parameter tuning)

- 算法参数 (超参数) → 人工设定候选值, 例如学习率
- 模型参数 → 通过学习产生, 例如W

调参: 调整超参数

调参思路:

- 不同超参产生若干模型, 然后基于评估方法进行选择
- 参数调得好不好对最终性能有关键影响

在什么数据上评估?

超参数调整的一个具体方法:

- 对每个参数选择一个范围和变化步长
- 例如在[0,0.2]范围内以0.05为步长
- 要评估的候选参数值是5个
- 从这5个值中产生选定值

四类数据：训练集、测试集、验证集、新数据

NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

训练集（训练过程中用来确定参数）

NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	no
Merisa	Associate Prof	7	no
George	Professor	5	yes
Joseph	Assistant Prof	7	yes

测试集（训练结束后测试过程中用来评估准确率）

NAME	RANK	YEARS	TENURED
Lisa	Assistant Prof	3	no
tracy	Prof	4	yes
Gates	Assistant Professor	5	yes
max	Assistant Prof	10	no

验证集（训练过程中用来确定超参数）

NAME	RANK	YEARS	TENURED
Jeff	Professor	4	?


新数据（测试结束后推理过程中用）

四类数据：训练集、测试集、验证集、新数据


- 训练集（Training Set）：用于模型训练，通过训练集确定模型的参数
 - 训练误差（或者 经验误差）
- 验证集（Validation Set）：用于模型选择，通过验证集确定模型的超参数
 - 验证误差
- 测试集（Test Set）：测试已训练好模型的精确度
 - 测试误差
- 新数据（Unseen Data）：应用已训练好的模型，进行预测（学习的目标）
 - 泛化误差

过拟合问题 (Overfitting)

- 为了使算法具有较好的泛化性，通常需要进行足够多的训练
- 但是，过度训练会导致过拟合（和欠拟合具有同样的危险!）



训练一定时间，达到较好拟合



继续训练，导致过拟合

过拟合问题 (Overfitting)


- 所以，在快要过拟合时，算法需要停止训练
- 需要在训练的不同时间节点 (timestep)，计算算法的泛化性能
- 这时，不能使用测试集（留作算法全部训练结束后测试模型用）
- 需要另一个数据集合：验证集。用来计算算法在训练过程中的泛化性能，选择验证误差最小时的参数作为最优参数（从而选择出最好的模型）

验证集 vs. 测试集

类别	验证集	测试集
是否被训练到	否	否
作用	用于调超参数，监控模型是否发生过拟合（以决定是否停止训练）	为了评估最终模型泛化能力
使用次数	多次使用，以不断调参	仅仅一次使用
缺陷	模型在一次次重新手动调参并继续训练后所逼近的验证集，可能只代表一部分非训练集，导致最终训练好的模型泛化性不够	测试集为了具有泛化代表性，往往数据量比较大，测试一轮要很久，所以往往只取测试集的其中一小部分作为训练过程中的验证集

数据集划分---为何要进行数据集划分?

训练/验证: 是为了**确定算法和算法的超参数**, 确定了这些之后, 需要再利用整个源数据集进行训练, 这次训练所得的**模型 (参数)** 才是最终模型, 也即提交给用户进行测试的模型



数据集划分---留出法

11

1. 留出法---数据集D拆分成互斥的两个集合T、V: $D = T \cup V, T \cap V = \emptyset$

➤ 在T (Train) 上训练模型, 在V (Validation) 上验证模型

(1)如何划分保证数据分布的一致性? => “**分层采样**”

采用“分层采样”的方法来保留类别比例。如原始数据集有100个样本, 假设训练集占60个, 验证集占40个。若训练集中正例反例各30个 (比例为1:1), 那么验证集中就应该正例反例各20个 (同样保持1:1的比例)

(2)如何保证随机划分的稳定性? => “**多次随机划分**”


- 单次使用评估结果不稳定、随机性较大
- 若干次随机划分、重复进行实验评估、取平均值作为评估结果
 - 1) 进行100次随机划分,
 - 2) 每次随机产生一个训练/验证集
 - 3) 得到100个结果
 - 4) 平均值作为最终结果

数据集划分---交叉验证法

12

2 交叉验证法

交叉验证法是将数据集 D 划分成 k 个大小相似的互斥子集，每个子集 D_i 都使用分层采样尽可能保持数据分布的一致性，即： $D = D_1 \cup D_2 \cup \dots \cup D_k, D_i \cap D_j = \emptyset (i \neq j)$



称为“k-折交叉验证”；

k的取值会影响结果的稳定性与保真性，k的取值一般为10。

数据集划分---交叉验证法

13

2 交叉验证法

如何保证随机划分的稳定性?

- k折交叉验证随机使用不同的划分重复p次
- 最终的评估结果是p次k折交叉验证的均值
- 例如常见的有10次10折交叉验证。（如此就要做100次训练与验证）

数据集划分---留一法

14

3 留一法

数据集 D 中有 m 个样本，当 $k=m$ 时，则得到了交叉验证的一个特例：留一法

优点：

- 留一法不受随机样本划分的干扰
- 使用的训练集比原始数据集 D 只少了1个样本
- 留一法训练的模型与使用原始数据 D 训练得到的模型很相似
- 评估结果会相对准确。

缺点：

- 在数据集比较大的时候，训练 m 个模型的开销十分大；
- 并且留一法也未必永远比其他方法更准确。

数据集划分---自助法

15

4 自助法 (Bootstrap Sampling)

优点:

- 在训练集较少, 难以有效划分训练与验证集;
- 能从初始数据集中产生多组不同的训练集, 对集成学习等方法有好处


缺点:

- 产生的数据集改变了数据集的原始分布, 引起估计偏差
- 数据集足够时, 优先选用留出法与交叉验证法

步骤:

- 给定包含 m 个样本的数据集 D
- 有放回采样: 每次随机从 D 中挑选一个样本, 将其放入 D' , 再将其放回初始数据集 D 中 (该样本在下次采样时仍有可能被采到)
- 重复执行 m 次后, 得到包含 m 个样本的数据集 D'

是不是所有的样例都会被随机取到呢?



样本 m 次没有取到的概率 $\left(1 - \frac{1}{m}\right)^m$ 其近似值为 $\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368$

可将 D' 用作训练集, $D-D'$ 用作验证集

- 实际评估的模型与期望评估的模型都使用 m 个训练样本
- 仍有数据总量约1/3的、没在训练集中出现的样本用于验证

数据集划分---几种方法的比较

16

测试方法	数学表达	注意事项	优缺点
留出法 (hold-out)	$D = T \cup V$ $T \cap V = \emptyset$	分层采样 (stratified sampling) 重复试验取平均评估结果	验证集小, 评估结果方差较大 训练集小, 评估结果偏差较大
交叉验证法 (cross validation)	$D = D_1 \cup \dots \cup D_k$ $D_i \cap D_j = \emptyset (i \neq j)$	p 次 k 折交叉验证	稳定性和保真性很大程度取决于 k
留一法 (Leave-One-Out, LOO)	$D = D_1 \cup \dots \cup D_k$ $D_i \cap D_j = \emptyset (i \neq j)$ $k = D $	每次使用一个样本验证	不受随机样本划分方式影响 数据量大时计算量大
自助法 (bootstrapping)	$ T = D $ $V = D \setminus T$	可重复采样/有放回采样	数据集较小有用 改变初始数据集的分布, 引入偏差

- 什么是有监督学习?
 - 决策树分类回顾
 - 决策树的模型解读
- 模型评估与选择
 - 数据集划分
 - 评价指标
 - 偏差和方差

评价指标---评估模型性能的指标

18

衡量模型泛化能力的指标

➤ 算法和数据对模型效果的影响---偏差和方差

理论分析

➤ 参数对模型效果的影响---评价指标

数值角度

在有监督学习中，要评估学习器（比如分类器）的性能，需要把
预测结果 $f(x_i)$ 与真实标记 y_i 进行比较。

模型评估-混淆矩阵

- 无论测试集有多大，都需要一种方法来评估训练后得到的模型是好是坏
- 对回归问题，可以采用误差平方和
- 对分类问题，可以采用混淆矩阵
 - 行是真实标签，列是预测标签
 - 对角线上的数字是预测正确的情况
 - 如，有2个样本，真实是C3，被错误预测为C1
 - 用对角线上的数值之和除以总样本数，则得准确率 (accuracy)

Outputs			
	C_1	C_2	C_3
C_1	5	1	0
C_2	1	4	1
C_3	2	0	4

模型评估-二元分类混淆矩阵

- 除了accuracy，还可以用更多的方式来度量模型的准确性
- 对于二元分类问题，混淆矩阵可以简化为右图：
 - 同样，对角线数值之和除以全部样本数为accuracy

	True Positive	True Negative
Positive	True Positives	False Positives
Negative	False Negatives	True Negatives

$$\text{Accuracy} = \frac{\#TP + \#TN}{\#TP + \#FP + \#TN + \#FN}$$

- 除此之外，还可以用更多度量进一步解释分类结果的好坏

- Sensitivity = TPR (true positive rate) = recall
- Specificity (true negative rate) = 1 - FPR (false positive rate)
- Precision: #FP=0时最好，表示预测为正例的可信度
- Recall: #FN=0时最好，正例被预测出来的比例

$$\text{Sensitivity} = \frac{\#TP}{\#TP + \#FN}$$

$$\text{Specificity} = \frac{\#TN}{\#TN + \#FP}$$

$$\text{Precision} = \frac{\#TP}{\#TP + \#FP}$$

$$\text{Recall} = \frac{\#TP}{\#TP + \#FN}$$

二元分类混淆矩阵---举例

21

有100张照片，其中，猫的照片有60张，狗的照片是40张。

输入这100张照片进行二分类识别，找出这100张照片中的所有的猫。

识别结果的混淆矩阵

		预测值	
		Positive	Negative
实际值	Positive	TP=40	FN=20
	Negative	FP=10	TN=30

正例 (Positives) : 猫; 负例 (Negatives) : 狗

查全与查准---举例

22

项目	符号	猫狗的例子
识别出的正例	TP+FP	40+10=50
识别出的负例	TN+FN	30+20=50
总识别样本数	TP+FP+TN+FN	50+50=100
识别对了的正例与负例	真正例+真负例 =TP+TN	40+30=70
识别错了的正例与负例	伪正例+伪负例 =FP+FN	10+20=30
实际总正例数量	真正例+伪负例 =TP+FN	40+20=60
实际总负例数量	真负例+伪正例	30+10=40

		预测值	
		Positive	Negative
实际值	Positive	TP=40	FN=20
	Negative	FP=10	TN=30

正确率 (Accuracy) $= (TP + TN) / S$
TP + TN = 70, S = 100, 则正确率为:
Accuracy $= 70 / 100 = 0.7$

查准、精度 (Precision) $= TP / (TP + FP)$
TP = 40, TP + FP = 50。
Precision $= 40 / 50 = 0.8$

查全、召回率 (Recall) $= TP / (TP + FN)$
TP = 40, TP + FN = 60。则召回率为:
Recall $= 40 / 60 = 0.67$

查准率和查全率之间的矛盾

23

- 查准率高时，查全率往往偏低；
- 查全率高时，查准率往往偏低。
- 对于癌症预测例子：
 - 假设非常有把握时才预测病人得癌症 ($y=1$)
 - 即将**预测为正例的可信度设置为1**，
 - 导致高精度度，低召回率；
 - 假设不希望将太多的癌症病人被错分（避免假负例---本身得了癌症，误分为没得癌症）
 - 即将**正例被预测出来的比例设置为1**，
 - 导致高召回率，低精确度；

模型评估-F1度量

- 除了accuracy, 还可以用更多的方式来度量模型的准确性
- 对于二元分类问题, 混淆矩阵可以简化为右图:
 - 同样, 对角线数值之和除以全部样本数为accuracy

	True Positive	True Negative
Positive	True Positives	False Positives
Negative	False Negatives	True Negatives

$$\text{Accuracy} = \frac{\#TP + \#FP}{\#TP + \#FP + \#TN + \#FN}$$

$$\text{Sensitivity} = \frac{\#TP}{\#TP + \#FN}$$

$$\text{Specificity} = \frac{\#TN}{\#TN + \#FP}$$

$$\text{Precision} = \frac{\#TP}{\#TP + \#FP}$$

$$\text{Recall} = \frac{\#TP}{\#TP + \#FN}$$

- 除此之外, 还可以用更多度量进一步解释分类结果的好坏
 - Sensitivity = TPR (true positive rate) = recall
 - Specificity (true negative rate) = 1 - FPR (false positive rate)
 - Precision: #FP=0时最好
 - Recall: #FN=0时最好
 - F1: #FP和#FN很难同时最小, 同时兼顾则 (#FP+ #FN)/2最小时最好**

$$F_1 = 2 \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = \frac{\#TP}{\#TP + (\#FN + \#FP)/2}$$

模型评估-F1度量

F1度量：基于查准率与查全率的**调和平均**定义的。调和平均F1值越大越好。

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

$$\frac{1}{F1} = \frac{1}{2} \left(\frac{1}{P} + \frac{1}{R} \right)$$

F β ：加权调和平均---可以表达对查准率/查全率的不同偏好。

$$F_{\beta} = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R},$$

调和平均 (harmonic mean) 又叫倒数平均

$$H_n = \frac{n}{\frac{1}{a_1} + \frac{1}{a_2} + \dots + \frac{1}{a_n}}$$

其中 β ($\beta > 0$) 度量了**查全率**对查准率的相对重要性。

$\beta = 1$ 时退化为标准的 F1;

$\beta > 1$ 时查全率有更大影响;

$0 < \beta < 1$ 时查准率有更大影响。

查全占的比重较大

查准占的比重较大

模型评估-F1度量

基于查准率与查全率的**调和平均**F1: $\frac{1}{F1} = \frac{1}{2} \left(\frac{1}{P} + \frac{1}{R} \right)$

优点:


- (1) 避免极端, 例如出现查全率或查准率为1而另一个为0
- (2) F1综合P和R的结果, 取值在[0,1]之间变化, 当F1越高模型性能越好。

应用: 对查准率和查全率的**重视度不同**

- 商品推荐系统**: 更希望推荐内容是用户感兴趣的, 此时**查准率更重要**
- 逃犯信息检索系统**: 更希望少漏掉逃犯, 此时**查全率更重要**

模型评估-ROC曲线

- 除了评估一个二元分类模型的好坏之外，有时还需要对两个模型进行比较
 - 如具有两组不同参数的同一个模型
 - 或者是两个完全不同的模型
- 每次计算出两个重要量的值FPR（假正例率）、TPR（真正例率），分别作为横、纵坐标，即得到ROC曲线



$$TPR = \frac{TP}{TP + FN}$$

有多少真正的正例预测准确,例如,
有多少癌症患者被预测为恶性肿瘤
(所有正例为分母)

$$FPR = \frac{FP}{TN + FP}$$

有多少反例被预测为正例,例如, 有
多少健康的病人, 被预测为癌症
(所有负例为分母)

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

模型评估-ROC曲线


- ROC曲线

- 算法每运行一次，获得ROC曲线上一点
 - 可以使用不同数据集（如K折交叉验证法）运行多次，得到曲线上的多个点
- (0, 1)位置的模型最理想
- (1, 0)位置的模型最差
- 所以，学习算法运行结果越靠近左上角，越好

在医学中，判断有病的样本


➤尽量发现有病的样本，第一个指标TPR，纵轴的值要越高越好。

➤把没病的样本不要误诊，第二个指标FPR，横轴的值要越低越好。




模型评估-AUC

- 通常用ROC曲线下面的面积AUC (Area Under the ROC Curve) 来评估二元分类模型的好坏
- AUC越大越好




模型评估-AUC


- AUC例子




最理想分类器，两个类别完全分离



比较好的分类器，两个类别少量重叠



最差的随机分类器，两个类别无法区分



反向分类器，两个类别全部预测反，可再次取反以获得正确结果

模型评估-Unbalanced Data

- 前面介绍的评估指标都假设：正样本和负样本的数量一样多
- 很多情况下该假设不成立
 - 这时，可计算：balanced accuracy = (sensitivity + specificity) / 2
 - 或者，采用更准确的Matthew's Correlation Coefficient (MCC)

$$MCC = \frac{\#TP \times \#TN - \#FP \times \#FN}{\sqrt{(\#TP + \#FP)(\#TP + \#FN)(\#TN + \#FP)(\#TN + \#FN)}}$$

当分母中某一分项为0时，整个分母设为1

模型评估-多元分类模型

- 当将二元分类器的评估指标用于多元分类器时，可以使用One vs ALL 的方法，为N个类别绘制N条AUC、ROC曲线
- for example, If you have **three** classes named **X**, **Y**, and **Z**, you will have one ROC for X classified against Y and Z, another ROC for Y classified against X and Z, and the third one of Z classified against Y and X.

有监督学习

- 什么是有监督学习?
- 模型评估与选择
 - 数据集划分
 - 评价指标
 - 偏差和方差


偏差和方差---具象化理解

方差 Variance:

描述的是预测值的变化范围，离散程度，也就是离其期望值的距离。方差越大，数据的分布越分散，如右图右列所示


偏差 Bias:

描述的是预测值（估计值）的期望与真实值之间的差距。偏差越大，越偏离真实数据，如右图第二行所示



偏差与方差---泛化误差分析

对回归任务，泛化误差可通过“偏差-方差分解”拆解为：



偏差与方差---泛化误差分析

36

- 泛化误差可分解为偏差、方差和噪声之和。

$$E(f; D) = \mathbb{E}_D[(f(\mathbf{x}; D) - y_D)^2] = \dots = \text{bias}^2(\mathbf{x}) + \text{var}(\mathbf{x}) + \varepsilon^2$$

- 方差度量了**数据扰动**所造成的影响, $\mathbb{E}_D[(f(\mathbf{x}; D) - \mathbb{E}_D[f(\mathbf{x}; D)])^2]$

- 偏差度量了**学习算法**的偏离程度, $(\mathbb{E}_D[f(\mathbf{x}; D)] - y)^2$

- 噪声刻画了**学习问题本身**的难度, $\mathbb{E}_D[(y_D - y)^2]$

- y_D 为数据集中的标记, y 是 $\mathbf{x}$ 的真实标记;

- $f(\mathbf{x}; D)$ 为数据集D上训练的模型对 $\mathbf{x}$ 的预测输出, $\bar{f}(\mathbf{x})$ 为算法的期望预测输出
 $\bar{f}(\mathbf{x}) = \mathbb{E}_D[f(\mathbf{x}; D)]$

偏差与方差---泛化误差分析

37

期望输出与真实标记的差别称为偏差，即 $\text{bias}^2(\mathbf{x}) = (\bar{f}(\mathbf{x}) - y)^2$

为方便讨论，假定噪声期望为0，也即 $\mathbb{E}_D[y_D - y] = 0$ 。误差分解

$$\begin{aligned} E(f; D) &= \mathbb{E}_D [(f(\mathbf{x}; D) - y_D)^2] \\ &= \mathbb{E}_D [(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}) + \bar{f}(\mathbf{x}) - y_D)^2] \\ &= \mathbb{E}_D [(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2] + \mathbb{E}_D [(\bar{f}(\mathbf{x}) - y_D)^2] \\ &\quad + \mathbb{E}_D [2(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))(\bar{f}(\mathbf{x}) - y_D)] \quad \leftarrow \text{因为 } \bar{f}(\mathbf{x}) = \mathbb{E}_D[f(\mathbf{x}; D)] \text{, 所以红色部分第一项为0} \\ &= \mathbb{E}_D [(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2] + \mathbb{E}_D [(\bar{f}(\mathbf{x}) - y_D)^2] \\ &= \mathbb{E}_D [(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2] + \mathbb{E}_D [(\bar{f}(\mathbf{x}) - y + y - y_D)^2] \\ &= \mathbb{E}_D [(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2] + \mathbb{E}_D [(\bar{f}(\mathbf{x}) - y)^2] + \mathbb{E}_D [(y - y_D)^2] \\ &\quad + 2\mathbb{E}_D [(\bar{f}(\mathbf{x}) - y)(y - y_D)] \quad \leftarrow \text{因为, 假定噪声期望为零, 即 } \mathbb{E}_D[y_D - y] = 0 \text{, 所以红色部分第二项为0} \\ &= \mathbb{E}_D [(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2] + (\bar{f}(\mathbf{x}) - y)^2 + \mathbb{E}_D [(y - y_D)^2] \end{aligned}$$


泛化误差可分解为方差、偏差与噪声之和

偏差和方差---具象化理解

方差、偏差和模型复杂度

随着模型复杂度的增加，方差会逐渐增大，偏差会逐渐减小


在虚线处，差不多是模型复杂度的最恰当的选择，其“偏差”和“方差”也都适度，才能“适度拟合”




偏差和方差---偏差-方差窘境

一般而言，偏差与方差存在冲突：

- ❑ 训练不足时，学习器拟合能力不强，偏差主导
- ❑ 随着训练程度加深，学习器拟合能力逐渐增强，方差逐渐主导
- ❑ 训练充足后，学习器的拟合能力很强，方差主导



偏差和方差---具象化理解



训练集误差和验证集误差近似时： 偏差/欠拟合
验证集误差远大于训练集误差时： 方差/过拟合

高方差（过拟合）处理方法

1. 获得更多的训练数据

使用更多的训练数据是解决过拟合问题最有效的手段，更多的样本能够让模型学习到更多更有效的特征，减小噪声的影响。

2. 降维

丢弃一些特征。可以是手工选择，或者使用一些选择的算法（例如PCA）。

3. 正则化

正则化(regularization)的技术，保留所有的特征，但是减少参数的大小（magnitude），它可以改善或者减少过拟合问题。

4. 集成学习方法

集成学习是把多个模型集成在一起，来降低单一模型的过拟合风险。

高偏差（欠拟合）的处理

1. 添加新特征

当特征不足或者现有特征与样本标签的相关性不强时，模型容易出现欠拟合。通过挖掘组合特征等新的特征，往往能够取得更好的效果。

2. 增加模型复杂度

简单模型的学习能力较差，通过增加模型的复杂度可以使模型拥有更强的拟合能力。例如，在线性模型中添加高次项，在神经网络模型中增加网络层数或神经元个数等。

3. 减小正则化系数

正则化是用来防止过拟合的，但当模型出现欠拟合现象时，则需要有针对性地减小正则化系数。