



数据仓库



本讲内容


- 1 从数据库到数据仓库(WHY)
- 2 什么是数据仓库(WHAT)
- 3 数据仓库中的数据组织(HOW)
- 4 数据库体系化环境
- 5 小结



1 从数据库到数据仓库 (Why)


数据处理的两两种基本类型

- 操作型(与业务活动关联)
- 分析型(与决策活动关联)



数据处理的两类基本类型


- 操作型处理也叫事务处理，是指对数据库联机的日常操作，通常是对一个或一组记录的查询和修改，主要是为企业的特定应用服务的，人们关心的是响应时间，数据的安全性和完整性。
- 分析型处理则用于管理人员的决策分析。例如：**DSS, EIS**和 multidimensional analysis 等，经常要访问大量的历史数据。
- 两者之间的巨大差异使得操作型处理和分析型处理的分离成为必然。



传统的数据库技术


传统的数据库技术是以单一的数据资源,即数据库为中心,进行从事务处理、批处理,到决策分析等各种类型的数据处理工作。

然而,不同类型的数据处理有着其不同的处理特点,以单一的数据组织方式进行组织的数据库并不能反映这种差异,满足不了数据处理多样化的要求。




从数据库到数据仓库 (Why)

- 数据库在操作型应用中取得了巨大的成功
 - ❖ 数据库已经成为几乎所有信息系统的基础
 - ❖ 在事务处理方面的应用获得了巨大的成功
 - ❖ 经历了三代的发展
 - ❖ 造就了四位图灵奖获得者
 - ❖ 1973年: Charles Bachman ——网状数据库
 - ❖ 1981年: Edgar Codd ——关系型数据库
 - ❖ 1998年: Jim Gray ——事务处理
 - ❖ 2014年: Michael Stonebraker ——商用数据库
 - ❖ 积累了大量的业务数据(财富)




从数据库到数据仓库 (Why)

- 分析型应用(**DSS**)
 - 数据库三级模式体系结构告诉我们,任何数据库应用都是建立在外模式之上的.
 - 传统数据库的即席查询功能就可以支持**DSS**的需求
 - **DSS**的重点放在模型与方法上,没有考虑在数据库管理系统层面上的支持



从数据库到数据仓库 (Why)


- 事务处理环境不适宜**DSS**应用的原因
 - (1) 事务处理和分析处理的性能特性不同
 - (2) 数据集成问题
 - (3) 数据动态集成问题
 - (4) 历史数据问题
 - (5) 数据的综合问题



(1) 事务处理和分析处理的性能特性不同


用户的行为模式

- ❖ 在事务处理环境中，数据的存取操作频率高而每次操作处理的时间短
- ❖ 在分析处理环境中，**DSS**应用需要运行时间长，消耗系统资源多




(2) 数据集成问题

- **DSS需要的数据:**
 - 全面、集成
 - 相关数据收集得越完整 结果就越可靠
 - 企业内部数据
 - 企业外部数据
 - 竞争对手的数据
 - ...




数据集成问题

- 事务处理的数据：
 - 与本部门业务有关当前数据
 - 对整个企业范围内的集成应用考虑少
 - 当前企业内数据的状况
 - 分散而非集成——这是事务处理环境所固有的
 - 事务处理应用产生的细节数据不能成为统一的整体
 - **DSS**应用必须在应用程序中进行数据集成




数据集成问题

- 数据分散的原因
 - 事务处理应用的分散
 - “蜘蛛网”问题
 - 数据不一致问题
 - 外部数据和非结构化数据



1) 事务处理应用的分散

- 当前企业事务处理应用间是独立的
- 原因
 - 设计方面:
 - 为减少系统开发费用和加快开发进度, 所采用的设计方案仅仅针对当前问题, 并且尽可能简单而“有效”
 - 设计方案不能保证对以后新出现的问题继续有效



事务处理应用的分散


- 原因 (续)
 - 经济方面:
 - 经费有限
 - 系统的设计与实现采用“滚雪球”方式
 - 优先为企业的关键业务活动建立**MIS**
 - 然后再逐步建立其他业务的**MIS**
 - 历史和地理方面:
 - 大公司分散在各地
 - 企业兼并
- **DSS**应用要对分散数据进行集成，向分析人员提供统一的数据视图


2) “蜘蛛网” 问题

DSS应用的“抽取程序”：

数据库/文件 → 用户1.抽取程序 → 数据库/文件 →

用户2.抽取程序 → 数据库/文件






“蜘蛛网” 问题

- 问题:

- 1) 时间基准不统一
- 2) 抽取算法不相同
- 3) 抽取级别也不相同
- 4) 参考不同的外部数据

- 结果:


导致对同一问题的分析,
不同节点会产生不同的结果



3) 数据不一致问题

- 多个应用间数据不一致的常见形式:
 - 同一字段有不同数据类型
 - 同一字段具有不同的名字
 - 同名字段，不同含义

数据统一是一项很繁重的工作




4) 外部数据和非结构化数据

- 外部数据源


- 刊物发布的统计数据
- 业界的技术报告
- 市场比较和分析报告
- 股票行情

- 外部数据源的特点： 非结构化数据




数据集成问题

- 数据分散的原因小结
 - 事务处理应用的分散
 - “蜘蛛网”问题
 - 数据不一致问题
 - 外部数据和非结构化数据




数据集成问题

- **DSS对数据集成有迫切需要**
 - 数据集成是一项十分繁杂的工作，都交给应用程序完成会大大增加程序员的负担。
 - 如果每做一次分析，都要进行一次这样的集成，将会导致极低的处理效率。
- **DSS对数据集成的迫切需要是数据仓库技术出现的最重要动因**




(3) 数据动态集成问题

- 静态集成：
集成后不再与数据源发生联系
- 动态集成：
以一定的周期（例如24小时）刷新集成数据



(4) 历史数据问题

- 事务处理系统中的数据
 - 当前数据
 - 短期数据
- 决策分析的数据
 - 必须要历史数据




(5) 数据的综合问题

■ DSS系统的分析对象

- 一般不对细节数据进行分析
 - 细节数据数量太大，会严重影响分析的效率
 - 太多的细节数据影响分析人员的注意力
- 分析前需要对细节数据进行不同程度的综合

■ 事务处理系统的对象

- 只关心细节数据，不具备综合能力
- 综合是一种数据冗余，需要加以限制



结论

- 事务处理环境不适宜DSS应用的原因

- (1) 事务处理和分析处理的性能特性不同

- (2) 数据集成问题

- (3) 数据动态集成问题


- (4) 历史数据问题

- (5) 数据的综合问题

- 结论

- 在操作型环境中直接构建分析型应用是一种失败的尝试

- 需要将分析型处理数据和操作型处理数据分离



从数据库到数据仓库


1 从数据库到数据仓库

2 什么是数据仓库

3 数据仓库中的数据组织

4 数据库体系化环境

5 小结




2 什么是数据仓库 (What)

不同的定义:


“数据仓库是作为DSS服务基础的分析型DB, 用来存放大容量的只读数据, 为制定决策提供所需的信息。”

“数据仓库是与操作型系统相分离的、基于标准企业模型集成的、带有时间属性的 (即与企业定义的时间区段相关)、面向主题及不可更新的数据集合。”



操作型数据和分析型数据的区别

操作型数据	分析型数据
细节的	综合的，或提炼的
在存取瞬间是准确的	代表过去的数据
可更新	不更新
操作需求事先可知道	操作需求事先不知道
生命周期符合SDLC	完全不同的生命周期
对性能要求高	对性能要求宽松
一个时刻操作一单元	一个时刻操作一集合
事务驱动	分析驱动
面向应用	面向分析
一次操作数据量小	一次操作数据量大
支持日常操作	支持管理需求




2 什么是数据仓库 (What)

数据仓库数据的四个基本特征:

- 数据仓库的数据是面向主题的
- 数据仓库的数据是集成的
- 数据仓库的数据是不可更新的
- 数据仓库的数据是随时间不断变化的


数据仓库定义:

数据仓库就是一个用以更好地支持企业或组织的决策分析处理的、面向主题的、集成的、不可更新的、随时间不断变化的数据集合




2.1 主题与面向主题

- 数据仓库的第一个特征
 - 数据仓库中的数据是面向主题进行组织的
- 什么是主题
 - 主题是在较高层次上将企业信息系统中的数据综合、归类并进行分析利用的抽象
 - 逻辑意义：对应企业中某一宏观分析领域所涉及的分析对象



主题与面向主题

- 什么是较高层次
 - 是相对面向应用的数据组织方式而言的
 - 是指按照主题进行数据组织的方式具有更高的数据抽象级别
- 面向主题的数据组织方式的特点
 - 是对分析对象的数据的一个完整、一致的描述
 - 能完整、统一地刻画各个分析对象所涉及企业的各项数据, 以及数据之间的联系



面向主题与面向应用的数据组织方式

例：“会员制”商场

按照业务处理要求，建立的数据库模式：

采购子系统：

订单(订单号，供应商号，总金额，日期)


订单细则(订单号，商品号，类别，单价，数量)

供应商(供应商号，供应商名，地址，电话)

销售子系统：

顾客(顾客号，姓名，性别，年龄，文化程度，地址，电话)

销售(员工号，顾客号，商品号，数量，单价，日期)



面向主题与面向应用的数据组织方式

库存管理子系统:

领料单 (领料单号, 领料人, 商品号, 数量, 日期)

进料单 (进料单号, 订单号, 进料人, 收料人, 日期)


库存 (商品号, 库房号, 库存量, 日期)

库房(库房号, 仓库管理员, 地点, 库存商品描述)

人事管理子系统:

员工(员工号, 姓名, 性别, 年龄, 文化程度, 部门号)

部门(部门号, 部门名称, 部门主管, 电话)



传统的面向应用数据组织方式的特点


1. 面向应用进行数据组织, 需要对企业中相关的组织、部门等进行详细调查, 收集数据库的基础数据及其处理的过程。

- 调查的重点

- 数据
- 处理

- 组织数据的依据


- 企业的部门组织结构
- 企业各部门的业务活动特点



传统的面向应用数据组织方式的特点

2. 数据组织应反映一个企业内数据的动态特征


- 要表达每个部门的实际业务处理的数据流程
 - 输入
 - 处理
 - 输出
- 组织数据的方式
 - 按照实际应用即业务处理流程来组织
- 组织数据的目标
 - 提高OLTP应用的速度和准确性



传统的面向应用数据组织方式的特点

3. 数据库模式与实际的业务处理流程中所涉及的单据或文档具有对应关系


- 从而可以较好在这些数据库模式上建立起各项实际的应用处理
- 在有些应用中, 这种数据组织方式只是对企业业务活动所涉及的数据的存储介质的改变, 即从纸介质到磁介质的转变



传统的面向应用数据组织方式的特点

4. 没有体现数据库这一概念提出的原本意图： 数据与数据处理的分离

- 没有将数据从数据处理或应用中抽象出来, 组织成一个和具体的应用独立的数据世界
- 后果
 - 描述同一客观实体的数据与不同的应用逻辑捆绑在一起而变得不统一;
 - 一个完整的客观实体的数据分散在不同的数据库模式中;



传统的面向应用数据组织方式的特点


- 结论

- 缺点

- 抽象程度不够高, 数据与应用没有完全分离

- 优点

- 能较好地将数据库模式和企业的现实业务活动对应起来, 从而具有很好的操作性
 - 便于将企业原来的各项业务从手工处理的方式向计算机处理方式的转变
 - 可以较好地支持OLTP




面向主题的数据组织

步骤:

- 1、抽取主题: 按照分析的要求来确定
- 2、确定每个主题所应包含的数据内容

例如: 商场商品采购

- ① 在**OLTP**数据库中, “订单” “订单细则” “供应商” 三个数据库模式清晰完整地描述了一笔采购业务所涉及的数据内容, 这是面向应用来进行数据组织的方式;
- ② 在数据仓库中, 主要是进行数据分析处理, 商品采购时的分析活动主要是要了解各供应商的情况, “供应商” 是采购分析时的分析对象。所以不需要组织象“订单” 和“订单细则” 这样的数据库模式, 因为它们包含的是纯操作型的数据; 但是仅仅只用**OLTP**数据库的“供应商” 中的数据又是不够的, 因而要重新组织“供应商” 这么一个主题。



商场主题：供应商、商品、顾客等

商品：

商品固有信息：商品号，商品名，类别，颜色等；

商品采购信息：商品号，供应商号，供应价，供应日期，供应量等；

商品销售信息：商品号，顾客号，售价，销售日期，销售量等；

商品库存信息：商品号，库房号，库存量，日期等；

供应商：


供应商固有信息：供应商号，供应商名，地址，电话等；

商品供应信息：供应商号，商品号，供应价，供应日期，供应量等；

顾客：


顾客固有信息：顾客号，顾客名，性别，年龄，文化程度，住址，电话等；

顾客购物信息：顾客号，商品号，售价，购买日期，购买量等；



面向应用到面向主题的转变过程


1. 丢弃不必要的、不适于分析的信息
2. 把分散在各子系统中有关某一主题的信息组织起来，形成一个完整一致的描述




面向应用到面向主题的转变过程

3. 不同的主题之间**内容重叠**：反映主题之间的直接联系
- A. 主题之间的重叠是逻辑上的重叠, 不是同一数据内容的重复物理存储
 - B. 主题之间的重叠是细节级上的重叠, 因为在不同的主题中的综合方式是不同的。
 - C. 主题间的重叠并不是两两重叠。


面向应用到面向主题的转变过程






主题在数据仓库的实现

- 基于多维数据库
- 基于关系数据库




基于多维数据库

- 以多维数组形式存储数据
- 遇到的问题
 - 数据稀疏



基于关系数据库

- 一个主题用一组关系表表示
- 每个关系表都含有一个公共码键，是主属性
- 一个主题的所有表通过公共码键统一联系起来



基于关系数据库示例

例:

主题: 商品

公共码键: 商品号

商品表(商品号, 商品名, 类型, 颜色 ...)

/* 描述的是商品的固有信息*/

采购表1(商品号, 供应商号, 供应日期, 供应价, 供应日期, ...)

/* 描述的是商品的采购细节 */

采购表2(商品号, 时间段, 采购总量, ...)

/* 某时间段内商品采购信息 */

.....

采购表n(商品号, ..., ...)

/* 时间段不等的采购综合表 */

销售表1(商品号, 顾客号, 销售日期, 售价, 销售量, ...)

/* 描述的是商品的销售细节信息 */

销售表2(商品号, 时间段, 销售总量, ...)

/* 某时间段内商品销售信息 */

.....

销售表n(..., ...)

/* 时间段不等的销售综合表 */

库存表1(商品号, 库房号, 库存量, 日期, ...)

/* 描述的是商品的库存细节信息 */

库存表2(商品号, 库房号, 库存量, 月份, ...)


/* 每月月底的商品库存信息 */

...

库存表n(商品号, 库房号, ..., ...)


/* 时点不同的商品库存信息*/

...




主题中表的存储

- 同一主题的不同的表：存储在磁盘、磁带、光盘等不同介质中
 - ❖ 年代久远的、细节、查询概率低存贮在廉价慢速设备上
 - ❖ 近期的、综合、查询概率高保存在快速存储设备上




面向主题的数据组织

- 主题域：一个完备的分析领域
 - ① 独立性：主题域必须具有独立内涵,要求有明确的界限，规定某项数据是否该属于“商品”主题。
 - ② 完备性：主题内包含任何对该主题对象的分析处理要求的一切内容



面向主题的数据组织


- 主题的数据组织是一个在较高层次上对数据的抽象, 可以独立于数据的处理逻辑
 - 因而可以在此数据环境上方便地开发新的分析型应用
 - 同时, 这种独立性也是建设企业全局数据库所要求的, 所以面向主题不仅是适用于分析型数据环境的数据组织方式, 同时也是适用于建设企业全局数据库的数据组织方式



2.2特征二：数据是集成的


■ 集成的含义

- 从原有的分散的数据库数据中抽取、清洗得到
- 从原有的分散的数据库数据中综合得到
- ❖ 集成是数据仓库建设中最关键、最复杂的步骤




特征二：数据是集成的

- 集成需要解决的问题
 - 统一源数据中所有矛盾之处
 - 字段的同名异义
 - 字段的异名同义
 - 单位不统一
 - 字长不一致
 -
 - 进行数据综合和计算
 - 综合时间：抽取数据时生成
数据仓库内部生成




特征三：数据是不可更新的

- 数据仓库的数据
 - 存放的是历史数据
 - 基本操作是数据查询, 一般情况下并不进行修改操作
 - 数据一旦超过存储期限, 可以删除




特征三：数据是不可更新的

- 数据仓库管理系统
 - 数据管理功能简化
 - 数据查询要求提高
 - 提高大数据量的查询速度
 - 查询界面友好性
 - 数据的直观表示




特征四： 随时间不断变化的

- 数据仓库中的数据不可更新是针对应用而言的
- 数据仓库的用户进行分析处理时是不进行数据更新操作的
- 数据仓库的数据是随时间的变化不断变化的




特征四：随时间不断变化的

- 数据仓库的数据随时间的变化
 - 数据仓库随时间变化不断增加新的数据内容
 - 数据仓库随时间变化不断删去旧的数据内容
 - 操作型环境中一般只保存有**60-90**天的数据
 - 数据仓库中则需要保存较长时限的数据（如**5-10**年）
 - 数据仓库中包含有大量的跟时间有关的综合数据
 - 经常按照时间段进行综合
 - 隔一定的时间片进行抽样
 - 随着时间的变化不断地进行重新综合
- 数据仓库数据的码键都包含时间项，以标明数据的历史时期



从数据库到数据仓库


- 1 从数据库到数据仓库
- 2 什么是数据仓库
- 3 数据仓库中的数据组织
- 4 数据库体系化环境
- 5 小结




3 数据仓库中的数据组织

- 3.1 数据仓库中的数据组织
- 3.2 粒度与分割
- 3.3 数据仓库的数据组织形式
- 3.4 数据仓库的数据追加

3.1 数据仓库中的数据组织




数据仓库的数据组织结构




数据仓库中的数据组织

- 数据仓库中的数据存在着不同的综合级别
 - 早期细节级
 - 当前细节级
 - 轻度综合级
 - 高度综合级
- 粒度：数据的不同综合级别
 - 粒度越大、表示细节程度越低、综合程度越高。
 - 级别的划分是根据粒度进行的

数据仓库中的数据组织



数据仓库的数据组织结构的一个例子




数据仓库中的元数据

元数据(metadata)： 关于数据的数据


第一种： 从操作型环境向数据仓库环境转换而建立的元数据。包含： 所有源数据项名、属性及其在数据仓库中的转换

第二种： 与终端用户的多维商业模型 / 前端工具之间建立映射的DSS元数据




3 数据仓库中的数据组织

- 3.1 数据仓库中的数据组织
- 3.2 粒度与分割
- 3.3 数据仓库的数据组织形式
- 3.4 数据仓库的数据追加



3.2 粒度与分割

- 粒度
- 分割



1. 粒度

粒度分为两种形式:

1) 对数据仓库中的数据综合程度高低的一个度量

- 粒度越小, 细节程度越高, 综合程度越低
- 粒度大小影响数据仓库效率、能回答询问的种类

“张三在某时某地是否给李四打过电话?”


“张三去年共打了几次长途电话”

“某地区今年长途与普通电话费用之比”

“今年长途 / 普通电话费用增长率”

“预测未来长途 / 普通电话费用变化趋势”


- 数据仓库是多粒度的, 不同的粒度回答不同的查询



1. 粒度

2) 样本数据库

- 根据采样率的高低来划分粒度：以一定的采样率从细节数据或轻度综合数据中抽取的一个子集
- 用处：代替源数据进行模拟分析
- 抽样的方法：随机抽取
- 优点：
 - 高效率
 - 源数据量很大的情况下，抽样数据可以大大下降，
 - 分析结果误差极小
 - 有助于抓住主要因素和主要矛盾




1. 粒度

- 实际：两种形式的粒度都存在

例：“商品”主题表的划分：

销售综合表和采购综合表是属于第一种形式的粒度
(时间段上信息的综合)


库存信息的不同表：则属于第二种形式粒度划分
(不同时点上的粒度)



2. 分割

- 分割：指将数据分散到各自的物理单元中去以便能分别独立处理
- 分片：数据分割后的数据单元
- 分割的目的：提高效率

例如：对于某种相关性的数据集合的分析是最常见的
将具有相关性的数据组织在一起,会提高效率




2. 分割

- 分割标准：根据实际情况确定
 - 1 易于重构、索引、重组、恢复、监控和顺序扫描
 - 2 按日期、地域或业务领域
 - 3 按多个分割标准的组合


例子：

	健康保险	生命保险	事故保险
2018	分片1	分片2	分片3
2019	分片4	分片5	分片6
2020	分片7	分片8	分片9



3 数据仓库中的数据组织


- 3.1 数据仓库中的数据组织
- 3.2 粒度与分割
- 3.3 数据仓库的数据组织形式
- 3.4 数据仓库的数据追加




3.3 数据仓库的数据组织形式

- 简单堆积文件
 - 它将由数据库中提取并加工的数据逐一积累存储
- 轮转综合文件
 - 数据存储单位被分为若干个级别
 - 轮转记录--综合
 - 优点：结构简捷，数据量较简单堆积结构减少
 - 缺点：损失数据细节。越久远的数据，细节损失越多

3.3 数据仓库的数据组织形式




简单堆积文件



轮转综合文件

图1-4 数据仓库基本数据结构




3.3 数据仓库的数据组织形式

- 简化直接文件

- 间隔一定时间的数据库快照，类似简单堆积文件
(按一定的时间间隔对数据库的采样)

- 连续文件

- 1) 两个连续的简化直接文件 → 比较他们的不同
→ 连续文件
- 2) 连续文件+新的简单文件 → 新的连续文件



数据库快照

一月份顾客表

姓名	顾客号	地址
张平	C960100	北京
王英	C960101	天津
王宾	C960102	上海
李强	C960103	重庆
.....		

图1-5 生成简化直接文件

连续文件 — 两个连续的简化直接文件 → 比较他们的不同
 → 连续文件

1月份顾客表

姓 名	顾 客 号	地 址
张平	C960100	北京
王英	C960101	天津
王宾	C960102	上海
刘仲	C960104	重庆

2月份顾客表

姓 名	顾 客 号	地 址
张平	C960100	北京
王英	C960101	沈阳
王宾	C960102	上海
刘仲	C960104	大连

比较不同

1-2月份顾客表

姓 名	顾 客 号	时 间	地 址
张平	C960100	1-2月	北京
王英	C960101	1-1月	天津
王英	C960101	2-2月	沈阳
王宾	C960102	1-2月	上海
刘仲	C960104	1-1月	重庆
刘仲	C960104	2-2月	大连

连续文件+新的简单文件 → 新的连续文件

1-2月份顾客表

姓名	顾客号	时间	地址
张平	C960100	1-2月	北京
王英	C960101	1-1月	天津
王英	C960101	2-2月	沈阳
王宾	C960102	1-2月	上海
刘仲	C960104	1-1月	重庆
刘仲	C960104	2-2月	大连


3月份顾客表

姓名	顾客号	地址
张平	C960100	北京
王宾	C960102	上海
刘仲	C960104	大连


比较不同

1-3月份顾客表

姓名	顾客号	时间	地址
张平	C960100	1-3月	北京
王英	C960101	1-1月	天津
王英	C960101	2-2月	沈阳
王宾	C960102	1-3月	上海
刘仲	C960104	1-1月	重庆
刘仲	C960104	2-3月	大连




各种文件结构的最终实现： 关系数据库中是“表”



3 数据仓库中的数据组织

- 3.1 数据仓库中的数据组织
- 3.2 粒度与分割
- 3.3 数据仓库的数据组织形式
- 3.4 数据仓库的数据追加




3.4 数据仓库的数据追加

数据追加：数据仓库的数据初装完成后，再向数据仓库输入数据的过程

追加内容：上次数据追加后在**OLTP**数据库中变化了的数据

变化数据的捕捉途径：

- 时标方法
- **DELTA**文件
- 前后映象文件
- 日志文件




1. 时标方法

- 时标方法

- 如果数据含有时标, 对新插入或更新的数据记录, 加更新时的时标

- 问题

- 许多数据库中的数据并不含有时标



2. DELTA文件

- **DELTA文件方法**


- 由应用生成**DELTA**文件，记录应用所改变的所有内容

- **优点**

- 避免了扫描整个数据库，效率比较高


- **问题**

- 生成**DELTA**文件的应用不普遍
 - 更改应用代码，应用在生成新数据时可自动将其记录下来
 - 应用成千上万，且修改代码十分繁琐，很难实现



3. 前后映像文件

- 前后映像文件的方法
 - 抽取数据到数据仓库之后, 本次将抽取数据之前, 对数据库分别作一次快照, 比较两幅快照的不同, 确定追加的数据
- 问题
 - 占用大量资源, 影响系统性能



4. 日志文件


■ 优点

- 利用DB的固有机制，数据只限于日志文件，不用扫描整个数据库

■ 缺点


- 原来日志文件的格式是依据DB系统的要求设计的。要进行改进

如：对一个记录的多次更新，日志文件将全部变化过程都记录下来，而数据仓库，只要最终结果



从数据库到数据仓库


- 1 从数据库到数据仓库
- 2 什么是数据仓库
- 3 数据仓库中的数据组织
- 4 数据库体系化环境
- 5 小结



4 数据库体系化环境

什么是数据库体系化环境？


在一个企业或组织内，由各面向应用的OLTP数据库、以及各级面向主题的数据仓库所组成的完整的数据环境；并在这个数据环境上建立和进行一个企业或部门的从联机事务处理到企业管理决策的所有应用。



4 数据库体系化环境

数据库体系化环境分为两个部分:

操作型环境和分析型环境, 分别为操作型处理和分析型处理这两类不同的数据处理服务



4 数据库体系化环境

数据库体系化环境的构成:

1. 各级数据库和数据仓库
 2. 各面向应用的数据库之间、各级数据仓库之间、以及数据库与数据仓库之间的界限和相互联系有合理划分和明确描述
 3. 在不同的数据库或数据仓库上的数据处理和应用有明确的定义和划分
 4. 软硬件资源及其人员的配置有明确规定
- 体系化环境是一个结构清晰、层次分明、联系明确、可有序运行的有机的整体

4.1 四层体系化环境


层次的体系化环境:

操作型环境


全局级数据仓库

部门级的局部仓库

个人级数据仓库



数据仓库在体系化环境中的位置



4.1 四层体系化环境

操作型环境存放：细节的操作型数据，服务于高性能事务处理


全局级数据仓库：存放细节数据、导出数据

部门级局部仓库：一般存放导出数据

个人级数据仓库：数据一般是暂时存放，用于启发式分析。

多层次体系化环境的优点：

- 1 数据的抽取方向,保证了不会出现“蜘蛛网”的情况
- 2 四层体系化环境与企业实际的部门组织结构相对应



基层管理

中层管理

高层管理

操作管理

管理和控制

战略决策

日常业务处理

业务处理
简单分析

复杂的分析加工

操作型环境

部门级的
局部数据仓库

个人级数据仓库
全局级数据仓库

- 3 体系化环境的层次反映了数据与应用逻辑的抽象程度
层次越多, 体系化环境也就越丰满, 也就越能细致地
反映企业中整个数据组织与处理

4.2 数据集市 (Data Mart)





图1-9 数据集市



4.2 数据集市 (Data Mart)

建设多级数据仓库：自顶向下 / 自底向上

数据集市的概念：自底向上建设多级数据仓库

从最关心的部分开始，先以最少的投资，完成企业当前需求，获取最快的回报，然后再不断扩充，不断完善


数据集市：部门级数据仓库

小型的、面向部门或工作组

数据集市组织：一般以业务的分类来组织

数据仓库的主题来组织

数据的地理分布来组织 (分布式数据仓库)



4.2 数据集市 (Data Mart)

组织原则：应有全局的观点


数据集市在扩展后可以集成为全企业级的数据仓库

数据集市的特点：

管理较容易：结构简单，数据增长时易管理


较灵活：不同的数据集市可以分布在不同的
物理平台上或逻辑的分布于同一物理平台上

可独立实施：企业人员可以快速获取信息



从数据库到数据仓库

- 1 从数据库到数据仓库
- 2 什么是数据仓库
- 3 数据仓库中的数据组织
- 4 数据库体系化环境
- 5 小结



5 小结


■ 主要内容

- 从数据库发展到数据仓库的必然性
- 数据仓库的基本概念、基本内容

■ 基本要点

1. 数据仓库与数据库的差别和联系

- 数据仓库：操作型处理和分析型处理区分开来
- 数据仓库与数据库是互补的。数据仓库的产生不是要替代原来的OLTP数据库。数据仓库与数据库一起组成一个企业的数据库体系化环境




5 小结

2. 数据仓库数据的四个基本特征

- 面向主题的
- 集成的
- 不可更新的
- 随时间不断变化的

3. 数据仓库的数据组织

- 了解数据仓库数据的抽取、集成过程
- 掌握粒度、分割和数据追加等概念



5 小结

4. 理解数据库体系化环境的概念