

# 数据方体的存储

---

# 数据方体的存储

---

- 数据方体的存储具有两种形式，一种是采用多维数组的形式存储，另一种是采用传统的关系表的形式存储。
- 通常将基于多维数组存储的OLAP实现方式称之为MOLAP (Multi-dimensional OLAP)
- 而将基于关系表存储的OLAP实现方式称之为ROLAP (Relational OLAP) 。

# MOLAP

---

- MOLAP使用多维数组存储数据方体。
- 由于多维数组的特点，可以实现对多维数据的快速访问。
- 但是，并非维间的每种组合都会产生具体的值，实际上，许多组合没有具体值，是空的或者值为零。

因此，**MOLAP**必须具有高效的稀疏数据处理能力，能略过零元、缺失和重复数据。

# 多维数组存储的优点

- 假设有一组商品冰箱、彩电和空调，它们在东北、西北和华北三个地区的销售数据如下图所示。

| 产品名称 | 地区 | 销售量   |
|------|----|-------|
| 冰箱   | 东北 | 5 0   |
| 冰箱   | 西北 | 6 0   |
| 冰箱   | 华北 | 1 0 0 |
| 彩电   | 东北 | 4 0   |
| 彩电   | 西北 | 7 0   |
| 彩电   | 华北 | 8 0   |
| 空调   | 东北 | 9 0   |
| 空调   | 西北 | 1 2 0 |
| 空调   | 华北 | 1 4 0 |

用关系表存储

|    | 东北  | 西北    | 华北    |
|----|-----|-------|-------|
| 冰箱 | 5 0 | 6 0   | 1 0 0 |
| 彩电 | 4 0 | 7 0   | 8 0   |
| 空调 | 9 0 | 1 2 0 | 1 4 0 |

二维数组存储

# 优点1

---

- 多维数组表达清晰，占用的存储空间少
  - 在多维数组中，从纵向看，可以清楚的看出每种商品的销售额，从横向看，可以得到每个地区的销售额。
  - 而以关系表存储这些数据，只能满足方便的查看产品或地区的销售额，很难兼顾两方面。
  - 以关系表存放多维数据，维成员需要重复存放，如，冰箱要重复三次。而多维数组不需要存放坐标值，因此，一般地说，多维数组占用的存储空间较少。

## 优点2

---

- 多维数组查找速度快，维护代价小
  - 根据数据结构的知识，一个多维数组被存放在一个线性空间中，知道了数据单元的坐标后，可以由数组线性化函数快速地确定数据单元在线性空间中的地址，从而找到该数据单元
  - 而在关系表中，首先要看是否有合适的索引，否则要遍历整个关系表。不但查找速度慢，而且，建立和维护索引也需要一定的开销

## 优点3

---

- 多维数组有利于多维计算
  - 如果要查询“冰箱的销售总量是多少？”，需要进行计算，涉及多个数据项求和。
  - 在使用关系表存储的情况下，系统必须在大量的数据记录中选出产品名称为“冰箱”的记录，然后把它们销售量加到一起，这时系统效率较低。
  - 由于关系数据库统计数据的方式是对记录进行扫描，而多维数组对此类查询只要按行或按列进行求和，因而具有极大的性能优势。

# 多维数组有利于预综合

- 在实际应用中，为了获得快速一致的响应，决策分析人员经常对一些数据进行预综合，存放在数据库中。例如，在关系表中加上一行总和的记录

| 产品名称 | 地区 | 销售量   |
|------|----|-------|
| 冰箱   | 东北 | 5 0   |
| 冰箱   | 西北 | 6 0   |
| 冰箱   | 华北 | 1 0 0 |
| 冰箱   | 总和 | 2 1 0 |
| 彩电   | 东北 | 4 0   |
| 彩电   | 西北 | 7 0   |
| 彩电   | 华北 | 8 0   |
| 彩电   | 总和 | 1 9 0 |
| 空调   | 东北 | 9 0   |
| 空调   | 西北 | 1 2 0 |
| 空调   | 华北 | 1 4 0 |
| 空调   | 总和 | 3 5 0 |
| 总和   | 东北 | 1 8 0 |
| 总和   | 西北 | 2 5 0 |
| 总和   | 华北 | 3 2 0 |
| 总和   | 总和 | 7 5 0 |

# 多维数组有利于预综合

---

- 在关系表中，由于已经预先对产品在各地区的销售量进行了求和（综合），查询时就不用再进行计算了。
- 如果所求的总和都已经被综合的话，只要读取单个记录就可以回答按产品（或按地区）求和的问题了。
- 这样处理就可以得到快速一致的查询响应。当数据库不算太大时，这种综合效果较好

# 多维数组有利于预综合

---

- 但当数据库太大时，预先计算这些总和就要花费很长时间。
- 另外，" 总和 " 项破坏了列定义的统一语义
  - 例如上例中的地区列中的值表示的是地区名称，而 " 总和 " 就成为一个例外。查询时用户必须了解这种约定。

# 多维数组有利于预综合

- 多维数组的优势不仅在于多维概念表达清晰，占用存储少，更重要的是它有着高速的预综合速度。
- 在多维数组中，数据可以直接按行或列累加，并且由于多维数组中不象关系表里那样重复地出现产品和地区信息，因此其综合速度远远超过关系表，数据库记录数越多其效果越明显

|    | 东北    | 西北    | 华北    | 总和    |
|----|-------|-------|-------|-------|
| 冰箱 | 5 0   | 6 0   | 1 0 0 | 2 1 0 |
| 彩电 | 4 0   | 7 0   | 8 0   | 1 9 0 |
| 空调 | 9 0   | 1 2 0 | 1 4 0 | 3 5 0 |
| 总和 | 1 8 0 | 2 5 0 | 3 2 0 | 7 5 0 |

# 多维数组存储的缺点

---

- 多维数组存储方式的最大缺点是数据稀疏问题。
  - 例如，一个由时间维、商店维和产品维构成的多维数组，如果存储**10000**种商品，在**1000**个商店，**10**年中每天的销售额，则这个多维数组中有 **$3.6 \times 10^{10}$** 个数据单元，是一个十分巨大的多维数组。
  - 但实际上，并不是每一天、每个商店都会产生**10000**种商品的交易，因此，这是一个相当稀疏的多维数组。

# 多维数组存储的缺点

---

- 相对地，在关系表存储模式下，只有当某一交易确实发生时，才在相应的表中留下记录。
- 因此，如果采用多维数组存储方式的话，必须很好地解决数据稀疏的问题，否则将丧失多维数组的优势。

# 多维数组存储的缺点

---

- 为了解决稀疏问题，可以把维分成稀疏维（**Sparse**）和紧密维（**Dense**），然后区别对待。
- 稀疏维和紧密维的确定需要根据具体的数据分布来决定。确定以后，由紧密维构成多维数组，数组是密实的，不稀疏。稀疏维作为关系表的列。


# 多维数组存储的缺点

---

- 划分之后，一个巨大的稀疏的多维数组实际上被划分成两部分：索引和若干个数据块
  - 索引是一个关系表
  - 数据块是一个密实的多维数组

采用这样的结构，在查找一个数据单元时，首先通过索引找到它所在的数据块，然后利用数组线性函数在数据块中查找该数据单元。

# 多维数组存储的缺点



# 多维数组存储的缺点

---

- 由于构成索引的维很稀疏，并且每个数据块只需一个指针来标识，因此索引项较小，只占数据空间的一小部分，可以完全放进内存。
- 这样，既解决了由于数组稀疏占用巨量存储空间的问题，又具有查询速度快的优点。

# 维的表示方法

---

- **MOLAP**采用多维数组来表示多维数据模型中的数据方体。另外，还需要有效地存储多维数据模型中的维、成员、层、层次、成员关系等
- 另外，为了便于建模，多维数据模型采用文字来描述成员等，而多维数组的下标是数字，需要进行转换，一般可以采用对照表来实现

# ROLAP

---

- ROLAP将多维数据存储在关系表中，由关系数据库管理系统负责管理，而多维查询语言翻译、多维计算、元数据管理等由OLAP服务器负责。
- 采用关系表存储数据，可以有效的处理海量数据，但是对多维数据的处理涉及到大量昂贵的连接运算，查询速度较慢，必须采用预计算和索引等技术加以克服。

# ROLAP

---

- ROLAP通常采用星型模型或雪片模型来组织数据，维表和事实表均采用关系表来实现。

# 星型连接

---

- **ROLAP**以关系数据库的表的形式存放维表和事实表，由关系数据库管理系统来管理这些表，从而把**OLAP**服务器从数据存储管理中解脱出来
- **OLAP**服务器从客户端接受多维查询语句，进行分析后，生成相应的**SQL**语句从关系数据库中获得数据，进行多维计算后，以多维的形式返回客户端

# 星型连接

---


- 在这种存储模式下，对维的基本操作，如，查找维的一个成员，查找某个层的所有成员，查找某个成员在某层的所有后继成员等，只需要对维表进行操作。由于维表相对比较小，查询速度比较快
- 对数据方体的查询，如果只涉及事实表中存储的数据，以目前关系数据库的技术水平，查询速度也有保障。

# 星型连接

- 但是，多维数据分析中常常用到聚集操作，该操作通常要提升维层。
  - 例如，事实表中存放的是每天的销售量，现在需要求出每月的销售量，在时间维上，维层从日期层提升到月份层。这时，就需要把时间维表的事实表做连接，获得每个月每天的销售量，进行累加后，作为月销售量。

# 星型连接

- 在极端的情况下，每个维的维表需要同时和事实表做连接操作，叫做星型连接



- 因此，星型连接操作的效率成为制约ROLAP系统性能的一个关键因素。关系数据库管理系统必须针对星型连接，采用有效的查询优化以及索引技术来提高系统的性能。

# 预综合数据

---

- 和MOLAP一样，为了提高查询响应时间，ROLAP也采用对数据进行预综合的技术，来减少实时计算时间。
- 不同的是，ROLAP更依赖这种技术。
- 后面，将详细介绍数据方体的预综合（计算）技术


# MOLAP和ROLAP实现机制的比较

---

## ■ 结构

- MOLAP将数据库服务器与OLAP服务器合二为一，数据库服务器（DB或DW）不仅负责数据的存储、存取及检索，同时也负责所有OLAP需求的执行。
- 来自不同事务处理系统的源数据通过一系列批处理过程被加载到数据库服务器中,以多维数组形式存储，并建立索引、进行预综合来提高查询性能。

# 结构



# 结构

## ■ ROLAP的结构

- 数据仓库的数据模型在定义完毕后，来自不同数据源的数据将装入数据仓库中
- 接着系统根据数据模型需要运行相应的综合程序来综合数据，并创建索引以优化存取效率。
- 最终用户的多维分析请求通过ROLAP服务器动态翻译成SQL请求，然后交给RDBMS服务器来处理SQL请求，最后查询结果经多维处理（即将以关系表形式存放的结果转换为多维视图）后返回给用户。

# 结构

- MOLAP和ROLAP均满足数据处理的一般过程：即数据装入、汇总、建索引和提供给最终用户使用。
- 但MOLAP较之ROLAP要简明一些
  - MOLAP的索引及数据综合可以自动进行，并且可以根据元数据自动管理所有的索引及模式。这为应用开发人员设计物理数据模式和确定索引策略节省了不少时间和精力，不过这也丧失了一定的灵活性
  - 相比而言，ROLAP的实现较为复杂，但灵活性较好，用户可以动态定义统计或计算方式

# 数据存储

---

- **MOLAP**以多维数组为主要存储结构，聚集计算通过数组下标的直接偏移进行。
- **ROLAP**以传统的关系数据库系统为基础，以关系表为主要存储结构。

# 数据存储

---

- 在数据的存储容量上，由于关系数据库的技术较为成熟，因此**ROLAP**占优势，并且可以支持的维数也较**MOLAP**大
- 但限制**MOLAP**数据量的不是维数，而是数据单元数。如果**MOLAP**能在数据单元的存储管理上有进一步的提高，再辅之以高效的稀疏处理能力，其数据量也可以达到很大
- 另外，尽管**ROLAP**的数据容量大，但为了提高分析响应速度，须构造大量的中间表（即预综合以避免重复连接），因此数据冗余也大

# 数据存取

- 由于**ROLAP**是用关系表来模拟多维数据，因此其存取较**MOLAP**复杂。
  - 首先用户的分析请求由**ROLAP**服务器转为**SQL**请求，然后交由**RDBMS**处理，处理结果经多维处理后返回给用户。
  - 而且**SQL**并非可以处理所有的多维分析和计算工作，有些时候只能依赖附加的应用程序来完成
- 而**MOLAP**可以利用多维查询语言(如**MDX**)或其它方式直接将用户查询转为**MOLAP**可以处理的形式，基本不借助附加程序。

# 适应性

---

- 从以下几个方面对MOLAP和ROLAP的适应性比较：
  - 适应分析维数动态变化
  - 适应数据变化
  - 适应海量数据
  - 适应软硬件的能力

# 适应分析维数动态变化

---

- 由于MOLAP的预综合度相当高（85%以上），因而增加一维则数据方体的规模会迅猛增长。
- 而ROLAP的预综合度相当灵活，大多根据用户需要进行，一般在85%以下，增加一维意味着增加一些维表及与用户分析相关的综合表，还有事实表中的相应内容，相对来说比较容易。

# 适应数据变化

---

- 因为MOLAP的预综合度高，因此，当数据或计算频繁变化时，其重新计算量相当大，甚至需要重新构建多维数据库
- 相比而言，ROLAP的预综合度低，适应数据变化的范围大

# 适应海量数据

---

- 由于RDBMS已有二十多年的历史，其技术上比较成熟，加之近年来并行处理技术的发展和运用，ROLAP在适应海量数据上的能力强于MOLAP

# 适应软硬件的能力

---

- 理由同上，**ROLAP**在软硬件上的适应力明显强于**MOLAP**

# 适应性总结

---

- 尽管**ROLAP**在适应性方面明显强于**MOLAP**，但这种差距是历史造成的。
- 随着时间的推移，**MOLAP**的技术会不断成熟，象并行处理等**RDBMS** 上用到的技术也会逐渐用到**MOLAP**上来。

# 比较总结

---

- **MOLAP**和**ROLAP**各有所长
- 总体来说，**MOLAP**是近年来应多维分析而产生的，它以多维数组为核心，多维数组在数据存储及综合上都有着关系表不可比拟的一些优点，但毕竟是一种新技术，在许多方面有待提高
- 而**ROLAP**则以广泛应用的**RDBMS**为基础，在技术成熟及各方面的适应性上较之**MOLAP** 要占一定的优势，但**ROLAP**的实现不如**MOLAP**简明，对开发人员的经验及技术要求高，维护工作量大

