



第1讲 机器学习

余力 博士

教授、博士生导师

大数据分析 & 智能决策实验室

buaayuli@ruc.edu.cn

目录

- 概述
- 聚类分析
- 分类预测
- 集成学习




中國人民大學
RENMIN UNIVERSITY OF CHINA




1. 机器学习概述

人类学习过程




什么是机器学习？




机器学习就是让计算机从大量的数据中学习相关的规律和逻辑，然后利用学习来的规律来进行决策，推理和识别等。



机器学习 vs. 人类学习




机器学习分类




监督学习

Classification




Regression




半监督学习



- 1. 有标记样本难以获取.
 - 需要专门的人员,特别的设备,额外的开销等等.
- 2. 无标记的样本相对而言是很廉价的.




无监督学习




密度估计



异常检测



聚类



降维


(有监督) 机器学习

- 1、对语言、文字的认知与识别
- 2、对图像、场景、自然物体的认知与识别
- 3、对规则的学习与掌握


例如：下雨天要带伞，生病要吃药，天冷了要穿厚衣服等

- 4、对复杂事物的推理与判断能力

例如：好人与坏人的辨别能力，事物的正误的判断能力



机器学习基本过程



例子：天气预报


- **目标**：预测明天北京会不会下雨
- **数据**：过去10年北京每一天的天气数据
 - 那天是否下雨：是/否
 - 那天的前一天傍晚18点的气温、相对湿度、风向、风速、气压等(特征)
 - 某条数据: <18, 20, 东, 15, 80, 是>
- **训练**：学习得到规律（模型）
- **预测**：给定今天傍晚18点的气温、相对湿度、风向、风速、气压等、根据模型预测明天是否下雨

机器学习的关键问题

- **【表示】** 如何表示数据样本？
 - 通常用一个向量来表示一个样本，向量中选用哪些特征是关键
- **【训练】** 如何找出规律【模型+策略+算法】*
 - 通常变成一个选择题，给你n个候选的模型让你选。【模型】
 - 确定选择的标准（什么样的模型才叫好模型）【策略】
 - 如何快速地从n个模型中选出最好的【算法】
- **【测试】** 如何根据找到的规律进行预测

机器学习任务

$$y=f(x)$$



训练集



身高	发长	抽烟	性别
1.88	1.4cm	是	男
1.66	15.3cm	否	女
1.78	22.6cm	否	女

机器学习（预测）问题范式

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	y
P1	3	4	3	5	3	3	3	2	3	3	1
P2	3	2	4	2	2	3	5	3	8	8	0
P3	3	7	3	3	2	3	5	4	6	8	0
P4	4	6	8	3	3	2	3	3	3	2	1
P5	5	6	3	5	3	3	5	3	8	8	1
P6	4	8	6	3	5	4	2	2	3	5	1
P7	5	4	8	4	6	3	5	3	2	3	0
P8	3	3	2	6	3	5	4	2	4	6	0
P9	6	3	5	3	2	3	3	4	6	8	1
P10	3	3	2	3	3	4	6	8	2	2	0
...	3	3	2	3	3	3	2	4	6	8	0
New	5	2	8	2	4	6	5	7	8	9	?

类别型特征

1. 序号编码

序号编码通常用于处理类别间具有大小关系的数据。对类别型特征赋予一个数值ID，例如高表示为3、中表示为2、低表示为1，。

2. 独热编码(one-hot)

独热编码通常用于处理类别间不具有大小关系的特征。如血型有4个取值（A型血、B型血、AB型血、O型血），独热编码A型血表示为（1, 0, 0, 0），B型血表示为（0, 1, 0, 0）。

3. 二进制编码

二进制编码主要分为两步，给每个类别赋予一个类别ID，将类别ID对应的二进制编码作为结果。以A、B、AB、O血型为例，A型血的ID为1，二进制表示为001；B型血的ID为2，二进制表示为010。

血型	类别ID	二进制表示			独热编码			
A	1	0	0	1	1	0	0	0
B	2	0	1	0	0	1	0	0
AB	3	0	1	1	0	0	1	0
O	4	1	0	0	0	0	0	1

文本表示模型

1. 词袋模型和N-gram模型

最基础的文本表示模型是词袋模型。

就是将每篇文章看成一袋子词，并忽略每个词出现的顺序。

2. 主题模型

主题模型用于从文本库中发现有代表性的主题（得到每个主题上面词的分布特性），并且能够计算出每篇文章的主题分布。

3. 词嵌入与深度学习模型


词嵌入是一类将词向量化的模型的统称，核心思想是将每个词都映射成低维空间（通常 $K=50 \sim 300$ 维）上的一个稠密向量（Dense Vector）。

机器学习-样本问题


年龄	肝脏大小	体重	肝硬化
23	10	60kg	否
78	8	65kg	否
36	5	55kg	否
34	13	80kg	否
13	7	43kg	否
46	11	75kg	是
22	8	63kg	否
29	8	59kg	否
58	10	71kg	否

噪声太多导致算法过拟合怎么办？
--预处理，过滤噪声




样本预处理




机器学习-算法问题



算法融合



机器学习-实施过程











2. 聚类分析

K-means(均值聚类)

- **初始化**。输入对象集 X ，输入指定聚类类数 K ，并在 X 中随机选取 K 个对象作为初始聚类中心。
- **进行迭代**。根据相似度准则将数据对象分配到最接近的聚类中心。
- **更新聚类中心**。然后以每一类的平均向量作为新的聚类中心，重新分配数据对象。
- **反复执行第二步和第三步**直至满足中止条件。迭代中止条件，比如最大循环次数或者聚类中心收敛误差容限。

K-means(均值聚类)

$$x_1=(2,1), x_2=(1,3), x_3=(6,7), x_4=(4,7)$$






New Center:
 sum = 129
 # cards = 14
 mean = $129/14$
 (about) 9



层次聚类

- 层次聚类是通过自顶向下或自底向上**层次凝聚式聚类**





中國人民大學
RENMIN UNIVERSITY OF CHINA



3. 分类预测

分类 vs. 聚类

- 分类: 有监督的学习
- 聚类: 无监督的学习
- 分类：类别事先人工定义好，并且是学习算法输入的一部分
- 聚类：簇在没有人工输入的情况下从数据中推理而得
 - 但是，很多因素会影响聚类的输出结果：簇的个数、相似度计算方法、文档的表示方式，等等


分类学习问题



欺诈发现



客户分类



手写识别



人脸识别

分类算法评价



- k折交叉验证(k-cross validation)
- 留一法(leave-one-out)
- 指标：正确率、召回率、 F1值

准确率P 及召回率R

	in the class	not in the class
predicted to be in the class	true positives (TP)	false positives (FP)
predicted to not be in the class	false negatives (FN)	true negatives (TN)

正确率 **Precision** = $TP / (TP + FP)$

召回率 **Recall** = $TP / (TP + FN)$

$$F_1 = \frac{1}{\frac{1}{2} \frac{1}{P} + \frac{1}{2} \frac{1}{R}} = \frac{2PR}{P + R}$$

一个计算的例子

	In the class	Not in the class
Predicted to be in the class	100	50
Predicted to not be in the class	40	80

正确率**Precision** = $100 / (100 + 50)$

召回率**Recall** = $100 / (100 + 40)$

分类机器学习（预测）问题范式

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	y
P1	3	4	3	5	3	3	3	2	3	3	1
P2	3	2	4	2	2	3	5	3	8	8	0
P3	3	7	3	3	2	3	5	4	6	8	0
P4	4	6	8	3	3	2	3	3	3	2	1
P5	5	6	3	5	3	3	5	3	8	8	1
P6	4	8	6	3	5	4	2	2	3	5	1
P7	5	4	8	4	6	3	5	3	2	3	0
P8	3	3	2	6	3	5	4	2	4	6	0
P9	6	3	5	3	2	3	3	4	6	8	1
P10	3	3	2	3	3	4	6	8	2	2	0
...	3	3	2	3	3	3	2	4	6	8	0
New	5	2	8	2	4	6	5	7	8	9	?

传统分类算法

近邻法

(KNN)

决策树

(DT)

朴素贝叶斯



(Naive Bayesian)

支持向量机




(SVM)

1. 近邻法 (KNN)

- KNN = **k nearest neighbors** , k近邻
- KNN的基本原理: 邻近性假设
- 离它最近的k篇对象所属类别中最多的那个类别



2. 决策树 (Decision Tree)



关键问题：分裂标准

如何区别男生女生？

- “头发长短” ？
- “穿的鞋子是否是高跟鞋” ？
- “有没有喉结” ？

- **ID3**：取值多的属性，更容易使数据更纯，其信息增益更大。
- **C4.5**：采用信息增益率替代信息增益。
- **CART**：以基尼系数替代熵，最小化不纯度，而不是最大化信息增益。

熵

$$Entropy(S) \equiv -p_{\oplus} \log_2 p_{\oplus} - p_{\ominus} \log_2 p_{\ominus}$$

举例来说，假设S是一个关于布尔概念的有14个样例的集合，它包括9个正例和5个反例（我们采用记号[9+，5-]来概括这样的数据样例），那么S相对于这个布尔样例的熵为：

$$Entropy([9+, 5-]) = -(9/14) \log_2 (9/14) - (5/14) \log_2 (5/14) \\ = 0.940。$$

So，根据上述这个公式，我们可以得到：

- 如果S的所有成员属于同一类，则Entropy(S)=0；
- 如果S的正反样例数量相等，则Entropy(S)=1；
- 如果S的正反样例数量不等，则熵介于0，1之间

ID3 - 信息增益

- 信息增益： $G(S,W) =$

$$E(S) - [P(W \text{ is present}) * E(S_{W \text{ is present}}) + P(W \text{ is absent}) * E(S_{W \text{ is absent}})]$$


$$E(S) = \sum_{c \in \{hot, cold\}} -p(S_c) \log_2(p(S_c))$$

$$\text{Entropy}([9+, 5-]) = -(9/14) \log_2(9/14) - (5/14) \log_2(5/14) = 0.940$$


例子

outlook	temperature	humidity	windy	Play/CLASS
sunny	85	HIGH	WEAK	no
sunny	80	HIGH	STRONG	no
overcast	83	HIGH	WEAK	yes
rainy	70	HIGH	WEAK	yes
rainy	68	NORMAL	WEAK	yes
rainy	65	NORMAL	STRONG	no
overcast	64	NORMAL	STRONG	yes
sunny	72	HIGH	WEAK	no
sunny	69	NORMAL	WEAK	yes
rainy	75	NORMAL	WEAK	yes
sunny	75	NORMAL	STRONG	yes
overcast	72	HIGH	STRONG	yes
overcast	81	NORMAL	WEAK	yes
rainy	71	HIGH	STRONG	no

基于信息增益的特征选择



Humidity
重要!



$$\begin{aligned} \text{Gain}(S, \text{Humidity}) &= .940 - (7/14) \cdot .985 - (7/14) \cdot .592 \\ &= .151 \end{aligned}$$

$$\begin{aligned} \text{Gain}(S, \text{Wind}) &= .940 - (8/14) \cdot .811 - (6/14) \cdot 1.0 \\ &= .048 \end{aligned}$$

其他指标

■ C4.5 - 信息增益率

$$Gain_ratio(D, a) = \frac{Gain(D, a)}{IV(a)}$$

$$IV(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

■ CART - 基尼系数

- 集合中一个随机选中的样本被分错的概率。

$$Gini(D) = \sum_{k=1}^{|y|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|y|} p_k^2$$

3. 朴素贝叶斯 (Naive Bayesian)

帅？	性格好？	身高？	上进？	嫁与否
帅	不好	矮	不上进	不嫁
不帅	好	矮	上进	不嫁
帅	好	矮	上进	嫁
不帅	好	高	上进	嫁
帅	不好	矮	上进	不嫁
不帅	不好	矮	不上进	不嫁
帅	好	高	不上进	嫁
不帅	好	高	上进	嫁
帅	好	高	上进	嫁
不帅	不好	高	上进	嫁
帅	好	矮	不上进	不嫁
帅	好	矮	不上进	不嫁

$$P(\text{嫁}|\text{不帅, 性格不好, 矮, 不上进}) = \frac{P(\text{不帅, 性格不好, 矮, 不上进}|\text{嫁})P(\text{嫁})}{P(\text{不帅, 性格不好, 矮, 不上进})}$$

(三) 贝叶斯分类 (Bayesian)

帅?	性格好?	身高?	上进?	嫁与否
帅	不好	矮	不上进	不嫁
不帅	好	矮	上进	不嫁
帅	好	矮	上进	嫁
不帅	好	高	上进	嫁
帅	不好	矮	上进	不嫁
不帅	不好	矮	不上进	不嫁
帅	好	高	不上进	嫁
不帅	好	高	上进	嫁
帅	好	高	上进	嫁
不帅	不好	高	上进	嫁
帅	好	矮	不上进	不嫁
帅	好	矮	不上进	不嫁

$$P(\text{嫁}|\text{不帅, 性格不好, 矮, 不上进}) = \frac{P(\text{不帅, 性格不好, 矮, 不上进}|\text{嫁})P(\text{嫁})}{P(\text{不帅, 性格不好, 矮, 不上进})}$$

朴素贝叶斯分类器

- 朴素贝叶斯是一个概率分类器
- 文档 d 属于类别 c 的概率计算如下：

$$P(c | d) = P(d | c)P(c) / P(d) \propto P(d | c)P(c) = P(c) \prod_{1 \leq k \leq n_d} P(t_k | c)$$

- n_d 是文档的长度(词的个数)
- $P(t_k | c)$ 是词项 t_k 出现在类别 c 中文档的概率
- $P(c)$ 是类别 c 的先验概率

一个例子

	docID	words in document	in $c = \textit{China}$?
training set	1	Chinese Beijing Chinese	yes
	2	Chinese Chinese Shanghai	yes
	3	Chinese Macao	yes
	4	Tokyo Japan Chinese	no
test set	5	Chinese Chinese Chinese Tokyo Japan	?

- 估计朴素贝叶斯分类器的参数
- 对测试文档进行分类

计算过程

先验 $\hat{P}(c) = 3/4$ 及 $\hat{P}(\bar{c}) = 1/4$, 而条件概率如下:

$$\hat{P}(\text{CHINESE}|c) = (5 + 1)/(8 + 6) = 6/14 = 3/7$$

$$\hat{P}(\text{TOKYO}|c) = \hat{P}(\text{JAPAN}|c) = (0 + 1)/(8 + 6) = 1/14$$

$$\hat{P}(\text{CHINESE}|\bar{c}) = (1 + 1)/(3 + 6) = 2/9$$

$$\hat{P}(\text{TOKYO}|\bar{c}) = \hat{P}(\text{JAPAN}|\bar{c}) = (1 + 1)/(3 + 6) = 2/9$$

$$\hat{P}(c|d_5) \propto 3/4 \cdot (3/7)^3 \cdot 1/14 \cdot 1/14 \approx 0.0003$$

$$\hat{P}(\bar{c}|d_5) \propto 1/4 \cdot (2/9)^3 \cdot 2/9 \cdot 2/9 \approx 0.0001$$

常见的贝叶斯模型

- 多项式模型 (MultinomialNB)

$$P(Y_k) = \frac{N_{Y_k} + \alpha}{N + K\alpha} \quad P(x_i | Y_k) = \frac{N_{Y_k, x_i} + \alpha}{N_{Y_k} + n\alpha}$$



- 高斯模型 (GaussianNB)

$$P(x_i | y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

- 伯努利模型 (BernoulliNB)



$$P(x_i | y) = P(i | y)x_i + (1 - P(i | y))(1 - x_i)$$

4. 支持向量机 (SVM)





基本思想


支持向量机，因其英文名为support vector machine，故一般简称SVM，通俗来讲，它是一种二类分类模型，其基本模型定义为特征空间上的间隔最大的线性分类器，其学习策略便是间隔最大化，最终可转化为一个凸二次规划问题的求解。



空间映射



最优超平面



$$w \cdot x_i + b \geq 1 \quad \text{for } y_i = 1$$
$$w \cdot x_i + b \leq -1 \quad \text{for } y_i = -1$$


$$\max \frac{1}{\|w\|}, \quad \text{s.t. } y_i (w^T x_i + b) \geq 1, i = 1, 2, \dots, n$$

$$d_i = \frac{y_i (w^T x_i + b)}{\|w\|}$$

$$\max d, \quad \text{s.t. } d_i \geq d, \\ i = 1, 2, \dots, n$$

$$\min_i y_i (w^T x_i + b) = 1$$

核函数



$$a_1\xi_1 + a_2\xi_2 + a_3\xi_1^2 + a_4\xi_2^2 + a_5\xi_1\xi_2 + b = 0$$

$$\varphi(\xi_1, \xi_2) = (\xi_1, \xi_2, \xi_1^2, \xi_2^2, \xi_1\xi_2)$$

假设在二维空间中两个向量 $X_1 = (\xi_1, \xi_2)$ 和 $X_2 = (\eta_1, \eta_2)$ ，那么它们经过映射之后在五维空间的内积表示为

$$\langle \varphi(X_1), \varphi(X_2) \rangle = \xi_1\eta_1 + \xi_2\eta_2 + \xi_1^2\eta_1^2 + \xi_2^2\eta_2^2 + \xi_1\xi_2\eta_1\eta_2$$

我们注意到

$$(\langle X_1, X_2 \rangle + 1)^2 = 2\xi_1\eta_1 + 2\xi_2\eta_2 + \xi_1^2\eta_1^2 + \xi_2^2\eta_2^2 + 2\xi_1\xi_2\eta_1\eta_2 + 1$$


对之前的映射稍作修改

$$\varphi'(X_1) = \varphi'(\xi_1, \xi_2) = (\sqrt{2}\xi_1, \sqrt{2}\xi_2, \xi_1^2, \xi_2^2, \sqrt{2}\xi_1\xi_2, 1)$$


$$\varphi'(X_2) = \varphi'(\eta_1, \eta_2) = (\sqrt{2}\eta_1, \sqrt{2}\eta_2, \eta_1^2, \eta_2^2, \sqrt{2}\eta_1\eta_2, 1)$$

就有 $\langle \varphi'(X_1), \varphi'(X_2) \rangle = (\langle X_1, X_2 \rangle + 1)^2$

核映射



二维空间向二维特征空间映射



二维空间向三维空间的映射



中國人民大學
RENMIN UNIVERSITY OF CHINA



4. 集成学习

机器学习与集成学习



集成学习




所谓集成学习，指构建多个分类器（弱分类器）对数据集进行预测，然后用某种策略将多个分类器预测的结果集成起来，作为最终预测结果。通俗比喻就是“三个臭皮匠赛过诸葛亮”，或一个公司董事会上的各董事投票决策，它要求每个弱分类器具备一定的“准确性”，分类器之间具备“差异性”。

集成学习根据各个弱分类器之间有无依赖关系，分为Boosting和Bagging两大流派：

Boosting流派，各分类器之间有依赖关系，必须串行，比如Adaboost、GBDT(Gradient Boosting Decision Tree)、Xgboost


Bagging流派，各分类器之间没有依赖关系，可各自并行，比如随机森林(Random Forest)

Bagging+Boosting



Bagging

Bagging通过结合相同数据集的不同子样本的多分类器模型的结果，以减少预测的方差 bootstrap aggregating的缩写，也称作“套袋法”




Boosting

Boosting 的核心思路是——挑选精英

经过不停的考验和筛选来挑选出「精英」，然后给精英更多的投票权，表现不好的基础模型则给较少的投票权，然后综合所有人的投票得到最终结果。
大部分情况下，经过 **boosting** 得到的结果偏差（bias）更小



Boosting




1. Random Forest(随机森林)

从样本集（假设样本集 N 个数据点）中**重采样**选出 n 个样本（有放回的采样，样本数据点个数仍然不变为 N ），在所有样本上，对这 n 个样本建立分类器（ID3\C4.5\CART\SVM\LOGISTIC），重复以上两步 m 次，获得 m 个分类器，最后根据这 m 个分类器的投票结果，决定数据属于哪一类。



每棵树种植和成长如下：

- 1.设训练集个数是 N 。这 **N 个样本采取随机但有放回**。此样本用于生长树的训练集。
- 2.如有 M 个输入变量，每节点指定一个数 $m < M$ ， m 变量从 M 中随机选择。在这 m 上最好的分裂时用来分裂节点。当我们生长森林的时候， m 的值是恒定的。
- 3.**每棵树都长到最大程度，而且没有剪枝。**
- 4.通过聚合 n 棵树的预测值预测新数据（如分类的多数票，回归的平均值）




投票决定最优分类 blog.csdn.net/zjuPeco

Create random subsets



Class prediction



2. AdaBoost

有如下二分类数据集

$$T = \{(x_1, y_1), (x_1, y_1), \dots, (x_N, y_N)\} \quad y_i \in Y = \{-1, 1\}$$

输入：数据集 T ，弱学习算法

输出：最终分类器 $G(x)$

(1) 初始化训练数据的权值分布

$$D_1 = (w_{11}, w_{12}, \dots, w_{1N}), \quad w_{1i} = \frac{1}{N}, \quad i = 1, 2, \dots, N$$

(2) 对 $m=1,2,\dots,M$ (弱分类器的个数, 对每个弱分类器做如下):

(a) 使用具有权值分布 D_m 训练数据集学习, 得到基本分类器

$$G_m(x) : X \rightarrow \{-1, 1\}$$

(b) 计算 $G_m(x)$ 在训练数据集上的分类误差率 (错误分类的样本的权重之和)

$$e_m = \sum_{i=1}^N P(G_m(x_i) \neq y_i) = \sum_{i=1}^N w_{mi} I(G_m(x_i) \neq y_i)$$

(c) 计算 $G_m(x)$ 的系数 (弱分类器的权重, 反函数, 误差率越大, 则权重越小, 反之越大)

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}$$

(d) 更新训练数据集的权值分布

$$D_{m+1} = (w_{m+1,1}, w_{m+1,2}, \dots, w_{m+1,N})$$

$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), \quad i = 1, 2, \dots, N$$

如果第 i 个样本分类错误, 则 $y_i G_m(x_i) < 0$, 导致样本的权重在第 $m+1$ 个弱分类器中增大

$$Z_m = \sum_{i=1}^N w_{mi} \exp(-\alpha_m y_i G_m(x_i))$$

它使得 D_{m+1} 成为一个概率分布。

(3) 构建基本分类器的线性组合

$$f(x) = \sum_{m=1}^M \alpha_m G_m(x)$$

得到最终的分类器

$$\sum_{i=1}^N w_{mi} = 1$$

$$w_{m+1,i} = \begin{cases} \frac{w_{mi}}{Z_m} e^{-\alpha_m} & , G_m(x_i) = y_i \\ \frac{w_{mi}}{Z_m} e^{\alpha_m} & , G_m(x_i) \neq y_i \end{cases}$$

$$G(x) = \text{sing}(f(x)) = \text{sign}\left(\sum_{m=1}^M \alpha_m G_m(x)\right)$$

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathfrak{L}$;
训练轮数 T .

过程:


- 1: $\mathcal{D}_1(\mathbf{x}) = 1/m$.
- 2: **for** $t = 1, 2, \dots, T$ **do**
- 3: $h_t = \mathfrak{L}(D, \mathcal{D}_t)$;
- 4: $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$;
- 5: **if** $\epsilon_t > 0.5$ **then break**
- 6: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$;
- 7: $\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases}$
 $= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t}$
- 8: **end for**

输出: $H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$

实现

```
1 from sklearn.model_selection
2 import cross_val_score from sklearn.datasets import load_iris
3 from sklearn.ensemble import AdaBoostClassifier
4
5 iris = load_iris()
6 clf = AdaBoostClassifier(n_estimators=100)
7 scores = cross_val_score(clf, iris.data, iris.target)
8 scores.mean()
```

3. 组合策略



平均法
(Average)

投票法
(Voting)

堆叠法
(Stacking)

平均法(Averaging)

对数值型(连续)输出 $h_i(x) \in R$ ，最常见的结合策略为平均法。

---简单平均法(simple averaging)

$$H(x) = \frac{1}{T} \sum_{i=1}^T h_i(x)$$

---加权平均法(weighted averaging)

$$H(x) = \sum_{i=1}^T w_i h_i(x)$$

其中 w_i 为权重，通常 w_i 要求：

$$w_i \geq 0, \quad \sum_{i=1}^T w_i = 1$$

投票法(Voting)

对分类来说，学习器 $h_i(x)$ 将从类别集合中预测出一个类别标记，最常用的是投票法。

---绝对多数投票法(majority voting)

$$H(x) = \begin{cases} c_j, & \text{if } \sum_{i=1}^T h_i^j(x) > 0.5 \sum_{k=1}^N \sum_{i=1}^T h_j^k(x); \\ \text{reject}, & \text{otherwise} \end{cases}$$

即如某标记的投票过半数，则预计为该标记；否则拒绝预测。

---相对多数投票法(plurality voting)

$$H(x) = c_{\arg \max_j \sum_{i=1}^T h_i^j(x)}$$


即预测为得票最多的标记，若同时出现多个票数最多，则任选其一。

---加权投票法(weighted voting)

$$H(x) = c_{\arg \max_j \sum_{i=1}^T w_i h_i^j(x)}$$

堆叠法 (Stacking)

- 先训练多个不同的模型，然后把之前训练的各个模型的输出为输入来训练一个模型，以得到一个最终的输出
- 理论上，采用合适的模型组合策略即可。但在实际中，常使用 logistic 回归作为组合策略。




Stacking

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
初级学习算法 $\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_T$;
次级学习算法 $\mathcal{L}$.


过程:

```
1: for  $t = 1, 2, \dots, T$  do
2:    $h_t = \mathcal{L}_t(D)$ ;
3: end for
4:  $D' = \emptyset$ ;
5: for  $i = 1, 2, \dots, m$  do
6:   for  $t = 1, 2, \dots, T$  do
7:      $z_{it} = h_t(\mathbf{x}_i)$ ;
8:   end for
9:    $D' = D' \cup ((z_{i1}, z_{i2}, \dots, z_{iT}), y_i)$ ;
10: end for
11:  $h' = \mathcal{L}(D')$ ;
输出:  $H(\mathbf{x}) = h'(h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_T(\mathbf{x}))$ 
```


总结：Bagging



总结：Boosting




总结：Sacking





中國人民大學
RENMIN UNIVERSITY OF CHINA



谢谢大家！

