


第一章 数据的整理与图形表示

§ 1 数据的整理与图形表示

§ 2 数据的描述性指标



§ 1 数据的整理与图形表示

描述数据的变量可分为两类：

- 分组(类)变量
- 定距变量


{ 品质标志——性质或属性特征

{ 分组(类)变量 { 名义变量：性别，省份，季节

{ 顺序变量：工种，产品等级，工厂规模

{ 数量标志——数量特征

{ 定距变量：身高，体重，销量，工资



一. 数据的整理

按照分组变量或定距变量对数据进行统计分组。

如何依据分组变量进行数据的整理？

性别

	Frequency	Percent	Valid Percent	Cumulative Percent
Valid 女	192	42.7	42.7	42.7
男	258	57.3	57.3	100.0
Total	450	100.0	100.0	

常用作法：先统计得到数据的频数分布，再列成**频数频率分布表**。

相关术语：频数，频率，频数频率分布表

如何依据定距变量进行数据的整理？

总评等级

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	不及格	11	13.3	13.3	13.3
	及格	12	14.5	14.5	27.7
	中	27	32.5	32.5	60.2
	良	15	18.1	18.1	78.3
	优	18	21.7	21.7	100.0
Total		83	100.0	100.0	

特殊情形下，可采用约定分组，此时组距可以不相等。

一般情形下，采用组距分组法（即等距分组），才能更好观察数据的取值分布。


阻值区间

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	[2.5, 3.0)	3	10.0	10.0	10.0
	[3.0, 3.5)	5	16.7	16.7	26.7
	[3.5, 4.0)	9	30.0	30.0	56.7
	[4.0, 4.5)	8	26.7	26.7	83.3
	[4.5, 5.0)	5	16.7	16.7	100.0
	Total	30	100.0	100.0	

两个注意问题

- 等距分组
- 组数适宜

小结：多了**人为分组**，实际上是人为生成一个分组变量。




二. 数据的图形表示

在数据整理的基础上，用各种统计图形描述数据。



- 饼形图
- 条形图与柱状图
- 并列（复合）条形图或柱状图
- 频率直方图
- 茎叶图

饼形图

饼形图用以直观显示部分对整体的比例关系，仅适用于分组变量。





条形图与柱状图



细微区分：条的放置方式，条形图（水平），柱状图（垂直）。


依时间变化情况多采用柱状图。

实例——季节与智商




简单的条形图与柱状图，对于问题的探究通常是不够的。

并列（复合）条形图或柱状图



- 主分组变量
- 次分组变量

意义：对两组或两组以上的并列数据进行比较。





比较一下：哪一个并列条形图更有意义？


不同方向的并列条形图，通常需要作选取。

频率直方图


频率直方图的形成



想一想：频率直方图与条形图有何区别，为什么存在这些区别？



频率直方图仅适用于定距变量。




茎叶图


茎叶图只是记录数据的一种图形方式，依据茎叶图可以复现数据集。

总评成绩 Stem-and-Leaf Plot

Frequency	Stem &	Leaf
2.00	Extremes	(=<43)
3.00	4 .	559
6.00	5 .	002557
12.00	6 .	011144667888
27.00	7 .	011111133334445556677788888
15.00	8 .	000001222334578
18.00	9 .	000001111111234447
Stem width:	10	
Each leaf:	1 case(s)	


*三维条形图





总结


- 数据标志不同，处理的相同与差异。
- 选取合适的统计图形。
- 赋予统计图形更多更好的实际意义。



§ 2 数据的描述性指标

数据的描述性指标，通常只适合于**定距变量**。

- 数据集中趋势的度量
- 数据离散趋势的度量



一. 数据集中趋势的度量

数据集中趋势的度量：描述数据的集中点或**中心值**。

常用的度量指标

1. 众数 (Mode)

出现次数（频数）最多的变量值。

2. 中数或中位数 (Median)

$$x_1, x_2, \dots, x_n \Rightarrow x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

$$\text{Median} = \begin{cases} x_{(\frac{n+1}{2})}, & n \text{ 为奇数} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}), & n \text{ 为偶数} \end{cases}$$

3. 平均数或均值 (Mean)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

4. 加权平均数 (Weighted Mean)


$$\text{Weighted Mean} = \frac{\sum_{i=1}^k q_i x_i}{\sum_{i=1}^k q_i}, \quad q_i \text{ 称为权重, 表示各值出现的频数。}$$

5. 四分位数 (Quartiles)

$$\text{上四分位数 } P_{75}, \text{ 即 } x_{(i)}, \quad i = \left\lceil \frac{75}{100} \times n \right\rceil$$

$$\text{下四分位数 } P_{25}, \text{ 即 } x_{(j)}, \quad j = \left\lceil \frac{25}{100} \times n \right\rceil$$


注：向上取整，上四分位数与下四分位数的意义。



练一练：


流调的某种流行性疾病的潜伏期（单位：天）：

4, 6, 3, 4, 7, 5, 5, 4, 12, 5



常用度量指标的比较与评价

- 众数：众数不受极端值（奇异值）的影响，但可能不唯一。
- 中位数：中位数不受极端值的影响，具有较高的稳健性，非常适用于具有极端值的情形。
- **平均数**：易于计算，具有**抽样的稳定性**，最为常用，但要考虑极端值的影响。
- 加权平均数：考虑了数据出现频数的差异，只适用于已分组的定距变量。



二. 数据离散趋势的度量

数据离散趋势的度量：描述数据之间的变异程度（**离散程度**）。

常用的度量指标

1. 极差或全距（Range）

最大值与最小值之差， $\text{Range} = x_{(n)} - x_{(1)}$ 。

2. 四分位差（ $P_{75} - P_{25}$ ）


上四分位数与下四分位数之差， $P_{75} - P_{25}$ 。

3. 方差 (Variance) 与标准差 (Standard Deviation)

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad S = \sqrt{S^2}$$

方差的另一个计算公式:


$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$



练一练：

流调的某种流行性疾病的潜伏期（单位：天）：


4, 6, 3, 4, 7, 5, 5, 4, 12, 5



常用度量指标的比较与评价

- 极差：特别容易受极端值的影响，极差越大，数据取值的差异越大。
- 四分位差：不受极端值的影响，比极差稳定，在（P25，P75）间集中了最为“常见”的数据。
- **方差和标准差**：刻画了所有数据偏离其平均值的程度，具有**抽样的稳定性**，最为常用，但要考虑极端值的影响。


离散程度的理解：产品的性能指标，生产线的稳定性。



Statistics

现在的工资

N	Valid	450
	Missing	0
Mean		\$35,040.28
Median		\$29,400.00
Mode		\$30,750
Std. Deviation		\$17,276.332
Variance		298471636
Range		\$119,250
Percentiles	25	\$24,450.00
	50	\$29,400.00
	75	\$37,950.00



第二章 随机变量以及抽样分布

§ 1 随机变量及其数字特征


§ 2 常用随机变量及其分布

§ 3 随机变量的函数、随机变量的独立性

§ 4 总体与样本


§ 5 抽样方法

§ 6 统计量与抽样分布



§ 1 随机变量及其数字特征

- 随机变量的概念
- 随机变量的数字特征



一. 随机变量的概念

引例1 中奖情况——离散型随机变量

发行1万张，设一等奖 2名，二等奖 5名，三等奖 10名

X	0	1	2	3
P	$1 - \frac{17}{10^4}$	$\frac{2}{10^4}$	$\frac{5}{10^4}$	$\frac{10}{10^4}$

结论：离散型随机变量通常用概率函数来描述。


$$P(X = x_i) = p_i$$

记 X 为奖金，其分布为


X	0	1000	100	10
P	$1 - \frac{17}{10^4}$	$\frac{2}{10^4}$	$\frac{5}{10^4}$	$\frac{10}{10^4}$

引例2 2000年美国人口的年龄分布——连续型随机变量

年龄组	百分比
0—20	29%
20—40	29%
40—60	26%
60—80	13%
80—100	3%



年龄组	百分比
0—10	14%
10—20	15%
20—30	14%
30—40	15%
40—50	15%
50—60	11%
60—70	7%
70—80	6%
80—90	2%
90—100	1%



年龄段划分越来越细，直方图上的折线会越来越平滑，最终会形成一条光滑的曲线 $f(x)$ ，

$$f(x) \geq 0 \text{ 且 } \int_0^{100} f(x)dx = 1。$$

记 X 表示美国人口的年龄，则有

$$P(a \leq X \leq b) \text{ (年龄介于 } a \text{ 到 } b \text{ 的百分比)} = \int_a^b f(x)dx。$$

结论：

- 连续型随机变量是离散型随机变量基础上的抽象结果。
- **连续型**随机变量通常用**概率密度**来描述。

密度函数 $f(x)$ 的性质

(1) $f(x) \geq 0$, $-\infty < x < +\infty$ (理解: 气温)

(2) $\int_{-\infty}^{+\infty} f(x)dx = 1$ (想一想: 为什么?)

(3) $P(a \leq X \leq b) = \int_a^b f(x)dx$ (意义)

理解 美国人的年龄 X


(1) $\{X = 21\}$ 为事件, 但 $P\{X = 21\} = 0$

(2) $P(20 \leq X \leq 35)$, $P(X > 73)$

结论:

(1) $X \sim f(x)$, $P(X = x) = 0$ 。

(2) 概率就是面积, 概率就是积分。



二. 随机变量的数字特征

1. 数学期望

离散型: $P(X = x_i) = p_i$, $EX = \sum_i x_i p_i$

记 X 为奖金, 其分布为

X	0	1000	100	10
P	$1 - \frac{17}{10^4}$	$\frac{2}{10^4}$	$\frac{5}{10^4}$	$\frac{10}{10^4}$

$$EX = 0 \times \left(1 - \frac{17}{10^4}\right) + 1000 \times \frac{2}{10^4} + 100 \times \frac{5}{10^4} + 10 \times \frac{10}{10^4} = 0.26$$

例 射手的射击技术

甲射手

命中环数	8	9	10
概率	0.3	0.1	0.6

乙射手

命中环数	8	9	10
概率	0.2	0.5	0.3

谁的射击技术较好？

平均命中环数

$$\text{甲: } EX = 8 \times 0.3 + 9 \times 0.1 + 10 \times 0.6 = 9.3$$

$$\text{乙: } EY = 8 \times 0.2 + 9 \times 0.5 + 10 \times 0.3 = 9.1$$

甲的射击技术较好。

连续型: $X \sim f(x)$, $EX = \int_{-\infty}^{+\infty} f(x)dx$

美国人口的年龄 $X \sim f(x)$


选取 N 个美国人, 年龄在 $[x_i, x_i + \Delta x)$ 间的人数约为

$$N \cdot P(x_i \leq X < x_i + \Delta x) \approx Nf(x_i)\Delta x$$

年龄总和: $\sum_{i=1}^n Nf(x_i)\Delta x \cdot x_i$

平均年龄: $\frac{\sum_{i=1}^n Nf(x_i)\Delta x \cdot x_i}{N} = \sum_{i=1}^n x_i f(x_i)\Delta x$

取极限: $\lim_{n \rightarrow \infty} \sum_{i=1}^n x_i f(x_i)\Delta x = \int_0^{+\infty} xf(x)dx$



例 某种电子元件的寿命 X （单位：小时）的密度函数为

$$f(x) = \begin{cases} \frac{1}{1000} e^{-\frac{x}{1000}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

$$EX = \int_0^{+\infty} x \cdot \frac{1}{1000} e^{-\frac{x}{1000}} dx = 1000$$

期望的意义：期望描述了随机变量的平均取值（或者说，随机变量分布的中心位置）。

2. 方差和标准差

例 射手的射击技术

甲射手

命中环数	8	9	10
概率	0.3	0.1	0.6

乙射手

命中环数	8	9	10
概率	0.2	0.5	0.3

谁的射击技术较好？

偏离期望的程度

$$\text{甲: } DX = (8 - 9.3)^2 \times 0.3 + (9 - 9.3)^2 \times 0.1 + (10 - 9.3)^2 \times 0.6 = 0.81$$

$$\text{乙: } DY = (8 - 9.1)^2 \times 0.2 + (9 - 9.1)^2 \times 0.5 + (10 - 9.1)^2 \times 0.3 = 0.49$$

乙的发挥更稳定。

以平均值评判，甲好，以稳定性评判，乙好。

方差: $DX = E(X - EX)^2 = EX^2 - (EX)^2$, 标准差: $\sqrt{DX}$

离散型场合: $DX = \sum_k (x_k - EX)^2 p_k = \sum_k x_k^2 p_k - \left(\sum_k x_k p_k \right)^2$


连续型场合: $DX = \int_{-\infty}^{+\infty} (x - EX)^2 f(x) dx = \int_{-\infty}^{+\infty} x^2 f(x) dx - \left(\int_{-\infty}^{+\infty} x f(x) dx \right)^2$

例 某种电子元件的寿命 X （单位：小时）的密度函数为

$$f(x) = \begin{cases} \frac{1}{1000} e^{-\frac{x}{1000}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

$$EX = 1000, \quad DX = \int_0^{+\infty} x^2 \cdot \frac{1}{1000} e^{-\frac{x}{1000}} dx - 1000^2 = 1000^2$$

方差的意义：方差刻画了随机变量取值偏离其平均值（期望）的程度，即随机变量取值的离散程度。方差越大，随机变量的取值越分散。




期望与方差的理解

产品标识，产品的生产监测


统计思想：数据的整理与图形表示的目的与意义

- 获得的数据只是部分抽样结果，希望利用部分推断全体。
- 所计算的描述性指标并不一定等于总体指标值，但是总体指标的反映。
- 图形表示，特别是频率直方图的目的是直观形象地刻画总体的取值分布。



§ 2 常用随机变量及其分布

- 0—1分布
- 二项分布
- 正态分布与标准正态分布




一. 0—1分布

0—1 分布也称为两点分布或伯努利分布，记为 $B(1, p)$ 。

X	1	0
P	p	$1-p$

$$EX = p, \quad DX = p(1-p)$$

0—1分布的应用背景：产品检测，疾病情况，市场占有率。



二. 二项分布

设 $P(A) = p$, 记 X 为 n 次独立试验中事件 A 发生的次数, 则有

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

称 X 服从二项分布, 记为 $B(n, p)$ 。

$$EX = np, \quad DX = np(1-p)$$

例 某种电子元件的寿命 X （单位：小时）的密度函数为

$$f(x) = \begin{cases} \frac{100}{x^2}, & x > 100 \\ 0, & \text{其他} \end{cases}$$

现随机抽取 3 只进行寿命测试。求：

- (1) 最初 150 小时内恰有 1 个元件被烧坏的概率。
- (2) 最初 150 小时内被烧坏的元件数目的分布。

解 记 Y 为最初 150 小时内被烧坏的元件数目, $Y \sim B(3, p)$, 且

$$p = P(X < 150) = \int_{100}^{150} \frac{100}{x^2} dx = \frac{1}{3}$$


(1) 最初 150 小时内恰有 1 个元件被烧坏的概率为

$$P(Y = 1) = C_3^1 \left(\frac{1}{3}\right)^1 \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

(2) 最初 150 小时内被烧坏的元件数目 $Y \sim B(3, p)$

三. 正态分布与标准正态分布

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < +\infty$$




$p(x)$ 的主要性质

- (1) 对称性：中心点 $x = \mu$ （中心位置）
- (2) σ^2 刻画了离散程度：曲线的尖锐程度


$$X \sim N(\mu, \sigma^2), \quad EX = \mu, \quad DX = \sigma^2$$

标准正态分布

$$p_0(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < +\infty$$



$$EX = 0, \quad DX = 1$$



正态分布的计算

正态分布与标准正态分布的联系：设 $X \sim N(\mu, \sigma^2)$ ，则有 $Y = \frac{X - \mu}{\sigma} \sim N(0, 1)$ 。

一般正态分布的计算可转化为标准正态分布来进行。

例 中国人的身高 $X \sim N(1.70, 0.10^2)$ ，求：

$$P(X < 1.60), \quad P(X \geq 1.90), \quad P(1.50 \leq X < 1.80)$$

解 $Y = \frac{X - 1.70}{0.10} \sim N(0, 1)$

$$P(X < 1.60) = P\left(Y = \frac{X - 1.70}{0.10} < \frac{1.60 - 1.70}{0.10}\right) = P(Y < -1) = 1 - \Phi(1) = 0.1587$$


$$P(X \geq 1.90) = P\left(Y = \frac{X - 1.70}{0.10} \geq \frac{1.90 - 1.70}{0.10}\right) = P(Y \geq 2) = 1 - \Phi(2) = 0.0228$$

$$\begin{aligned} P(1.50 \leq X < 1.80) &= P\left(\frac{1.50 - 1.70}{0.10} \leq Y = \frac{X - 1.70}{0.10} < \frac{1.80 - 1.70}{0.10}\right) \\ &= P(-2 \leq Y < 1) = \Phi(1) - (1 - \Phi(2)) = 0.8185 \end{aligned}$$

例 已知某种零件的内径（单位：mm）服从正态分布 $N(50, 0.5^2)$ ，按规定内径在 49mm 到 51mm 之间的为合格品，现随机抽测了 3 只该种零件。求：

- (1) 零件的合格率。 (2) 3 只零件中，合格品数目的分布。


3σ 准则



$$P(\mu - \sigma < X < \mu + \sigma) = 0.6826$$

$$P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.9544$$

$$P(\mu - 3\sigma < X < \mu + 3\sigma) = 0.9974$$



理解：理论与应用

中国人的身高 $X \sim N(1.70, 0.10^2)$

(1) 密度函数的意义


(2) $P(X > 3)$ 与 $P(X < -3)$

(3) 3σ 准则的重要性

统计的应用思想：


$X \sim N(\mu, \sigma^2)$ ，但 μ, σ^2 是未知的，反过来需要抽取部分个体推断 μ, σ^2 ，

才能计算 $P(X \in D)$ 。



§ 3 随机变量的函数、随机变量的独立性

- 随机变量的函数
- 随机变量的独立性



一. 随机变量的函数

1. 单一随机变量的函数

引例 1 正方形的面积 $S = X^2$

X	4	5	6
P	0.2	0.5	0.3

,

S	16	25	36
P	0.2	0.5	0.3

$$P(S = 16) = P(X^2 = 16) = P(X = 4) = 0.2$$

随机变量的函数仍然是随机变量，离散型具有概率函数，连续型具有概率密度。

2. 多个随机变量的函数


引例 2 四门课的总成绩

$$S = S_1 + S_2 + S_3 + S_4, \quad S_i, \quad i = 1, 2, 3, 4$$

引例 3 弹落点 (X, Y) 距目标的偏差

$$R = \sqrt{X^2 + Y^2}$$


多个随机变量的函数仍然是随机变量，自然具有相应的分布。



线性函数的期望

$$(1) \quad E(aX+b) = aEX + b ;$$

$$(2) \quad E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i EX_i \circ$$




二. 随机变量的独立性

独立性——随机变量之间无相互影响。

- (1) 将骰子投掷多次, X_i 为第 i 次的点数, $X_1, \dots, X_n$ 相互独立;
- (2) 从一批电子元件中, 检测 n 件的使用寿命 $X_1, \dots, X_n$, $X_1, \dots, X_n$ 相互独立;
- (3) X, Y 分别为北京市与天津市的夏季降雨量, X, Y 不相互独立。

常见的独立性场合:

- 重复试验的独立性。
- 群体 (总体) 数量很大, 抽样数量相对显小, 近似独立。



独立性的应用


(1) 设 X_1 与 X_2 相互独立, 则

$$D(aX_1 + bX_2) = a^2DX_1 + b^2DX_2。$$

(2) 设 $X_i \sim N(\mu_i, \sigma_i^2)$, $i=1, \dots, n$ 且相互独立, 则

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right),$$

特别地, 若 $X_i \sim N(\mu, \sigma^2)$ 且相互独立, 则 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)。$



中国人的身高问题——统计基础知识


中国人的身高 $X \sim N(\mu, \sigma^2)$ ，但 μ, σ^2 是未知的，抽取部分个体，希望得到 μ, σ^2 的近似值。

$x_1, \dots, x_n$ 为 n 个中国人的身高，需要构造函数 $T_1(x_1, \dots, x_n)$ ， $T_2(x_1, \dots, x_n)$ ，

$$\mu \approx T_1(x_1, \dots, x_n), \quad \sigma^2 \approx T_2(x_1, \dots, x_n)。$$

统计概念：

- 总体，样本
- 样本的独立同分布性
- 统计量




§ 4 总体与样本

总体是研究对象某一方面的数量指标，其分布函数和数字特征分别称为总体分布函数和总体数字特征。

按照某种方式从总体中抽出的部分个体指标，称为样本，样本中的个体数目称为样本容量。

总体总体分类：有限总体与无限总体

抽样方式：有放回与无放回




简单随机抽样

两个特点：

1. 随机性
2. 独立性

利用简单随机抽样可以得到简单随机样本，简称样本。



实例：中国人的身高


总体： $X \sim N(\mu, \sigma^2)$

样本： $(X_1, \dots, X_n)$ ， $X_1, \dots, X_n$ 相互独立且 $X_i \sim N(\mu, \sigma^2)$

(简记为 *i.i.d.*)。

样本的观测结果 $(x_1, \dots, x_n)$ 称为样本值。


样本 $X_1, \dots, X_n$ 相互独立且与总体 X 同分布！



§ 5 抽样方法

- 简单随机抽样
- 分层抽样
- 整群抽样
- 系统抽样

注：以后的内容都假定采用简单随机抽样。



附：统计推断

总体的分布通常是未知的，比如假定总体的分布类型（正态分布等），但分布中的参数却是未知的，进行抽样的目的，就是利用样本信息对总体的分布作统计推断。

如何进行统计推断？

引例1 称重问题——参数估计

在天平上重复称量一个重量为 μ 的物品，假设每次称量值 X_i 均服从正态分布 $N(\mu, \sigma^2)$ 且相互独立，试利用称量值 $(X_1, \dots, X_n)$ 构造 μ 的估计。




$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N(\mu, \frac{\sigma^2}{n})$$

估计量

$$E\bar{X} = \mu$$

$$D\bar{X} = \frac{\sigma^2}{n} \downarrow 0 \quad (n \rightarrow \infty)$$

$\bar{X}$ 集中了样本信息，是物品重量 μ 的很好估计。




想一想

为什么要多次称量，以平均值做近似值？只称一次行不行？

问题： $|\mu - x_1|$ 与 $|\mu - \bar{x}|$ 那个大？

$$X_1 \sim N(\mu, \sigma^2) \quad EX_1 = \mu, \quad DX_1 = \sigma^2 \gg \frac{\sigma^2}{n} = D\bar{X}$$

体会：统计是怎样思考问题的，体现了什么样的思想？




参数估计

一般地，设 $X \sim F(x; \theta)$ ， θ 为未知参数，抽取样本 $(X_1, \dots, X_n)$ ，构造样本函数 $\hat{\theta}(X_1, \dots, X_n)$ ，以其观测值 $\hat{\theta}(x_1, \dots, x_n)$ 作为 θ 的近似值，这一做法称为**参数的点估计**。

理解：

- 总体与样本的概念
- 样本的i. i. d. 性质
- 参数估计的思想
- 估计优良性的评价



引例2 废水问题——假设检验

某厂宣称已采取大力措施治理废水污染，根据经验，废水中所含某种有毒物质的浓度 X （单位：mg/kg）服从正态分布 $N(\mu, 2.4^2)$ 。现环保部门抽测了 9 个水样，测得样本的平均值为 17.4，若以往该厂废水中有毒物质浓度的平均值为 18.2，试问：有毒物质的浓度有无显著降低？

$$X \sim N(\mu, 2.4^2)$$

$$H_0: \mu = \mu_0 = 18.2 \longleftrightarrow H_1: \mu < \mu_0$$

$$\bar{X} \sim N(\mu, \frac{\sigma^2}{n}), \quad Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

$\bar{X}$ 是 μ 的估计, 当 H_0 成立时, $\bar{X}$ 应在 μ_0 的附近, 而当 H_1 成立时, $\bar{X}$ 倾向小于 μ_0 。

反过来看, $\bar{X}$ 越小, H_1 成立的可信度越高。

直观判断——确定 H_0 的拒绝域

$$\bar{x} = \begin{cases} 22.4 & \uparrow \text{ 接受 } H_0 \\ 17.9 & \\ \hline 15.1 & \downarrow \text{ 拒绝 } H_0 \\ 14.3 & \end{cases}$$

存在阈值（临界值） $T(n)$ ，检验规则为

$$\begin{cases} \bar{X} > T(n), & \text{接受 } H_0 \\ \bar{X} < T(n), & \text{拒绝 } H_0 \end{cases}$$


阈值 $T(n)$ 的确定： $P_{H_0}(\bar{X} < T(n)) = \alpha$

想一想：为什么说统计是合理的？

$$P(\bar{X} < T(n)) = P\left(Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < \frac{T(n) - \mu_0}{\sigma/\sqrt{n}}\right) = \alpha$$

$$\frac{T(n) - \mu_0}{\sigma/\sqrt{n}} = -z_\alpha$$

$$T(n) = \mu_0 - z_\alpha \frac{\sigma}{\sqrt{n}}$$



阈值 $T(n)$ 太不方便，一般采用 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ 来判断

$$P(\bar{X} < T(n)) = P(Z < -z_\alpha) = \alpha$$


拒绝域

$$C: Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -z_\alpha$$

具体检验：

$$\alpha = 0.05, \quad z_{\alpha} = 1.64, \quad \bar{x} = 17.4, \quad n = 9, \quad \sigma = 2.4, \quad \mu_0 = 18.2$$

$$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}} = -1.0 > -1.64 = -z_{\alpha}, \text{ 接受 } H_0。$$



假设检验

一般地，设 $X \sim F(x; \theta)$ ， θ 为未知参数，抽取样本 $(X_1, \dots, X_n)$ ，构造检验规则，


推断统计假设

$$H_0 \longleftrightarrow H_1$$

的正确性，这一过程称为**假设检验**。


检验的内在统计原理：

- 反证法
- 小概率原理



§ 6 统计量与抽样分布

- 统计量
- 三大分布
- 正态总体的抽样分布
- 一般总体大样本下的抽样分布



一. 统计量

样本 $(X_1, \dots, X_n)$ 的任意不含有总体分布未知参数的函数

常用的统计量

(1) 样本均值与样本方差

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

设 $E(X) = \mu$, $D(X) = \sigma^2$, 则有

$$E(\bar{X}) = \mu , \quad D(\bar{X}) = \frac{\sigma^2}{n} , \quad E(S^2) = \sigma^2 .$$

结论：样本均值 $\bar{X}$ 与样本方差 S^2 可分别用来估计总体均值与总体方差。

$S = \sqrt{S^2}$ 称为样本标准差。


(2) 样本矩

样本 k 阶原点矩: $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

样本 k 阶中心矩: $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, 其中 $S_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

称为样本的未修正方差。

理解：数据整理的目的和意义。




二. 三大分布

χ^2 分布、 t 分布与 F 分布是数理统计常用的三大分布。

χ^2 分布

设 $X_1, \dots, X_n$ 相互独立, 且 $X_i \sim N(0,1)$, 则称 $\chi^2 = \sum_{i=1}^n X_i^2$ 服从

自由度为 n 的 χ^2 分布, 记为 $\chi^2(n)$ 。



性质

$$(1) \quad E\chi^2(n) = n, \quad D\chi^2(n) = 2n$$

$$(2) \quad \chi^2 \text{ 分布具有再生性: 设 } X_1 \sim \chi^2(n_1), \quad X_2 \sim \chi^2(n_2)$$

且相互独立, 则有 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$ 。


分位数

设 $X \sim F(x)$ ，若存在 x_α ，使得

$$P(X > x_\alpha) = 1 - F(x_\alpha) = \alpha$$

则称 x_α 为 X 的上侧 α 分位数。


特别地，如果 X 的分布是对称的，则有 $x_{1-\alpha} = -x_\alpha$ 。




标准正态分布 $N(0,1)$ 的上侧分位数

$$X \sim N(0,1)$$

$$P(X > z_\alpha) = \alpha, \quad P(X < -z_\alpha) = \alpha.$$






t 分布

设 $X \sim N(0,1)$, $Y \sim \chi^2(n)$ 且相互独立, 称

$$T = \frac{X}{\sqrt{Y/n}}$$


服从自由度为 n 的 t 分布, 记为 $T \sim t(n)$ 。



性质

(1) 对称性

(2) $\lim_{n \rightarrow \infty} t(n) = N(0, 1)$



F 分布

设 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$ 且相互独立, 称


$$F = \frac{X/n_1}{Y/n_2}$$


服从自由度为 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$ 。

性质

(1) 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$

$$(2) F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$





三. 正态总体的抽样分布

- 单正态总体的抽样分布
- 双正态总体的抽样分布


定理 设 $X_i \sim N(\mu_i, \sigma_i^2)$ 且相互独立, 则 $\sum_{i=1}^n a_i X_i \sim N(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2)$ 。

例 两种工种的月工资 $X \sim N(5000, 400^2)$, $Y \sim N(4000, 300^2)$, 求 $P(X > Y)$ 。

解 $X - Y \sim N(5000 - 4000, 400^2 + 300^2) = N(1000, 500^2)$

$$P(X > Y) = P(X - Y > 0) = P(Z = \frac{(X - Y) - 1000}{500} > \frac{0 - 1000}{500})$$

$$= P(Z > -2) = \Phi(2) = 0.9772$$



单正态正态的抽样分布

定理 设 $(X_1, \dots, X_n)$ 是取自正态总体 $N(\mu, \sigma^2)$ 的样本, 则有

$$(1) \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \text{ 从而 } Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)。$$

$$(2) \quad \chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)。$$

$$(3) \quad \bar{X} \text{ 与 } S^2 \text{ 相互独立, 且 } T = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)。$$


例 设 $(X_1, \dots, X_{16})$ 是取自 $N(\mu, 1)$ 的样本, 求 $P(|X - \mu| > 1)$ 与 $P(|\bar{X} - \mu| > 1)$ 。

解 $X \sim N(\mu, 1), \frac{X - \mu}{\sqrt{1}} = X - \mu \sim N(0, 1)$

$$\begin{aligned} P(|X - \mu| > 1) &= 1 - P(|X - \mu| \leq 1) = 1 - P(\mu - 1 \leq X \leq \mu + 1) \\ &= 1 - P(-1 \leq X - \mu \leq 1) = 1 - (1 - 2(1 - \Phi(1))) = 0.3174 \end{aligned}$$

$$\bar{X} \sim N(\mu, \frac{1}{16}), \frac{\bar{X} - \mu}{\sqrt{\frac{1}{16}}} = 4(\bar{X} - \mu) \sim N(0, 1)$$

$$\begin{aligned} P(|\bar{X} - \mu| > 1) &= 1 - P(|\bar{X} - \mu| \leq 1) = 1 - P(\mu - 1 \leq \bar{X} \leq \mu + 1) \\ &= 1 - P(-4 \leq 4(\bar{X} - \mu) \leq 4) = 1 - (1 - 2(1 - \Phi(4))) = 0 \end{aligned}$$



双正态总体的抽样分布

定理 设 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ 且相互独立, $(X_1, \dots, X_{n_1})$ 与 $(Y_1, \dots, Y_{n_2})$

分别是取自 X 与 Y 的样本, 则有

$$(1) \quad Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

$$(2) \quad F = \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

(3) 当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时, 有

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

其中
$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

例 从正态总体 $N(\mu, 1)$ 中分别抽取容量为 9 与 16 的两个独立样本，求两样本均值之差的绝对值小于 1 的概率。


这两个独立样本，可以认为是分别取自于两个总体 X 与 Y ， X 与 Y 均服从 $N(\mu, 1)$ ，于是 $\bar{X} \sim N(\mu, \frac{1}{9})$ ， $\bar{Y} \sim N(\mu, \frac{1}{16})$ 。

$$\bar{X} - \bar{Y} \sim N(\mu - \mu, \frac{1}{9} + \frac{1}{16}) = N(0, \frac{25}{9 \cdot 16}),$$

$$\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{25}{9 \cdot 16}}} = 2.4(\bar{X} - \bar{Y}) \sim N(0, 1),$$

$$P(|\bar{X} - \bar{Y}| < 1) = P(-1 \leq \bar{X} - \bar{Y} \leq 1)$$

$$= P(-2.4 \leq 2.4(\bar{X} - \bar{Y}) \leq 2.4) = 1 - 2(1 - \Phi(2.4)) = 0.9836$$



练一练


假设成年中国人的身高（单位：m） $X \sim N(\mu, 0.1^2)$ ，其中 μ 未知，独立地抽样两次，每次 800 人，求两次抽测的平均身高之差的绝对值不超过 0.01 的概率。

$$\bar{X} - \bar{Y} \sim N(\mu - \mu, \left(\frac{1}{800} + \frac{1}{800}\right) \cdot 0.1^2) = N(0, \frac{1}{4} \times 10^{-4}),$$

$$\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{1}{4} \times 10^{-4}}} = 200(\bar{X} - \bar{Y}) \sim N(0, 1),$$

$$P(|\bar{X} - \bar{Y}| < 0.01) = P(-2 \leq 200(\bar{X} - \bar{Y}) \leq 2) = 1 - 2(1 - \Phi(2)) = 0.9545$$

想一想：什么是统计量的抽样稳定性？直观上是如何体现的？



四. 一般总体大样本下的抽样分布

设 $(X_1, \dots, X_n)$ 是取自总体 X 的样本, $\mu = EX$, $\sigma^2 = DX$, 记

$$U_n = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}, \quad T_n = \frac{\bar{X} - \mu}{S / \sqrt{n}}$$

则有

(1) U_n 渐近服从 $N(0,1)$, 即 $\lim_{n \rightarrow \infty} P(U_n \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{x^2}{2}} dx$ 。

(2) T_n 渐近服从 $N(0,1)$ 。