

2014 年同等学力申硕计算机综合试题-人工智能原理

一、单项选择题（本大题共 4 小题，每题 2 分，共 8 分）

1. 建造一个多层神经网络，可实现逼近一个任意的（B）。

- A. 函数
- B. 连续函数
- C. 只有有限个间断点的连续函数

解析：考查人工神经网络

多层神经网络（如含一个隐藏层的前馈神经网络）的“**万能逼近定理**”指出：只要隐藏层神经元数量足够，它可以逼近任意**连续函数**（或在紧集上逼近任意连续函数）。故选 B。

- A 错误：不能逼近所有函数（如非连续函数）；
- C 错误：“有限个间断点的连续函数”表述不准确，万能逼近定理针对的是连续函数。

2. 支持向量机（SVM）是一种（A）算法。

- A. 小样本下的统计机器学习
- B. 大样本下的统计机器学习
- C. 大样本下的实例机器学习

解析：考查统计机器学习

支持向量机（SVM）基于统计学习理论（结构风险最小化），其核心优势是在**小样本场景**下通过最大化分类间隔实现良好的泛化性能，无需依赖大样本；且 SVM 属于统计机器学习（基于统计理论建模），而非实例机器学习（如 K 近邻）。故选 A。

- B 错误：SVM 并非依赖大样本；
- C 错误：SVM 不是实例机器学习，且不依赖大样本。

3. 非单调推理是由于处理（B）问题提出来的。

- A. 逻辑矛盾
- B. 知识不完全
- C. 知识表示

解析：考查知识表示与推理

非单调推理的核心特点是“新证据可能推翻已有结论”，其提出的背景是**知识不完全**的场景——当初始知识不完整时，需基于现有信息做出假设性结论，后续新信息补充后可能修正之前的结论。故选 B。

- A 错误：逻辑矛盾通常通过一致性维护解决，并非非单调推理的核心动机；
- C 错误：知识表示是知识的存储形式，不是非单调推理的提出原因。

4. 在 MYCIN 专家系统中，已知证据（事实）A 和 B 的不确定性度量分别为 $CF(A) = 0.3$ 和 $CF(B) = 0.5$ ，那么证据 $A \wedge B$ 的不确定性度量 $CF(A \wedge B) =$ （B）。

- A. 0.5

- B. 0.3
C. 0.15

解析：考查不确定性推理

MYCIN 专家系统中采用可信度 (CF) 模型处理不确定性推理，对于合取证据 ($A \wedge B$) 的可信度计算规则为**取各证据可信度的最小值**。

已知 $CF(A)=0.3$ 、 $CF(B)=0.5$ ，因此 $CF(A \wedge B)=\min(0.3, 0.5)=0.3$ 。故选 B。

- A 错误：0.5 是 B 的可信度，合取证据需取最小值而非最大值；
- C 错误：0.15 是两者的乘积，并非 MYCIN 系统中合取证据的计算方式。

二、证明题 (10 分)

试使用归结法证明 $A1 \wedge A2 \wedge A3 \rightarrow B$ ，其中：

$A1 = (\forall x) \{ (D(x) \wedge \neg E(x)) \rightarrow (\exists y) (F(x, y) \wedge H(y)) \}$ ，

$A2 = (\exists x) \{ D(x) \wedge G(x) \wedge (\forall y) (F(x, y) \rightarrow \neg G(y)) \}$ ，

$A3 = (\forall x) (\neg E(x) \vee \neg G(x))$ ，

$B = (\exists x) (D(x) \wedge \neg E(x) \wedge (\exists y) H(y))$ 。

证明：考查归结推理方法

要证明 $A1 \wedge A2 \wedge A3 \rightarrow B$ ，使用反证法，只需证明： $A1 \wedge A2 \wedge A3 \rightarrow \neg B$ 是矛盾式，(即通过归结法推导出空子句 $\square$)。

步骤 1：将所有公式转化为子句集

1. 处理 A1

$A1 = (\forall x) \{ (D(x) \wedge \neg E(x)) \rightarrow (\exists y) (F(x, y) \wedge H(y)) \}$ 。

再写成蕴含式：

$(\forall x) \{ \neg(D(x) \wedge \neg E(x)) \vee (\exists y) (F(x, y) \wedge H(y)) \} \equiv (\forall x) \{ (\neg D(x) \vee E(x)) \vee (\exists y) (F(x, y) \wedge H(y)) \}$ 。

因此 A1 等价于：

$(\forall x) (\exists y) [\neg D(x) \vee E(x) \vee (F(x, y) \wedge H(y))]$ 。

分配析取到合取 (注意这里是析取一个合取式)：

$(\forall x) (\exists y) [(\neg D(x) \vee E(x) \vee F(x, y)) \wedge (\neg D(x) \vee E(x) \vee H(y))]$ 。

现在引入 Skolem 函数：因为 y 依赖于 x，用 Skolem 函数 $f(x)$ 代替 y。

得到两个全称量词子句 (去掉 $\forall x$)：

- $\neg D(x) \vee E(x) \vee F(x, f(x))$ 。
- $\neg D(x) \vee E(x) \vee H(f(x))$ 。

2. 处理 A2

$A2 = (\exists x) \{ D(x) \wedge G(x) \wedge (\forall y) (F(x, y) \rightarrow \neg G(y)) \}$ 。

先处理内部：

$F(x, y) \rightarrow \neg G(y) \equiv \neg F(x, y) \vee \neg G(y)$ ；

所以 $A2 = (\exists x) [D(x) \wedge G(x) \wedge (\forall y) (\neg F(x, y) \vee \neg G(y))]$ 。

消去存在量词 $\exists x$ ，引入 Skolem 常量 a (因为无外层全称量词)：

$A2 = D(a) \wedge G(a) \wedge (\forall y) (\neg F(a, y) \vee \neg G(y))$

消去全称量词 $\forall y$ ，得子句集：

- $D(a)$ 。
- $G(a)$ 。
- $\neg F(a, y) \vee \neg G(y)$ (对任意 y)。

3. 处理 A3

$A3 = (\forall x) (\neg E(x) \vee \neg G(x))$ 。

消去全称量词 $\forall x$ ，得到子句集：

- $\neg E(x) \vee \neg G(x)$ 。

4. 处理 $\neg B$ (目标否定式)

$B = (\exists x) (D(x) \wedge \neg E(x) \wedge (\exists y) H(y))$ ，

故 $\neg B = (\forall x) \{ \neg D(x) \vee E(x) \vee (\forall y) \neg H(y) \}$ 。

消去全称量词 $\forall x$ ，得子句集：

- $\neg D(x) \vee E(x) \vee \neg H(y)$ 。

5. 总子句集

合并上述子句集，标记子句顺序编号：

- C1: $\neg D(x) \vee E(x) \vee F(x, f(x))$,
- C2: $\neg D(x) \vee E(x) \vee H(f(x))$,
- C3: $D(a)$,
- C4: $G(a)$,
- C5: $\neg F(a, y) \vee \neg G(y)$,
- C6: $\neg E(x) \vee \neg G(x)$,
- C7: $\neg D(x) \vee E(x) \vee \neg H(y)$ 。

步骤 2: 归结过程 (推导出空子句)

我们从已知事实 $D(a)$, $G(a)$ 出发。

1. 用子句 C3: $D(a)$ 与子句 C2 归结

子句 C2: $\neg D(x) \vee E(x) \vee H(f(x))$,

代入 $x = a$: $\neg D(a) \vee E(a) \vee H(f(a))$,

与 $D(a)$ 归结，得：

→ 子句 C8: $E(a) \vee H(f(a))$ 。

2. 使用子句 C4: $G(a)$ 和子句 C6 归结

子句 C6: $\neg E(x) \vee \neg G(x)$,

代入 $x = a$: $\neg E(a) \vee \neg G(a)$ 。

子句 C4: $G(a)$,

归结 (消去 $\neg G(a)$)，得：

→ 子句 C9: $\neg E(a)$ 。

3. 用 C9: $\neg E(a)$ 与子句 C8 归结

子句 C8: $E(a) \vee H(f(a))$,

与 $\neg E(a)$ 归结 (消去 $E(a)$)，得：

→ 子句 C10: $H(f(a))$ 。

4. 用子句 C10 和 C9 与子句 C7 归结

子句 C10: $H(f(a))$,

子句 C9: $\neg E(a)$,

子句 C7: $\neg D(x) \vee E(x) \vee \neg H(y)$,

代入 $x = a, y = f(a)$: $\neg D(a) \vee E(a) \vee \neg H(f(a))$ 。

先用 $H(f(a))$ 归结 (消去 $\neg H(f(a))$):

→ 得子句: $\neg D(a) \vee E(a)$;

再与 $\neg E(a)$ 归结:

→ 得子句 C11: $\neg D(a)$;

5. 用子句 C11 和 C3 归结

子句 C11: $\neg D(a)$,

子句 C3: $D(a)$,

$\neg D(a)$ 与 $D(a)$ 归结:

→ 得到 空子句 $\square$ 。

结论

通过归结法推导出空子句, 证明 $A1 \wedge A2 \wedge A3 \rightarrow B$ 成立。

三、问答题 (每题 4 分, 共 12 分)

1. 对一类问题求解来说, 若有部分案例 (case), 而有较多的推理规则 (知识), 试问如何建造一个由基于案例推理和规则推理相结合的求解系统, 以使推理效率高又能求得问题的解。

答: 考查知识表示和推理

可采用**规则推理为主、案例推理为辅**的混合推理架构, 结合两种推理方式的优势实现高效且准确的问题求解, 具体构建方案如下:

● (1) 推理流程设计

- **优先案例匹配:** 接收问题后, 先将问题特征与案例库中的案例进行相似度匹配。若能匹配到相似度高于阈值的案例, 直接复用案例的解决方案 (或基于案例方案微调), 快速输出结果; 若匹配失败或相似度低于阈值, 则转入规则推理流程。
- **规则推理求解:** 利用系统中丰富的推理规则, 通过正向推理 (从已知事实推导结论) 或反向推理 (从目标结论回溯前提) 完成问题求解, 同时将本次求解的问题特征与最终方案作为新案例存入案例库, 实现案例库的动态扩充。
- **混合修正机制:** 若规则推理得到初步结论后, 可再检索案例库中类似场景的案例, 用案例经验对规则推理结果进行校验和修正, 提升解的合理性; 若案例匹配得到的方案存在局限性, 可调用规则库中的知识补充约束条件, 完善解决方案。

● (2) 模块协同设计

- **案例库与规则库的关联:** 为案例添加规则标签(如案例适用的规则范围、案例解决的规则例外场景),实现案例与规则的双向索引,便于推理过程中快速调用对应知识。
- **冲突消解机制:** 当案例方案与规则推理结论冲突时,优先以规则结论为基准(因规则知识更完备),同时结合案例的实际场景特征分析冲突原因,若为规则未覆盖的特殊场景,则以案例方案为准并更新规则库的例外条款。

2. 已知北京市地图以及地图中任意两点 A 和 B 的最短路径算法,试给出一种计算 A 和 B 最短路径的启发式算法。

答: 考查启发式搜索

可采用 **A* (A-Star) 启发式搜索算法**来高效求解北京市地图中两点 A 与 B 之间的最短路径。

具体设计如下:

(1) 问题建模:

将北京市地图抽象为**带权图** $G = (V, E)$, 其中:

- 节点 $v \in V$ 表示道路交叉口或关键位置;
- 边 $e \in E$ 表示路段,权重为实际距离或通行时间;
- 起点为 A, 目标点为 B。

(2) A*算法原理:

A*算法是一种结合**实际代价与启发式估计**的最优路径搜索算法。对每个节点 n , 定义评价函数: $f(n) = g(n) + h(n)$ 。

- $g(n)$: 从起点 A 到当前节点 n 的实际最短代价(如已行驶距离);
- $h(n)$: 从节点 n 到目标 B 的启发式估计代价(需满足可采纳性)。

(3) 启发函数设计(针对北京市地图):

由于地图包含地理坐标信息,可取:

$h(n) = \text{欧几里得距离}(n, B) = \sqrt{(x_n - x_B)^2 + (y_n - y_B)^2}$; 或更贴近道路网络的曼哈顿距离(若路网呈网格状)。

该 $h(n)$ 满足可采纳性,即 $h(n) \leq h^*(n)$ (真实最短代价),从而保证 A* 找到**最优解**。

(4) 算法执行流程:

- 初始化: 将起点 A 加入开放列表 (Open List);
- 循环: 从 Open List 中选取 $f(n)$ 最小的节点扩展;
- 对其邻居更新 g 值,若更优则加入或更新列表;
- 重复直至目标 B 出队,回溯路径即为最短路径。

相比 Dijkstra 算法(盲目搜索),A 利用地理方向信息**显著减少搜索空间**,提高效率,特别适合城市级大规模路网。

3. 给出分类问题的描述,进而说明用于分类的有监督机器学习方法与无监督机器学习方法。

答: 考查机器学习方法

(一) 分类问题的描述

分类问题是机器学习领域中监督学习的核心任务之一，其本质是从已知类别的数据中学习一个分类模型（也叫分类器），再利用该模型将新的未知数据映射到预先定义类别集合中。

①问题要素

- 输入：由若干特征构成的样本（特征向量），每个样本对应一组特征取值；
- 输出：离散的类别标签（如“正/负”“猫/狗/鸟”“正常/异常”等）；
- 目标：使分类模型对新样本的类别预测尽可能准确，即最小化分类误差。

②典型应用场景

如垃圾邮件识别（分类为“垃圾邮件”/“正常邮件”）、疾病诊断（分类为“患病”/“健康”）、图像识别（分类为不同物体类别）、信用风险评估（分类为“高风险”/“低风险”）等。

（二）分类任务中的有监督与无监督机器学习方法

①有监督机器学习方法

有监督分类方法的核心是**依赖带标注的训练数据**（每个训练样本均明确标注了真实类别），通过学习特征与类别间的映射关系构建分类器，具体常见方法如下：

- **逻辑回归**：基于线性回归模型，通过 sigmoid 函数将输出映射到 $[0, 1]$ 区间，实现二分类（输出为样本属于正类的概率，通过阈值判断最终类别），适用于线性可分的二分类场景。
- **决策树**：以树状结构进行决策，通过递归划分特征空间（如基于信息增益、信息增益比、Gini 系数选择最优划分特征），可实现多分类，具有可解释性强的优势。
- **支持向量机（SVM）**：通过寻找最大间隔超平面实现分类，对于线性不可分数据，可通过核函数映射到高维空间实现线性可分，适用于小样本、高维数据的分类。
- **神经网络**：通过多层神经元的非线性变换学习复杂的特征-类别映射，如 BP 神经网络、卷积神经网络（CNN，适用于图像分类），可处理非线性、高复杂度的分类任务。
- **朴素贝叶斯**：基于贝叶斯定理和特征条件独立假设，通过计算样本属于各类别的后验概率实现分类，具有计算简单、对小样本友好的特点。

②无监督机器学习方法

无监督方法**无标注训练数据**，其核心是通过挖掘数据的**内在结构或相似性**实现“分类”（实际为聚类），即把样本划分为若干簇，同一簇内样本相似度高，不同簇间相似度低，常见方法如下：

- **K-均值聚类**：预先指定簇的数量 K ，通过迭代更新簇中心，使簇内样本到中心的距离平方和最小，实现样本的硬划分，适用于簇呈球状分布的数据集。
- **层次聚类**：无需预先指定 K ，通过“自底向上聚合”（凝聚法）或“自顶向下分裂”（分裂法）构建聚类树，可直观展示样本的层级关系。
- **密度聚类（DBSCAN）**：基于样本的密度划分簇，能自动识别任意形状的簇，同时可标记噪声点，适用于存在异常值的数据集。

需注意：无监督方法的“分类”本质为**聚类**，其簇的含义需人工后验解读，与有监督分类的“类别预先定义且有标注”存在本质区别。