

2022 年同等学力申硕计算机综合试题-人工智能原理

一、单项选择题 (每小题 3 分, 共 9 分)

1. 主观贝叶斯方法是一种 (B) 方法。

- A. 机器学习的分类
- B. 不确定性推理
- C. 知识表示

解析：考查不确定性推理

正确答案是 B。

- 主观贝叶斯方法的核心是基于贝叶斯定理，结合先验概率、似然概率和证据，计算后验概率以处理不确定信息，是人工智能中**不确定性推理**的经典方法。故选 B。
- A. 机器学习的分类方法聚焦于通过数据训练模型实现类别划分（如决策树、SVM），主观贝叶斯方法不属此类；
- C. 知识表示是对知识的结构化描述（如本体、产生式规则），主观贝叶斯方法是推理手段，而非表示方法。

2. 关于启发式搜索描述正确的是 (A) 。

- A. 启发函数没有固定的模式，需要针对具体问题分析
- B. 启发式搜索不能在盲目搜索基础上增加启发函数完成
- C. 启发式搜索可以不用启发函数指导搜索

解析：考查启发式搜索

正确答案是 A。

- 启发式搜索的核心是通过**启发函数**估计节点到目标状态的代价，引导搜索向更优方向推进。启发函数需贴合具体问题场景设计（如八数码问题用“错位棋子数”，路径规划用“直线距离”），无统一固定模式，因此 A 正确。
- B 错误：启发式搜索本质是在盲目搜索（如广度优先、深度优先）的基础上，增加启发函数来剪枝无效路径、提升效率，并非不能基于盲目搜索实现。
- C 错误：启发函数是启发式搜索的核心指导依据，缺少启发函数则搜索失去“启发”性，退化为盲目搜索，因此启发式搜索必须依赖启发函数。

3. 下面关于 BP 神经网络描述正确的是 (B) 。

- A. 允许同层神经元有连接
- B. 采用梯度下降法进行训练
- C. 可以不使用激活函数来完成非线性可分数据的多分类

解析：考查神经网络

正确答案是 B。

- BP 神经网络（反向传播神经网络）的核心训练逻辑是**反向传播误差+梯度下降法**：前向传播计算预测输出，反向传播求解误差对各层权重的梯度，再通过梯度下降更新权重以最小化损失，因此 B 正确。
- A 错误：标准 BP 神经网络为多层前馈结构，仅允许神经元跨层连接（输入层→隐藏层→输出层），同层神经元之间无连接，避免信息循环干扰。

- C 错误：激活函数（如 Sigmoid、ReLU）是 BP 神经网络实现非线性映射的关键，若无激活函数，网络退化为线性模型，无法处理非线性可分数据的分类任务。

二、证明题（共 9 分）

使用归结法证明： $((T \wedge Q) \rightarrow P) \rightarrow (T \rightarrow (Q \rightarrow (S \vee P)))$ 。

证明：考查归结推理

1. 将原式化为子句集：

- 首先对 $((T \wedge Q) \rightarrow P) \rightarrow (T \rightarrow (Q \rightarrow (S \vee P)))$ 进行化简。
- 原式可化为 $\neg(\neg T \vee \neg Q \vee P) \vee (\neg T \vee \neg Q \vee S \vee P)$ 。
- 再根据德摩根定律 $(T \wedge Q \wedge \neg P) \vee (\neg T \vee \neg Q \vee S \vee P)$ 。
- 求其否定 $(\neg T \vee \neg Q \vee P) \wedge T \wedge Q \wedge \neg P \wedge \neg S$ 。
- 得到子句集 $S = \{\neg T \vee \neg Q \vee P, T, Q, \neg P, \neg S\}$ 。

2. 进行归结推理：

- 对 $\neg T \vee \neg Q \vee P$ 和 T 进行归结，消去 T 和 $\neg T$ ，得到 $\neg Q \vee P$ 。
- 对 $\neg Q \vee P$ 和 Q 进行归结，消去 Q 和 $\neg Q$ ，得到 P 。
- 对 P 和 $\neg P$ 进行归结，消去 P 和 $\neg P$ ，得到空子句口。

3. 得出结论：

因为通过归结得到了空子句，根据归结原理，说明子句集 S 是不可满足的。

而子句集 S 是原式否定的子句集，所以原式 $((T \wedge Q) \rightarrow P) \rightarrow (T \rightarrow (Q \rightarrow (S \vee P)))$ 是永真的，即证明了 $((T \wedge Q) \rightarrow P) \rightarrow (T \rightarrow (Q \rightarrow (S \vee P)))$ 。

三、简答题（每小题 4 分，共 12 分）

1. 说明使用支持向量机求解二分类问题的原理。

答：考查支持向量机

支持向量机（Support Vector Machine, SVM）是一种基于统计学习理论的监督学习算法，主要用于解决二分类问题。其核心原理是通过寻找一个最优分类超平面，实现两类样本的分离，并最大化分类间隔，从而提高模型的泛化能力。以下从几个方面详细说明其原理：

● 核心目标：最大化分类间隔

分类间隔指两类样本中距离分离超平面最近的点（即支持向量）到超平面的距离之和。SVM 的核心是选择间隔最大的超平面，因为间隔越大，模型对新样本的抗干扰能力越强，泛化误差越小。

- 线性可分场景的数学建模
- 对偶问题与支持向量特性
- 核函数处理非线性可分问题
- 软间隔机制适配噪声与重叠样本

综上所述，SVM 通过“最大化间隔”实现核心分类逻辑，以凸二次规划求解最优超平面，借助核函数拓展至非线性场景，通过软间隔兼容噪声，最终利用支持向量的稀疏性高效完成二分类任务。

2. 解释什么是分支界限法。

答：考查搜索方法

分支界限法是一种用于求解组合优化问题的精确算法，特别适用于整数规划、旅行商问题等 NP 难问题。它通过系统地将问题分解为子问题（分支）并计算子问题的目标函数值界限（界限），来避免无效搜索，从而高效地找到最优解。

(1) 核心思想

- **分支：**将原问题分解为多个更小的子问题，通常通过限制某些变量的取值范围（例如，将整数变量固定为 0 或 1）。
- **界限：**对每个子问题计算一个上界（对于最大化问题）或下界（对于最小化问题），以评估该子问题可能包含的最优解范围。如果子问题的界限不优于当前已知的最优解，则剪枝该分支，减少搜索空间。

(2) 算法步骤

- **初始化：**设置一个优先队列（通常基于界限值）来存储待处理的子问题，并初始化当前最优解。
- **分支：**从队列中取出一个子问题，进一步分解为更细的子问题。
- **计算界限：**对每个子问题计算界限，并与当前最优解比较。
- **剪枝：**如果子问题的界限表明不可能包含更优解，则丢弃该子问题；否则，将其加入队列。
- **终止条件：**当队列为空时，算法结束，当前最优解即为全局最优解。

(3) 应用场景

- 整数线性规划
- 旅行商问题
- 背包问题
- 调度问题

(4) 优点

- **保证最优性：**通过系统搜索和剪枝，确保找到全局最优解。
- **高效性：**剪枝策略显著减少搜索空间，比暴力枚举更高效。
- **灵活性：**可结合多种启发式方法改进界限计算。

总结：分支界限法是一种结合了分支和界限策略的树搜索算法，通过智能剪枝来平衡搜索效率和解的最优性，是解决复杂优化问题的重要工具。

3. 说明在证据理论中，用哪三个函数来描述和处理知识的不确定性。

答：考查不确定推理

在证据理论（Dempster-Shafer 理论）中，用于描述和处理知识不确定性的三个核心函数如下：

(1) 基本概率分配函数（Basic Probability Assignment, BPA）

- **定义：**也称为质量函数（mass function），记作 $m(A)$ ，其中 A 是假设空间（识别框架）的子集。
- **作用：**表示证据直接支持命题 A 的程度，而不支持 A 的任何真子集。它满足： $m(\emptyset) = 0$ 和 $\sum_{A \subseteq \emptyset} m(A) = 1$ ，其中 $\emptyset$ 是假设空间（识别框架）。
- **特点：** $m(A)$ 反映了证据对 A 的精确信任，但不分配信任给 A 的子集。

（2）信任函数（Belief Function）

- **定义：**记作 $Bel(A)$ ，表示对命题 A 的总信任程度。
- **计算：**它是所有子集 $B \subseteq A$ 的基本概率分配之和： $Bel(A) = \sum_{B \subseteq A} m(B)$ 。
- **作用：**度量证据最低限度支持 A 的程度，反映了命题的保守信任。

（3）似然函数（Plausibility Function）

- **定义：**记作 $Pl(A)$ ，表示命题 A 的合理程度。
- **计算：**它是所有与 A 相交的子集 B （即 $B \cap A \neq \emptyset$ ）的基本概率分配之和： $Pl(A) = \sum_{B \cap A \neq \emptyset} m(B)$ 。
- **作用：**度量证据不反对 A 的程度，反映了命题的乐观信任。

关系与意义

- **信任区间：**对于命题 A ，不确定性由 $[Bel(A), Pl(A)]$ 表示，其中 $Bel(A)$ 是下限， $Pl(A)$ 是上限。
- **处理不确定性：**这三个函数共同允许模型区分“不确定”和“不知道”，能有效处理不完全信息、冲突证据和合成规则（如 Dempster 组合规则）。

总结：证据理论通过基本概率分配、信任函数和似然函数，定量描述知识的支持、信任和合理范围，为不确定性推理提供强大工具。