

2025 年同等学力申硕计算机综合-模拟试卷-人工智能原理

一、单项选择题（每题 1 分，共 5 分）

1. 以下哪种知识表示方法常用于表示因果关系（ B ）

A. 语义网络 B. 产生式规则 C. 框架 D. 谓词逻辑

解析：考查知识表示

语义网络(A): 通过节点和有向边表示概念及关系(如 “is-a”, “part-of”), 更适合描述层次结构或关联性知识, 而非显式因果关系。

产生式规则(B) 是一种基于 “如果 - 那么” (IF-THEN) 结构的知识表示方法, 通常用于描述因果关系、逻辑推理或决策规则。例如, “如果下雨(条件), 那么地面会湿(结果)” 可表示为一条产生式规则, 故答案为 B。

框架(C): 以 “框架 - 槽 - 值” 结构组织知识, 用于表示对象的属性和默认值, 适用于结构化场景(如 “汽车框架” 包含 “车轮” “引擎” 等槽), 但不直接用于因果建模。

谓词逻辑(D): 通过逻辑表达式(如 $\forall x (P(x) \rightarrow Q(x))$) 表示精确的逻辑关系, 虽能描述因果关系, 但更侧重形式化逻辑推理, 不如产生式规则直观适用于启发式因果描述。

2. 以下关于 AI 大模型微调的说法, 正确的是（ C ）。

A. 微调只能使用少量数据, 否则会改变大模型的核心能力

B. 微调时不需要考虑原模型的预训练权重, 可重新随机初始化

C. 微调是在特定任务数据集上对预训练大模型进行参数调整, 以提升特定任务性能

D. 所有类型的 AI 大模型都适合任何任务的微调

解析：考查大模型

微调的核心目的是通过特定任务数据优化预训练大模型的参数, 使其更适配目标任务 (C 正确)。具体分析如下:

- A 错误: 微调可使用少量或大量数据, 取决于任务需求。例如, 医疗等专业领域可能需要较多领域数据, 合理微调不会破坏模型核心能力, 反而能增强专业性。

- B 错误: 微调必须基于原模型的预训练权重(即 “迁移学习”), 而非随机初始化。预训练权重已蕴含通用知识, 微调是在此基础上针对特定任务优化, 而非从头训练。

- D 错误: 不同大模型有其擅长领域(如文本生成模型 GPT、图像模型 Stable Diffusion), 强行用于不匹配的任务(如用文本模型处理图像任务)效果差, 且并非所有模型都支持任意任务微调(如某些模型架构不适合特定任务)。

3. 机器学习中, 决策树算法属于（ A ）

A. 监督学习 B. 无监督学习 C. 半监督学习 D. 强化学习

解析：考查机器学习

决策树算法属于监督学习 (A)，其核心特点是基于有标签数据（输入特征与对应输出结果）构建树形分类或回归模型。具体分析如下：

- **监督学习 (A)**：通过已标注的训练数据学习输入与输出的映射关系，适用于分类、回归任务。决策树通过递归划分特征空间（如 ID3 算法基于信息增益、C4.5 基于信息增益比），生成用于预测新样本标签的规则，典型应用包括鸢尾花分类、客户流失预测等。
- **无监督学习 (B)**：处理无标签数据，旨在发现数据内在结构（如聚类、关联规则），如 K-means、Apriori 算法，与决策树依赖标签的特性不符。
- **半监督学习 (C)**：结合少量有标签数据和大量无标签数据，通过挖掘无标签数据的分布规律辅助学习，决策树通常不依赖此类混合数据模式。
- **强化学习 (D)**：通过智能体与环境的交互试错学习最优策略，以累积奖励为目标，典型场景为游戏（如 AlphaGo）、机器人控制，与决策树的监督学习框架无关。

4. 专家系统的核心组成部分不包括 (C)

A. 知识库 B. 推理机 C. 数据库 D. 解释器

解析：考查专家系统

专家系统的核心组成部分包括知识库、推理机、解释器和用户界面，而数据库并非核心组件 (C 符合题意)。具体说明如下：

- **知识库 (A)**：存储领域专家的专业知识，通常以规则、事实等形式组织（如“如果症状为头痛且发烧，则可能是感冒”）。
- **推理机 (B)**：基于知识库中的知识，对用户输入的问题进行逻辑推理，得出结论（如通过匹配规则推断疾病）。
- **数据库 (C)**：一般用于存储实时数据或中间结果，但并非专家系统的必需核心模块。专家系统更依赖静态的知识库和动态的推理机制，而非专门的数据库组件。故选 C。
- **解释器 (D)**：向用户解释推理过程和结论的依据，增强系统的透明性和可信度（如“为什么诊断为感冒？因为符合规则 X、Y”）。

5. 以下哪个不是当前主流 AI 大模型常用的架构？ (C)

A. Transformer B. LSTM C. CNN D. GPT 变体架构

解析：考查大模型

CNN（卷积神经网络）不是当前主流 AI 大模型的常用整体架构 (C 符合题意)，具体分析如下：

- **Transformer (A)**：是主流大模型的核心架构，如 GPT 系列（用于自然语言处理）、ViT（用于图像识别）等均基于此。其通过自注意力机制捕获全局依赖关系，擅长处理长序列数据，是大模型实现泛化能力的基础。
- **LSTM (B)**：属于循环神经网络(RNN)的变种，虽在早期语言模型(如 Word2Vec)中应用广泛，但因计算效率低、长距离依赖问题，在当前超大规模模型中多作为辅助组件(而非核心架构)，或用于特定序列任务(如语音识别预处理)。
- **CNN (C)**：主要用于图像领域（如 ResNet、YOLO），通过卷积层提取局部特征，但难以直接处理长序列数据（如文本），且计算复杂度随模型规模扩大呈指数增长，因此较少作为主流大模型的整体架构（仅在多模态模型中用于处理图像分支，如 CLIP、DALL·E）。

- **GPT 变体架构 (D):** 如 GPT-3、GPT-4、LLaMA 等均属于 Transformer 的变体，是自然语言处理大模型的代表架构。

二、简答题（每题 5 分，共 10 分）

1. 解释什么是启发式搜索，并说明启发函数的作用。

解析：考查启发式搜索

启发式搜索是一种在问题求解过程中利用启发式信息（即与问题相关的经验性知识或规则）引导搜索方向的方法。它通过评估函数（启发函数）对当前状态进行评分，优先扩展更有可能接近目标的节点，从而减少搜索空间，提高效率。

启发函数的作用：

- **引导搜索方向：**通过量化节点与目标状态的“距离”或“优劣”（如曼哈顿距离、代价估计等），让搜索优先探索更有希望的路径，避免盲目遍历。
- **优化搜索效率：**减少不必要的节点扩展，降低时间和空间复杂度。例如，在 A * 算法中，启发函数 $h(n)$ 若能准确估计当前节点到目标的最小代价，则可保证找到最优解且效率优于广度优先搜索。
- **平衡完备性与效率：**合理设计的启发函数可在保证解的正确性（如 A * 算法的 admissible 条件）的同时，显著提升搜索速度。若启发函数不准确，可能导致次优解或搜索效率下降。

2. 简述 AI 大模型与传统机器学习模型在模型规模、训练数据和应用场景方面的主要区别。

解析：考查大模型和机器学习

AI 大模型与传统机器学习模型在以下三方面存在显著区别：

(1) 模型规模

- **AI 大模型：**参数规模庞大，通常达数十亿至数万亿级（如 GPT-4 含约 1.8 万亿参数），依赖深度神经网络架构（如 Transformer）实现复杂特征学习。
- **传统机器学习模型：**参数规模较小，通常为几千至几十万级（如逻辑回归、随机森林），架构相对简单，难以捕捉高维数据中的复杂模式。

(2) 训练数据

- **AI 大模型：**
 - **数据量：**需海量数据（通常数十亿至万亿级样本），如 GPT 系列基于互联网文本、代码等混合数据训练。
 - **数据多样性：**覆盖多领域、多模态数据（文本、图像、语音等），以学习通用知识与跨领域关联。
- **传统机器学习模型：**
 - **数据量：**依赖数千至数万级标注样本，数据规模受限。
 - **数据专业性：**聚焦单一领域（如医疗影像、金融交易），需人工预处理和特征工程，泛化能力较弱。

(3) 应用场景

- **AI 大模型：**

- **通用性强：**可跨领域解决复杂任务，如自然语言处理（文本生成、翻译）、计算机视觉（图像生成、视频理解）、多模态交互（图文问答）等。
- **典型场景：**智能助手（如 ChatGPT）、内容创作（如 DALL·E）、科学发现（如 AlphaFold）。

- **传统机器学习模型：**

- **任务专一性：**仅适用于单一类型任务，如信用卡欺诈检测（分类）、房价预测（回归）、简单图像分类。
- **局限性：**难以处理未见过的复杂场景，需针对新任务重新设计模型和流程。

总结

AI 大模型通过“大规模参数 + 海量数据”实现通用能力，而传统模型聚焦特定场景的高效求解。前者推动 AI 从“专用工具”向“通用智能”演进，后者仍是垂直领域的实用选择。

三、综合应用题（本大题共 1 小题，共 15 分）

假设有一个八数码问题，初始状态为 [2, 8, 3, 1, 6, 4, 7, 0, 5]，目标状态为 [1, 2, 3, 8, 0, 4, 7, 6, 5]。其中 0 表示空格。

(1) 请使用广度优先搜索算法求解该问题，画出搜索树（只需要画出前三层节点，每个节点标注其状态）。（8 分）

(2) 如果使用 A* 算法，设计一个启发函数，并说明其合理性。（7 分）

解析：考查搜索算法

八数码问题中的状态通常用一个长度为 9 的一维数组表示，代表一个 3x3 的棋盘。如下：

初始状态：

[2, 8, 3,
1, 6, 4,
7, 0, 5]

对应棋盘：

2 8 3
1 6 4
7 0 5

目标状态：

[1, 2, 3,
8, 0, 4,
7, 6, 5]

对应棋盘：

1 2 3
8 0 4
7 6 5

(1) BFS 前三层搜索树

● 层 0:

➤ [2, 8, 3, 1, 6, 4, 7, 0, 5]

● 层 1:

➤ [2, 8, 3, 1, 0, 4, 7, 6, 5]

➤ [2, 8, 3, 1, 6, 4, 0, 7, 5]

➤ [2, 8, 3, 1, 6, 4, 7, 5, 0]

● 层 2:

➤ [2, 0, 3, 1, 8, 4, 7, 6, 5]

➤ [2, 8, 3, 0, 1, 4, 7, 6, 5]

➤ [2, 8, 3, 1, 4, 0, 7, 6, 5]

➤ [2, 8, 3, 0, 6, 4, 1, 7, 5]

➤ [2, 8, 3, 1, 6, 0, 7, 5, 4]

(2) A * 启发函数设计:

启发函数定义: $h(n)$ = 错位棋子数 + 所有棋子到目标位置的曼哈顿距离之和)

● **错位棋子数**: 当前状态中位置与目标状态不一致的棋子数量 (0 不计)。

● **曼哈顿距离**: 每个棋子当前坐标与目标坐标的横向和纵向距离之和 (例如, 棋子 8 在初始状态的坐标为 (0, 1), 目标坐标为 (1, 0), 曼哈顿距离为 $|0-1| + |1-0| = 2$)。

推荐使用: 曼哈顿距离。

合理性分析: 它是可采纳的 (不会高估真实代价), 且比错位棋子更准确, 能更快找到最优解。